

## 미세먼지 예측을 위한 기계 학습 알고리즘의 적합성 평가

조경우<sup>1</sup> · 정용진<sup>1</sup> · 강철규<sup>2</sup> · 오창현<sup>3\*</sup>

### Conformity Assessment of Machine Learning Algorithm for Particulate Matter Prediction

Kyoung-woo Cho<sup>1</sup> · Yong-jin Jung<sup>1</sup> · Chul-gyu Kang<sup>2</sup> · Chang-heon Oh<sup>3\*</sup>

<sup>1</sup>Ph.D. student, Department of Electrical, Electronics & Communication Engineering, Korea University of Technology and Education(KOREATECH), Cheonan 31253, Korea

<sup>2</sup>Chief researcher, Photo Team, SEMES Co., LTD., Cheonan, 31040 Korea

<sup>3\*</sup>Professor, Department of Electrical, Electronics & Communication Engineering, Korea University of Technology and Education(KOREATECH), Cheonan 31253, Korea

#### 요 약

미세먼지의 인체 영향으로 인해 기존 대기 환경 모니터링 네트워크에서 측정된 과거 데이터를 활용하여 미세먼지를 예측하려는 다양한 연구가 진행되고 있다. 하지만 기존 설계된 예측 모델의 측정 환경, 세부 조건을 정확히 설정하기 어려우며, 측정된 기상 데이터의 누락과 같은 문제로 기존 연구 결과에 기반한 새로운 예측 모델의 설계가 필요하다. 본 논문에서는 미세먼지 예측을 위한 선행 연구로서 다수의 연구에서 사용된 기계 학습 알고리즘인 다중 선형 회귀와 인공 신경망을 통해 예측 모델을 설계하여 미세먼지 예측을 위한 알고리즘의 적합성을 평가하였다. RMSE를 통한 예측 성능 비교 결과, MLR 모델의 경우 18.13, MLP 모델의 경우 14.31의 값을 보여 미세먼지 농도를 예측함에 있어 인공 신경망 모델이 예측에 더 적합함을 보였다.

#### ABSTRACT

Due to the human influence of particulate matter, various studies are being conducted to predict it using past data measured in the atmospheric environment monitoring network. However, it is difficult to precisely set the measurement environment and detailed conditions of the previously designed predictive model, and it is necessary to design a new predictive model based on the existing research results because of the problems such as the missing of the weather data. In this paper, as a previous study for particulate matter prediction, the conformity of the algorithm for particulate matter prediction was evaluated by designing the prediction model through the multiple linear regression and the artificial neural network, which are machine learning algorithms. As a result of the prediction performance comparison through RMSE, 18.13 for the MLR model and 14.31 for the MLP model, and the artificial neural network model was more conformable for predicting the particulate matter concentration.

**키워드** : 미세먼지, 예측, 기계 학습, 딥 러닝, 인공 신경망

**Key word** : Particulate matter, Prediction, Machine learning, Deep learning, Artificial neural network

Received 7 September 2018, Revised 17 September 2018, Accepted 1 October 2018

\* Corresponding Author Chang-Heon Oh(E-mail:choh@koreatech.ac.kr, Tel:+82-41-560-1215)

Professor, Department of Electrical, Electronics & Communication Engineering, Korea University of Technology and Education (KOREATECH), Cheonan 31253, Korea

Open Access <http://doi.org/10.6109/jkiice.2019.23.1.20>

print ISSN: 2234-4772 online ISSN: 2288-4165

© This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License(<http://creativecommons.org/licenses/by-nc/3.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.  
Copyright © The Korea Institute of Information and Communication Engineering.

## I. 서 론

미세먼지(Particulate Matter; PM)는 다양한 크기, 모양, 성분을 가진 대기 중에서 부유하고 있는 혼합물이며, 환경 정책에 대한 중요성으로 과학적 관심이 높아지고 있다[1],[2]. 미세먼지는 호흡기의 흉부 부위를 통과할 수 있을 만큼 작은 흡입 입자를 포함하기 때문에 지상의 오존 및 기타 대기 오염 물질(일산화탄소와 같은)보다 인체 건강에 더 큰 위험을 초래한다. 미세먼지는 대기 중에 부유하는 고체 입자와 액체 입자의 이중 혼합물로 구성되며, 공간과 시간에 따라 크기와 화학 성분이 지속적으로 변한다[3]. 이러한 문제로 미세먼지의 인체 영향에 관한 많은 과학적 연구가 진행되었으며, 미세먼지의 화학적 성분은 심혈관, 호흡기, 뇌 혈관 질환에 영향을 미친다는 다수의 연구결과가 발표되었다. [4-7]. 이처럼 미세먼지에 의한 인체 영향은 대부분의 국가에서 심각한 환경 문제로 인식하고 있으며, 이에 각 국가에서는 대기 환경 모니터링 네트워크를 구축하여 사용자에게 실시간으로 측정 결과 및 예측 정보를 제공하고 있다. 우리나라의 경우 전 국토에 367개의 측정소를 배치하여 사용자에게 미세먼지 농도 측정 결과를 제공 중이다[8].

미세먼지 예측의 경우 대중의 인식과 대기 질 관리 능력을 향상시키기 위해 주변 농도를 정확히 예측할 수 있는 능력이 필요하다. 이에 많은 연구에서 통계 모델링 기법과 기계 학습 기법을 사용한 미세먼지 농도 예측 및 분석을 진행하였다. 그러나 해당 모델을 활용하기 위해 측정 환경 및 세부조건을 정확히 설정하는 데는 어려움이 따른다[9]. 또한 국내 측정소에서 제공하는 대기 환경 데이터의 경우 시스템의 유지 보수, 고장 등으로 누락된 데이터가 존재하여 기존 연구 결과를 토대로 새로운 예측 모델의 설계가 필요하다[10],[11]. 이에 본 논문에서는 미세먼지 예측을 위한 선행 연구로서 다수의 연구에서 공통적으로 활용된 기상 인자를 활용하여 기계 학습 알고리즘을 통한 미세먼지 예측을 수행한다. 이를 위해 천안 지역 측정소 3곳의 기상 데이터를 기반으로 주로 데이터 예측에 사용되는 기계학습 알고리즘인 다중 선형 회귀(Multiple Linear Regression; MLR), 인공 신경망(Artificial Neural Network; ANN)을 통해 예측 모델을 설계, 실제 데이터와의 비교를 통해 미세먼지 예측을 위한 알고리즘의 적합성을 평가한다.

## II. 관련 연구

A. Chaloulakou et al.의 연구에서는 2년간의 PM10농도, 기상 변수를 입력으로 하여 인공 신경망과 Multiple Linear Regression 모델을 통해 미세먼지 예측 성능을 비교하고 평가하였다. 두 모델을 비교한 결과 PM10의 예측을 위해 비선형 NN 방법이 더 나은 성능을 보였다고 평가하였다[12]. Munir et al.의 연구에서는 기상변수와 교통 관련 대기 오염 물질, 자연된 PM10 농도 데이터를 통해 PM10 농도를 모델링하였다. 이를 위해 Generalized Additive Model을 개발하고 평가한 결과 온도, 풍속과 같은 기상 변수가 PM10 농도예측 성능을 크게 조절한다는 것을 확인하였다[13]. M. M. Dedovic et al.의 연구에서는 3년간의 기상 변수 및 PM10 농도를 토대로 인공 신경망 기반의 PM10 농도 예측 결과를 보였다. 해당 연구에서는 이전 해의 PM10 데이터를 가진 확장된 입력 데이터 셋을 통해 PM10 농도 예측 성능을 높일 수 있음을 확인하였다[14]. J. W. Cha et al.의 연구에서는 2014~2017년의 실제 기상 및 대기 질 데이터를 이용하여 PM10의 미세먼지 수치를 예측하였다. 이를 위해 인공 신경망 및 K-Nearest Neighbor(K-NN) 알고리즘을 상호 응용하여 단일 알고리즘을 사용한 예측 결과와 설계한 예측 모델의 예측 결과와의 비교를 수행하였다[15]. 표 1은 관련 연구들의 입력 파라미터와 사용된 알고리즘을 정리한 표이다.

**Table. 1** Parameters and algorithms of related studies

Author	Parameters	Algorithms
A. Chaloulakou et al.	NO, NO2, CO, O3, Wind speed(m/s), Temperature(%), Humidity(°C), Wind direction	MLR ANN (Hidden layer : 1)
Munir et al.	NO, NO2, CO, SO2, Wind speed(m/s), Temperature(%), Humidity(°C), Wind direction	Generalized Additive Model
M. M. Dedovic et al.	Wind speed(m/s), Temperature(%), Humidity(°C), Pressure(hPa), PM10( $\mu g/m^3$ ), Weekdays, Hours	ANN (Hidden layer : 1)
J. W. Cha et al.	SO2, NO2, CO, O3, Precipitation(mm), Wind speed(m/s), Humidity(%), Daylight hours(hr), Temperature(°C), PM10( $\mu g/m^3$ )	ANN (Hidden layer : 1) K-NN

### III. 미세먼지 예측을 위한 기계 학습 모델 설계

#### 3.1. 다중 선형 회귀(MLR) 모델

회귀분석(regression analysis)은 관찰되거나 주어진 각각의 변수들에 대해 관련성을 밝히고 평가하는 방법이다. 선형 관계식에서 독립변수는 원인의 역할을 하는 변수이고 종속변수는 변화에 따른 결과로 관측되는 변수이다. 이를 통하여 독립변수의 영향력을 예측하는 것이 회귀분석의 일반적인 방법이다.

하나의 독립변수만을 고려하여 종속변수와의 관계를 분석하는 방법을 단순 선형 회귀 분석(simple linear regression analysis)라고 하고, 두 개 이상의 독립변수들의 변화로부터 종속변수의 변화를 예측하는 방법을 다중 선형 회귀 분석(multiple linear regression analysis)이라 한다.

단순 선형 회귀와 다중 선형 회귀의 기본 개념은 같지만 다중 선형 회귀의 경우 여러 개의 독립변수를 사용함으로써 예측 능력을 높일 수 있다. 독립변수가  $k$ 개인 다중 선형 회귀의 방정식은 예측변수와 오차제곱합을 최소화 하는 최소제곱법에 의해 식 (1)과 같이 수식화 된다.

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k \quad (1)$$

이때,  $\beta_k$ 는 회귀계수(coefficient)를 의미하며  $X_k$ 는  $k$ 번째 예측인자로 예측하고자 하는 변수  $Y_i$ 를 설명하는 값이다. 이에 따라 현재 미세먼지 농도와 관련된 기후요소로부터의 연관성을 찾으면 미세먼지 농도 예측이 가능하다는 의미가 된다[12],[16],[17].

본 논문에서는 월, 일, 온도, 습도, 풍속, 풍향, O<sub>3</sub>, NO<sub>2</sub>, CO, SO<sub>2</sub>를 독립 변수로 사용하여 식 (2)와 같이 PM<sub>10</sub>의 예측 모델을 설계하였다. 이 때 M은 월, D는 일, WS는 풍속, WD는 풍향을 의미한다.

$$\begin{aligned} Y = & -0.94M + 0.11D \\ & + 0.4Temp - 0.14Humi - 0.53WS \\ & + 0.01WD + 575.48O_3 + 897.36NO_2 \\ & + 33.43CO + 2760.61SO_2 \end{aligned} \quad (2)$$

#### 3.2. 인공 신경망(ANN) 모델

인공지능의 한 분야인 인공 신경망은 기계 학습과 인지 과학에서 인간의 뇌가 정보를 처리하는 구조를 모델로 한 아키텍처이다. 인공 신경망은 신경망의 최소 단위인 뉴런(노드)들 사이의 연결 패턴, 연결의 가중치를 갱신하는 학습과정, 마지막으로 뉴런의 가중 입력을 활성화화도 출력으로 바꿔주는 활성화 함수를 통해 정의된다. 활성화 함수는 일반적으로 sigmoid, hyperbolic tangent, ReLU 함수가 사용되며, 그 종류에 따라 input 값은 0과 1, 또는 -1과 1 사이의 출력 값으로 변환하여 다음 뉴런으로 전달하게 된다.




Fig. 1 Simple Neural network example

그림 1은 인공 신경망의 개략도이다. 인공 신경망의 layer는 크게 input layer, hidden layer, output layer로 구성되며 hidden layer를 한 개 이상 포함할 수 있다. 이 때, hidden layer의 수에 따라 1개의 경우 ANN, 2개 이상인 경우 Multi-Layer Perceptron(MLP), 다수의 hidden layer를 포함하는 경우 심층 신경망(Deep Neural Network; DNN)으로 구분한다. 각 layer의 뉴런들을 연결하는 연결선(Synapses)들은 각각의 가중치(weight)를 가지고 있다. 인공 신경망은 먼저 이들을 일정 수치로 초기화한 후, 최종 output layer의 손실(loss)을 줄이는 방향으로 가중치를 갱신하게 된다. 이를 위해 인공 신경망을

구성하고 있는 모든 연결선의 가중치를 손실함수(loss function)에 대한 미분값을 이용해 갱신하는 경사 하강법(gradient descent)을 사용한다. 경사 하강법은 forward propagation과 back propagation의 두 단계로 이루어지며, forward propagation을 통해 최종 loss를 계산하고, back propagation을 통해 손실을 줄이는 방향으로 각 가중치(weight)를 갱신한다[12],[15],[18-20].

본 논문에서는 인공 신경망의 PM10 예측 적합도를 평가하기 위한 신경망 모델을 설계하였다. 이 때, input layer의 입력 데이터는 MLR 모델과 동일하며, 1개의 hidden layer에 30개의 뉴런들로 구성된 ANN 모델과 3개의 hidden layer를 포함하는 MLP 모델을 설계하여 hidden layer 수에 따른 예측 성능을 비교하였다. 또한 MLP 모델의 경우 각각의 hidden layer에 포함된 뉴런의 수를 동일하게 구성하였으며, 뉴런의 수에 따른 예측 성능을 비교하기 위해 뉴런 수를 변경하여 두 종류의 MLP 모델을 설계하였다.

#### IV. 실험 및 평가

예측 모델은 크게 특정 수치를 예측하기 위한 regression과 분류를 위한 classification으로 구분할 수 있다. Classification 모델의 경우 모델의 평가를 위해 분류가 잘 이루어 졌는지 정확도를 이용하여 평가하며, regression 모델의 경우 실제 값과 예측 값의 차이를 표현하는 손실 함수로 평가한다.

본 논문에서 사용한 모델의 경우 regression 모델이며, 모델의 평가를 위해 손실 함수로 사용되는 평균 제곱근 오차(Root Mean Square Error;RMSE)를 이용하여 예측 성능을 평가하였다. RMSE는 모델이 예측한 값과 실제 값의 차이를 이용하여 정밀도를 표현하는 척도이며 식 (3)과 같이 계산 할 수 있다.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y - y_{pred})^2} \quad (3)$$

그림 2는 MLR을 이용한 미세먼지 농도의 예측 값과 실제 값을 비교한 그래프이다. 실제 PM10 수치와 예측 결과를 비교했을 때, 전체적인 예측 결과의 추세가 비슷한 모습을 보이고 있다. 그러나 25 ~ 35, 80 ~ 85, 155 ~

160 부분을 포함한 특정 부분에서 실제 값과 상승, 하강 추세가 반대로 예측된 것을 확인할 수 있다. 미세먼지 농도 값 오차의 경우 최대  $49.16 \mu g/m^3$ , 최소  $0.22 \mu g/m^3$ 의 농도 차이를 나타내었다




Fig. 2 PM10 prediction result using MLR




Fig. 3 PM10 prediction result using ANN and MLP

그림 3은 ANN과 MLP를 이용한 미세먼지 농도의 예측 값과 실제 값을 비교한 그래프이다. ANN의 미세먼지 농도 값 오차의 경우 실제 값과 최대  $53.43 \mu g/m^3$ , 최소  $0.04 \mu g/m^3$ 을 보였으며, MLP의 경우 최대  $48.81 \mu g/m^3$ , 최소  $0.01 \mu g/m^3$ 의 값을 나타내었다. 그림 2와 그림 3을 비교 하였을 때, 전반적인 예측 결과는 MLR 모델보다 ANN 모델의 예측 성능이 높음을 확인 할 수 있다. 또한 ANN 모델과 MLP 모델을 비교하였을 때, 실제 값에 더 근접한 모델은 MLP 모델임을 확인 할 수 있다.




Fig. 4 MLP prediction results according to the number of neurons

그림 4는 실제 데이터에 가장 근접한 모습을 보인 MLP 모델의 뉴런 수에 따른 예측 성능의 비교를 위해 각 hidden layer의 뉴런 수를 달리 한 예측 결과를 나타낸다. MLP 1의 경우 각 hidden layer의 뉴런 수를 30개로 구성하였으며, MLP 2의 경우 각 hidden layer의 뉴런 수를 60개로 구성하였다. 예측 결과 hidden layer의 뉴런 수가 30개인 MLP 1 모델이 실제 데이터와 더 유사한 결과를 보였으며, hidden layer의 뉴런 수가 60개인 MLP 2 모델의 경우 약  $20\sim 80\mu g/m^3$  범위 내에서 예측 값을 출력하여 급격히 변화하는 PM10 농도 값의 경우 큰 오차를 보였다. 실제 데이터와 예측된 PM10 농도 값 오차의 경우 MLP 1 모델은 최대  $48.81\mu g/m^3$ , 최소  $0.01\mu g/m^3$ 을 보였으며, MLP 2 모델의 경우 최대  $64.16\mu g/m^3$ , 최소  $0.1\mu g/m^3$ 의 값을 나타내었다.

설계된 각 예측 모델의 오차 평균인 RMSE의 경우 표 2와 같다. RMSE 값의 경우 MLP 1 - MLP 2 - ANN - MLR 순으로 값이 증가하는 것을 확인 할 수 있으며, 이는 미세먼지 농도를 예측함에 있어 MLR 모델보다 ANN 모델이 예측에 더 적합하다고 판단된다. 또한 ANN 모델을 통해 예측을 수행하더라도 hidden layer의 수, hidden layer의 뉴런 수의 따라 서로 다른 예측 성능을 보일 수 있어 예측 모델 설계 시 적절한 뉴런 수를 적용한 hidden layer의 구성이 중요함을 알 수 있다.

Table. 2 RMSE comparison for each models

Model	Hidden layer neurons	RMSE
MLR	-	18.13
ANN (hidden layer : 1)	30	17.25
MLP 1 (hidden layer : 3)	30	14.31
MLP 2 (hidden layer : 3)	60	15.84

## V. 결 론

미세먼지의 인체 영향으로 인해 대부분의 국가에서 미세먼지를 심각한 환경 문제로 인식하고 있다. 이에 대중의 인식과 대기 질 관리 능력 향상을 위해 각 국가에서 구축된 대기 환경 모니터링 네트워크에서 측정된 과거 데이터를 활용하여 미세먼지를 예측하려는 다수의 연구가 진행 중이다. 그러나 기존 연구 결과에서 설계된 모델을 활용하기 위해 측정 환경 및 세부조건을 정확히 설정하는 것은 어려우며, 측정소 시스템의 유지 보수, 고장 등으로 인한 데이터의 누락과 같은 문제로 기존 연구 결과에 기반 한 새로운 예측 모델 설계가 필요하다. 이에 본 논문에서는 미세먼지 예측을 위한 선행 연구로서 다수의 연구에서 공통적으로 활용된 기상 인자를 활용하여 기계 학습 기반의 미세먼지 예측을 수행하였다. 이를 위해 천안 지역 측정소 3곳의 기상 데이터를 기반으로 미세먼지 예측을 위한 다수의 연구에서 사용된 알고리즘인 다중 선형 회귀(MLR)와 인공 신경망(ANN)을 통해 예측 모델을 설계하고 실제 데이터와의 비교를 통해 미세먼지 예측을 위한 알고리즘의 적합성을 평가하였다. 설계된 예측 모델의 오차 평균인 RMSE를 비교한 결과, MLR 모델의 경우 18.13, ANN 모델의 경우 17.25의 RMSE 값을 보여 미세먼지 예측을 위한 알고리즘의 경우 ANN이 더 좋은 성능을 보임을 확인하였다. 또한, ANN의 hidden layer 수, hidden layer 내의 뉴런 수에 따른 예측 성능을 비교한 결과 hidden layer의 수가 더 많은 MLP 모델이 ANN 모델보다 2.94 낮은 RMSE 값을 나타내었다. 또한 동일한 hidden layer의 수를 가진 모델이라도 뉴런 수에 따른 예측 성능 차이를 보였다. 이는 hidden layer를 구성하는 뉴런의 수에 따라 시냅스

수의 변화로 인해 가중치가 변하게 되어 나타나는 결과로서 ANN을 사용한 미세먼지 예측 모델 설계 시 적절한 뉴런 수를 적용한 hidden layer의 구성이 중요함을 확인하였다.

### ACKNOWLEDGEMENT

This paper was supported by the Education and Research Promotion Program of KOREATECH in 2017.


### REFERENCES

- [ 1 ] C. A. Pope III, D. W. Dockery, "Health effects of fine particulate air pollution: Lines that connect," *Journal of the Air & Waste Management Association*, vol. 56, no. 6, pp. 709-742, 2006.
- [ 2 ] S. Fuzzi, U. Baltensperger, K. Carslaw, S. Decesari, H. Denier van der Gon, M.C. Facchini, D. Fowler, I. Koren, B. Langford, U. Lohmann, E. Nemitz, S. Pandis, I. Riipinen, Y. Rudich, M. Schaap, J. G. Slowik, D. V. Spracklen, E. Vignati, M. Wild, M. Williams, and S. Gilardoni, "Particulate matter, air quality and climate: Lessons learned and future needs," *Atmospheric chemistry and physics*, vol. 15, no. 14, pp. 8217-8299, 2015.
- [ 3 ] World Health Organization (WHO), "Health effects of particulate matter: Policy implications for countries in eastern europe, caucasus and central asia," *Regional Office for Europe*, 2013.
- [ 4 ] A. Valavanidis, K. Fiotakis, and T. Vlachogianni, "Airborne particulate matter and human health: Toxicological assessment and importance of size and composition of particles for oxidative damage and carcinogenic mechanisms," *Journal of Environmental Science and Health, Part C*, vol. 26, no. 4, pp. 339-362, 2008.
- [ 5 ] J. O. Anderson, J. G. Thundiyil, and A. Stolbach, "Clearing the air: A review of the effects of particulate matter air pollution on human health," *Journal of Medical Toxicology*, vol. 8, no. 2, pp. 166-175, 2012.
- [ 6 ] K. H. Kim, E. Kabir, and S. Kabir, "A review on the human health impact of airborne particulate matter," *Environment international*, vol. 74, pp. 136-143, 2015.
- [ 7 ] N. J. Hime, G. B. Marks, and C. T. Cowie, "A comparison of the health effects of ambient particulate matter air pollution from five emission sources," *International Journal of Environmental Research and Public Health*, vol. 15, no. 6, 2018.
- [ 8 ] Airkorea - Station Information [internet]. Available: <https://airkorea.or.kr/stationInfo/>.
- [ 9 ] K. T. Sohn, and D. H. Kim, "Development of statistical forecast model for PM10 concentration over Seoul," *Journal of the Korean Data and Information Science Society*, vol. 26, no. 2, pp. 289-299, 2015.
- [10] Y. J. Jung, K. W. Cho, C. G. Kang, and C. H. Oh, "Particulate matter prediction model using artificial neural network," in *Proceeding of Korea Information and Communication Engineering*, vol. 22. no. 2, Jeju, pp. 623-625, 2018.
- [11] K. W. Cho, Y. J. Jung, C. G. Kang, and C. H. Oh, "Particulate matter prediction using multi-layer perceptron network," in *Proceeding of Korea Information and Communication Engineering*, vol. 22. no. 2, Jeju, pp. 620-622, 2018.
- [12] A. Chaloulakou, G. Grivas, and N. Spyrellis, "Neural Network and multiple regression models for PM10 prediction in Athens: A comparative assessment," *Journal of the Air & Waste Management Association*, vol. 53, no. 10, pp. 1183-1190, 2003.
- [13] S. Munir, M. T. Habeebullah, A. R. Seroji, E. A. Morsy, A. M. Mohammed, W. A. Saud, A. E. A. Abdou, and A. H. Awad, "Modeling particulate matter concentrations in Makkah, Applying a statistical modeling approach," *Aerosol and Air Quality Research*, vol. 13, no. 3, pp. 901-910, 2013.
- [14] M. M. Dedovic, S. Avadakov, I. Turkovic, N. Dautbasic, and T. Konjic, "Forecasting PM10 concentrations using neural networks and system for improving air quality," in *proceeding of 2016 XI International Symposium on Telecommunications (BIHTEL)*, Sarajevo, pp. 1-6, 2016.
- [15] J. W. Cha, and J. Y. Kim, "Development of data mining algorithm for implementation of fine dust numerical prediction model," *Journal of the Korea Institute of Information and Communication Engineering*, vol. 22, no. 4, pp. 595-601, 2018.
- [16] S. Kim, "A study on prediction of blood donation number using multiple linear regression analysis," M.S. dissertation, Sungkyunkwan University, 2015.
- [17] J. B. Ahn, and Y. M. Cha, "A comparison study of corrections using artificial neural network and multiple linear regression for dynamically downscaled winter temperature over South Korea," *Asia-Pacific Journal of*



*Atmospheric Sciences*, vol. 41, no. 3, pp. 401-413, 2005.

- [18] J. Choi, "A study on automatic composition based on neural network," M.S. dissertation, Ajou University, 2017.
- [19] V. Sze, Y. H. Chen, T. J. Yang, and J. S. Emer, "Efficient processing of deep neural networks: A tutorial and survey," in *Proceedings of the IEEE*, vol. 105, issue 12, 2017.
- [20] D. Dubey, and G. S. Tomar, "Echelon based pose generalization of facial images approaches," *Asia-pacific Journal of Convergent Research Interchange*, vol. 3, no. 1, pp. 63-75, 2017.



**조경우(Kyoung-Woo Cho)**

2015년 3월 ~ 현재 한국기술교육대학교 전기전자통신공학과 박사과정  
 2015년 2월 한국기술교육대학교 전기전자통신공학과 공학석사  
 2013년 2월 공주대학교 전기전자제어공학부 전자공학나노정보공학전공 전자공학트랙 공학사  
 ※관심분야 : 미세먼지 예측, 인공지능경망, 심층신경망, Industrial IoT, LPWA



**정용진(Yong-Jin Jung)**

2018년 3월 ~ 현재 한국기술교육대학교 전기전자통신공학과 박사과정  
 2016년 2월 한국기술교육대학교 전기전자통신공학과 공학석사  
 2014년 2월 공주대학교 전기전자제어공학부 전자공학나노정보공학전공 전자공학트랙 공학사  
 ※관심분야 : 미세먼지 예측, 기계 학습, 인공지능경망, 심층신경망,



**강철규(Chul-Gyu Kang)**

2012년 9월 ~ 현재 ㈜세메스 책임연구원  
 2012년 8월 한국기술교육대학교 전기전자통신공학과 공학박사  
 2006년 2월 한국기술교육대학교 전기전자통신공학과 공학석사  
 2004년 2월 한국기술교육대학교 정보통신공학과 공학사  
 ※관심분야 : 기계 학습, MIMO, Wireless Sensor N/W



**오창헌(Chang-Heon Oh)**

1999년 2월 ~ 현재 한국기술교육대학교 전기전자통신공학부 교수  
 2006년 8월 ~ 2007년 7월 방문교수(University of Wisconsin-Madison)  
 1993년 10월 ~ 1999년 2월 삼성전자(주) CDMA 개발팀 선임연구원  
 1990년 2월 ~ 1993년 8월 한진전자(주) 기술연구소 전임연구원  
 1996년 2월 한국항공대학교 항공전자공학과 공학박사  
 1990년 2월 한국항공대학교 항공통신정보공학과 공학석사  
 1988년 2월 한국항공대학교 항공통신공학과 공학사  
 ※관심분야 : 무선/이동통신, IoT, 기계학습 기반 통신시스템