

수강 과목 : 기계학습

담당 교수 : 양희정 교수

논문 리뷰 과제 발표자 : 이우람 (학번: 202376602)

논문수집 출처 : DBPia

논문 제목: 머신러닝 기반 매출액 고성장 제약회사 예측 연구

논문 저자: 서신원, 양혜영

연도: 2023년

발행기관: 한국콘텐츠학회

※ 본 연구는 한국과학기술정보연구원 연구과제(K-21-L03-C01-S01)의

지원을 받아 수행되었습니다.

주제어: 임상시험, 특허, 머신러닝, 신약개발, 제약회사 R&D

데이터 출처: 클리니컬트라이얼즈, 인베스팅닷컴, 콤파스시스템(kisti운영)

사용 데이터: 임상시험 건수, 매출액 데이터, 특허 건수

머신러닝 모델: 랜덤 포레스트(Random Forest)

연구 결과 요약 :

특허와 임상시험 데이터를 동시에 사용한 모델의 정확도와 F1-척도가 대체로 높게 나타났고, 임상시험 데이터가 제약회사의 매출액 고성장 예측에 유의미한 영향을 미치는 것으로 확인되었다. 특히, 특허 및 임상시험 데이터를 활용한 머신러닝 분석이 제약회사의 매출액 고성장 예측에 효과적임을 입증하였다.

본 논문 특이점 :

본 논문은 제약회사의 매출액 증가에 있어서 임상시험 데이터의 중요성을 강조하고 있으며, 기존 연구들이 주로 특허나 연구개발 투자에 초점을 두었지만, 본 논문에서는 임상시험 데이터를 추가로 고려하여 예측 모델의 성능을 향상시킨 점에서 특별하다고 할 수 있다. 또한, 머신러닝 기법을 활용하여 제약산업의 성과를 예측하는 새로운 접근방식을 제시했다는 점에서 의미가 있다.

선택한 이유 :

제약회사 임상시험과 관련해서 관심이 있고, 비슷한 주제로 제 논문을 쓰고 싶어서 선택을 하였습니다.

1. 서론

제약회사의 생산성에 대한 이해와 성과 향상을 위한 다양한 연구들이 수행되었지만, 제약회사 연구개발의 핵심과정인 임상시험 단계와 매출액 증감 사이의 관련성을 고려한 연구가 부족했다. 그래서, 본 연구에서는 제약회사의 특허 및 임상시험이 제약회사 매출액 증감과 관련성이 있는지, 보다 구체적으로는 특허 및 임상시험 데이터를 이용하여 매출액이 고성장하는 제약회사를 분류하는 것이 가능하지, 이를 통해 고성장할 제약회사를 미리 예측할 수 있는지 알아보기 위해, 특허 건수 및 임상시험 건수 데이터에 대한 머신러닝 분석을 수행하였다.

2. 연구 배경 및 목적

제약산업은 기술집약적이고 고부가가치를 창출하는 산업으로, 매출액의 상당 부분인 10% 이상을 연구개발에 투자한다. 그러나, 최근 신약개발 비용의 급격한 증가로 인해 어려움을 겪고 있는데, 이는 주로 임상시험의 복잡성이 증대된 것이 원인이다. 임상시험은 신약개발 과정에서 핵심적인 역할을 하며, 전체 개발 비용의 50% 이상을 차지할 뿐만 아니라 신약의 성공 확률을 70% 이상 좌우하는 중요한 요소이기 때문에 특허와 임상시험 데이터를 활용한 머신러닝 분석을 통해 제약회사의 매출액 고성장 여부를 예측하고자 하였다.

3. 연구방법론

1) 데이터 수집

- 임상시험 데이터 출처: 클리니컬트라이얼즈 (<https://www.clinicaltrials.gov>)
- 임상시험 데이터 년도: 2012년~2018년
- 매출 데이터 출처: 인베스팅닷컴 (<https://www.investing.com>)
- 매출 데이터 년도: 2016년~2019년
- 특허 데이터 출처: 콤파스시스템 (<https://compass.kisti.re.kr/index.jsp>)
- 특허 데이터 년도: 2012년~2018년

2) 분석방법 : 머신러닝 기법 중 랜덤포레스트 알고리즘 사용

- 랜덤포레스트는 의사결정나무 형성과정에서 각 노드에서 입력변수를 무작위로 선택하고 그중에서 최적의 분리를 찾을 수 있다. 이러한 무작위적 입력변수는 상관관계가 낮아서 예측오차가 작아지고 과적합을 방지하는 데 유용하다.

3) 분석모델 설계

- 분석대상: 2012~2018년 미국에서 상장한 80개 제약회사
- 분석목적: 해당 기업의 5년간의 임상시험 건수와 특허수, 해당 연도의 매출액 데이터를 사용하여 차년도 매출액의 10%이상 증가 여부 예측
- 분석 데이터 구조화 및 데이터 크기 확대:
 - ① 임상시험 및 특허 데이터 2012~2016년 (5년)
 - ② 임상시험 및 특허 데이터 2013~2017년 (5년)
 - ③ 임상시험 및 특허 데이터 2014~2018년 (5년)
 - ④ 매출 데이터 2016년, 2017년, 2018년
- 매출 데이터를 데이터 기본 단위로 하여, 각 제약회사마다 시구간을 이동하며 3개의 데이터를 만듦
- 전년도 매출액 대비 10% 이상 증가(고성장) 여부 라벨 부여 (1 또는 0)
- 두 가지 모형으로 분류하여 결과 예측
 - ① 특허 데이터만 사용한 예측 모델
 - ② 특허 + 임상시험 데이터를 함께 사용한 예측 모델

4. 실험결과

- 훈련데이터셋과 검증데이터셋 비율 : 7:3 비율
- 에폭 개수: 100~290까지 10개 단위로 순차적 증가하며 실험
 - ※ 에폭의 개수는 훈련데이터셋을 통한 알고리즘 수행 횟수 의미
- 분류 모델 성능 평가 지표
 - ① 정확도(Accuracy)
 - ※ 실제 1인 것을 1로, 실제 0인 것을 0으로 예측한 비율
 - ② F1-척도(F1-score)
 - ※ 재현율(Recall)과 정밀도(Precision)의 조화평균
 - ※ 재현율은 실제 1인 것 중 예측도 1로 한 비율
 - ※ 정밀도는 예측된 1중 실제 1인 것의 비율
- 최종 결과:
 - ① 모형 2(임상+특허) > 모형 1(특허만)
 - ② 모형 2 : 에폭수 280개, 정확도 0.847222, F1-척도 0.916031

5. 토의 및 결론

본 연구를 통해 임상시험 데이터가 제약회사의 매출 성장 예측에 중요한 역할을 한다는 점을 확인할 수 있었습니다. 또한 머신러닝 기법이 기존의 통계적 방법보다 더 우수한 성능을 발휘하기 위해서는 충분한 양의 고품질 데이터가 필수적이라는 사실도 알 수 있었습니다.

향후 연구에서는 본 모델의 성능을 더욱 개선하기 위해 다양한 머신러닝 알고리즘을 적용해볼 필요가 있습니다. 예를 들어, 서포트 벡터 머신(SVM)이나 신경망 등의 알고리즘을 활용하여 현재의 랜덤 포레스트 모델과 성능을 비교해보는 것이 유익할 것 같습니다. 이러한 후속 연구를 통해 제약산업의 성과를 더욱 정확하게 예측할 수 있는 모델을 개발할 수 있을 것으로 기대됩니다.