

제목: 기계학습의 의사결정나무를 이용한 개인정보 유출 탐지 모델

정보보안 박성철(202376629)

1. 제안모델: PC 보안솔루션 로그기록 및 인사 DB, 기존 적용되어 있는 보안정책을 바탕으로 위험도를 측정하여 개인정보 유출을 탐지 예측.

2. 기계학습 모델

■ 의사결정나무 알고리즘 진행순서

순서	설명	알고리즘
의사결정나무의 형성	분리기준과 정지 규칙을 지정	CART, C4.5, CHAID
가지치기	분류오류 큰 위험이 높거나 부적절한 추론규칙을 있는 가지를 제거	REP, PEP, CHAID
타당성 평가	의사결정나무를 평가한다.	10-겹 교차 타당성 평가
해석 및 예측	의사결정나무 해석하고 예측모형 설정	

■ 의사결정나무 분리기준

분리기준	알고리즘	주요 특징
지니지수	CART	후보 나무들을 여러 개 생성하고 그 중에서 최적의 나무를 찾아내는 방법
엔트로피	C4.5	정보를 최대한로 줄이는 방법으로 의사결정나무를 생성
통계적 유의성	CHAID	범주형 자료만 적용 가능, 수치형 속성은 범주형으로 변환 후 입력이 가능

■ 분리기준에 따른 가지치기 알고리즘

순서	설명
감소한 에러 가지치기(REP)	상향식 가지치기 방법으로 하위노드에서 상위노드로 올라가며 가지치기를 수행
비관적 에러 가지치기(PEP)	나무뿌리에서 시작, 각 노드를 평가 에러에 대한 상한을 이용하여 에러를 추정하며 가지치기
통계적 유의성 방법(CHAID)	CHAID 제곱과 검정(적합도, 동질성, 독립성)을 통해 가지치기를 수행

■ 데이터 분류 및 탐지 기준

구분	위험코드	데이터 분류 기준	위험지수
인사DB	A1	개인정보를 사용하는 주요부서 직원	5
	A2	임원	4
	A3	퇴직 예정자	3
	A4	협력업체 직원	2
	A5	일반직원	1
개인정보	B1	개인정보 보유	1

검색시스템 DB	B2	개인정보 미보유	0
	C1	안전하지 않은 폴더에 보관	1
	C2	안전한 폴더에 보관	0
DRM	D1	인쇄 가능	3
	D2	편집 가능	2
	D3	열람 가능	1
	D4	권한 없음	0
	E1	미 암호화	1
	E2	암호화	0
DLP	F1	외부저장매체 사용	1
	F2	외부저장매체 미사용	0
	G1	허용되지 않은 온라인 활성화	1
	G2	허용되지 않은 온라인 비활성화	0
관리정책	H1	내부 개인정보 파일에 접근 가능	1
	H2	외부 개인정보 파일에 접근 가능	0
DLP 정책	I1	개인정보 유출 방지 시스템 미설치	2
	I2	일부분의 개인정보 유출 방지 시스템 설치	1
	I3	개인정보 유출 방지 시스템 설치	0
단계별 위험지수		A+B+C+E+F+G+H+I	
위험도	11 이상		고위험
	5 이상 ~ 10 이하		중위험
	4이하		저위험

■ 위험도를 바탕으로 생성된 의사결정나무 예측정확도

	CART	CHAID	C4.5
고위험	52.8	-	69.8
	82.2	-	51.1
	-	-	60.2
중위험	61.2	-	51.8
	71.3	-	48.9
	59.1	-	-
저위험	80.3	-	76.4
	51.3	-	52.1

3. 결론

개인정보 유출의 기준인 위험군(고위험과 중위험) 고려하여 C4.5 알고리즘 적용이 적합.

※ 참고문헌

- 논문수집 출처(DBpia)
- 김동현. “기계학습의 의사결정나무를 이용한 개인정보 유출 탐지 모델”. 광주(전남대학교) 석사학위 논문, 2018.