



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

이화여자대학교 대학원
2018학년도
석사학위 청구논문

콘텐츠 기반 변수 추출 방법에 의거한 가짜 뉴스 분류

빅 데이터 분석 학 협 동 과 정
정 호 선
2019

콘텐츠 기반 변수 추출 방법에 의거한 가짜 뉴스 분류

이 논문을 석사학위 논문으로 제출함

2018 년 12 월

이화여자대학교 대학원

빅 데이터 분석 학 협 동 과 정 정 호 선

정호선의 석사학위 논문을 인준함

지도교수 신 경 식 —

심사위원 김 은 갑 —

민 대 기 —

신 경 식 —

이화여자대학교 대학원

목 차

I. 서론	1
A. 연구 배경	1
B. 연구 목적	4
II. 선행연구	5
A. 콘텐츠 기반 가짜 뉴스 탐지 연구	5
B. 국내 가짜 뉴스 연구	10
III. 연구기법	13
A. 텍스트 분류	13
IV. 제안 모형 및 실험 설계	17
A. 제안 모형	17
B. 실험 설계	20
V. 실험 결과 및 분석	33
VI. 결론	38
참고문헌	40
ABSTRACT	44

표 목 차

표2-1. 콘텐츠 기반 가짜 뉴스 탐지 연구	9
표2-2. 국내 가짜 뉴스 분류 연구.....	12
표4-1. 텍스트 전처리 예시.....	22
표4-2. 변수 추출(Feature Extraction)	23
표4-3. 감성사전 예	26
표4-4. 최종 독립변수.....	27
표4-5. 혼동 행렬(Confusion Matrix)	30
표5-1. 10-fold Cross Validation 수행 결과	34
표5-2. 변수 추출 방법 별 성과 비교	35

그림 목 차

그림3-1. 텍스트 분류 과정	16
그림4-1. 제안 모형 과정	19
그림4-2. 간단한 서포트 벡터 머신(SVM)	28
그림4-3. 10겹 교차검증(10-fold Cross Validation)	29
그림5-1. 제안 모형의 정확도, 재현율, 정밀도, F값	41
그림5-2. 변수 추출 방법 별 성과 비교 그래프	43

논 문 개 요

최근 TV나 신문과 같은 전통적인 매체보다 페이스북, 트위터 등의 소셜 네트워크 서비스(Social Network Service, SNS)를 통해 뉴스를 소비하는 인구가 증가하고 있다. SNS를 이용하면 언제 어디서나 편리하게 뉴스에 접근할 수 있으며, 비용을 절감할 수 있기 때문이다. 하지만 SNS에는 가짜 뉴스가 쉽게 생성될 수 있으며, 한번 생성된 가짜 뉴스는 빠르게 확산되어 SNS 이용자들에게 노출되는 문제를 야기할 수 있다. 이와 같은 가짜 뉴스의 확산은 뉴스 소비자 개인과 전체 사회에 정치적, 경제적으로 악영향을 끼칠 수 있기 때문에 ‘SNS 상의 가짜 뉴스’는 최근 심각한 문제로 평가되고 있다. 구체적으로, 정치적 목적으로 SNS에 유포된 가짜 뉴스는 잘못된 여론 형성을 유발하여 SNS를 사용하는 수 많은 유권자들의 의사를 왜곡하는 문제가 발생할 수 있다. 또한, 개인이나 기업에 대한 가짜뉴스가 확산될 경우 브랜드의 가치가 하락하여 막대한 경제적 손실이 발생할 위험이 있다.

한편, 가짜 뉴스는 전세계적인 차원의 문제로 인지되고 있다. 2016년 45대 미국 대통령 선거에서 소셜 미디어를 통해 유출된 가짜 뉴스가 트럼프의 승리에 영향을 주었다는 연구 결과가 발표되었고, 이를 계기로 국외에서는 가짜 뉴스를 탐지하는 연구의 중요성이 대두되었다. 그 결과, 페이스북과 구글이 ‘가짜 뉴스’와의 전쟁을 선포하는 등 가짜 뉴스 문제를 해결하기 위한 연구들이 국외에서 다각도로 활발히 진행되고 있다. 국내에서도 가짜 뉴스 문제가 심각한 사회적 이슈로 자리잡고 있다. 하지만, 국외에 비해 가짜 뉴스 탐지에 대한 연구가 미흡한 실정이

다. 따라서, 본 연구에서는 SNS 상의 국내 가짜 뉴스를 대상으로 가짜 뉴스 탐지 연구를 진행하여 국내 가짜 뉴스 문제 해결에 기여해보고자 한다.

구체적으로, 본 연구는 한국어 트위터의 진위 여부를 파악해주는 분류 모형을 구축하는 것을 목표로 한다. 이를 위해, 텍스트의 문체적 특징을 대변해 줄 수 있는 언어학적 변수들을 추출하는 ‘콘텐츠 기반 변수 추출 방법(Content-based Feature Extraction Method)’에 의거하여 분류 모형을 구축하고자 한다. 텍스트 분류 연구에서는 비정형 텍스트로부터 정형화된 자질 벡터를 추출하기 위해 주로 단어 빈도(Term Frequency, TF) 혹은 단어 빈도-역문서 빈도(Term Frequency-Inverse Document Frequency, TF-IDF) 기법을 사용하는데, 이들은 텍스트의 어휘 특성만을 기반으로 하여 입력 값을 산출한다는 한계점을 지니고 있다. 따라서, 본 연구에서는 콘텐츠 기반 변수 추출 방법을 통해 어휘, 문장 구조, 문법 등 보다 다양한 범주의 언어학적 특징들에 주목하여 텍스트의 진위 여부를 파악해주는 우수한 성능의 분류기를 구축하는 것을 목표로 하였다.

연구 결과, 제안 모형은 정확도 70.53%, 재현율 85.76%, 정밀도 71.18%, F값 77.24%의 성능을 보여 전통적인 텍스트 자질 추출 방법인 TF나 TF-IDF를 적용한 모형보다 전반적으로 우수한 성과를 도출하였다. 이를 통해, 자연어처리 기반의 가짜 뉴스 분류 문제에서는 다양한 범주의 언어학적 변수들을 사용하는 것이 효과적임을 확인할 수 있다.

본 연구는 텍스트의 언어학적 특징에 주목하는 ‘콘텐츠 기반 변수 추출 방법’을 사용하여 우수한 성능의 가짜 뉴스 탐지 모형을 구축하였다. 가짜 뉴스가 사회적

으로 심각한 문제로 자리잡고 있는 현 시점에서, 본 연구는 SNS 상의 가짜 뉴스의 문체 특징을 분석하여 이를 기반으로 가짜 뉴스 여부를 알 수 있는 우수한 성능의 분류 모형을 구축하였다는 점에서 의미가 있다. 또한, 국내 가짜 뉴스 연구가 거의 전무한 상황에서 한국어 대상의 가짜 뉴스 분류 모형을 구축하였기에 학술적으로 의미가 있다고 사료된다. 나아가, 영어 대상의 가짜 뉴스 뿐만 아니라 한국어 대상의 가짜 뉴스에서도 ‘콘텐츠 기반의 변수 추출 방법’을 적용한 모형이 우수한 분류 성과를 보였으므로, 가짜 뉴스 도메인에서 다양한 범주의 언어학적 특징들을 변수로 추출하는 것이 중요함을 확인할 수 있다.

한편, 본 연구의 한계점은 다음과 같다. 우선, 데이터 확보의 어려움으로 인해 데이터의 양이 크지 않았다는 아쉬움이 따른다. 따라서 향후 연구에서는 데이터를 추가적으로 수집하여 연구의 타당성을 보다 높일 수 있는 방안을 모색할 필요가 있다. 나아가 레이블링된 데이터가 부족한 상황에서도 우수한 성능의 자동화된 분류기를 구축할 수 있는 준지도학습(Semi-supervised Learning) 기반의 연구를 진행하여 가짜 뉴스 도메인에서 발생할 수 있는 Cold-start 문제를 해결하는 것이 의미 있는 후속 연구가 될 것으로 예상된다. 또한, 콘텐츠 기반의 언어학적 변수들을 세분화하여 더욱 다양한 범주의 변수들을 고려한다면 더욱 우수한 성능의 분류 모형을 구축할 수 있을 것으로 보인다.

I. 서론

A. 연구 배경

현대 사회에서는 소셜 미디어의 영향력 증대로 인해 TV나 신문 등의 전통적인 뉴스 매체가 아닌 소셜 미디어 플랫폼을 통해 뉴스를 소비하는 인구가 증가하고 있다(Newman & Levy, 2016). Pew Research Center는 2016년 1월부터 2월까지 실시한 설문조사를 통해 미국 성인 인구의 62%가 소셜미디어를 통해 뉴스를 접하며, 페이스북 사용자의 66%, 트위터 사용자의 59%가 해당 소셜미디어 사이트를 통해 뉴스를 접한다는 연구 결과를 발표했다(Gottfried & Shearer, 2016). 이처럼 현대 사회에서는 많은 사람들이 소셜 미디어를 통해 뉴스를 소비하고 있는데, 이는 소셜 미디어의 두 가지 특징에 기인한다고 추측할 수 있다(Shu et al., 2017). 우선, 소셜 미디어는 전통적인 매체 보다 접근하기 쉬우며 뉴스 소비를 위한 비용을 요구하지 않는다. 또한, ‘공유’와 ‘댓글’ 기능을 통해 타인과 뉴스에 대해 소통할 수 있다는 장점을 가지고 있다. 하지만 소셜 미디어를 통한 뉴스 소비 행위는 가짜 뉴스와 관련된 심각한 문제를 야기하기 때문에 부정적으로 인식되기도 한다. 소셜 미디어에는 누구나 뉴스를 생성할 수 있으며, 한번 생성된 뉴스는 검증 없이 빠른 속도로 확산 수 있기 때문에 허위 정보가 유포될 수 있는 문제를 야기할 수 있기 때문이다. 즉, 소셜 미디어에 대한 뉴스 소비 의존성이 심화될수록 사용자들이 거짓 정보를 포함하는 가짜 뉴스에 노출될 수 있는 가능성이 증가하여 사회적으로 심각한 문제가 발생하고 있다. 실제로, 2016년도 제 45대 미국 대통령 선거

에서 소셜 미디어를 통해 유통된 가짜 뉴스가 트럼프의 승리에 영향을 주었다는 연구결과가 발표되면서, 가짜 뉴스 문제에 대한 관심이 전세계적으로 증가하고 있다(Allcott & Gentzkow, 2017). 국내에서도 2017년 5월에 9일에 치뤄진 19대 대선을 앞두고 가짜 뉴스가 선거의 공정성을 해치는 주요한 사회적 이슈로 떠오르기 시작했다(한상기, 2017; 김대근 외., 2017).

구체적으로, 가짜 뉴스는 개인과 사회에 심각한 정치적, 경제적 피해를 야기할 수 있다. 우선, 특정 정치인과 정치단체가 정치 선전을 목적으로 유포하는 가짜 뉴스는 잘못된 여론을 형성하고 유권자의 판단에 혼동을 유발할 수 있다. 2017년 19대 대통령 선거를 앞두고 가짜 뉴스 유포가 기승을 부려 국내에서도 가짜 뉴스 문제를 우려하는 목소리가 증가하고 있다. 실제로, 중앙선거관리위원회는 19대 대선을 앞두고 허위사실공표, 후보자 비방, 지역 및 성별/모욕을 포함하는 등의 선거법 위반 행위를 26,448건 적발하였는데, 이는 4,043건 발생했던 18대 대선 대비 6.5배 가량 증가한 수치였다(김대근 외., 2017). 이로 인해, 국내에서도 정치적 목적을 가진 가짜 뉴스가 확산되고 있고, 이로 인해 유권자의 의사 결정에 혼동을 가져다 줄 수 있는 상황이 발생하고 있음을 확인할 수 있다.

가짜 뉴스는 유권자 의사를 왜곡하는 정치적 문제를 야기할 뿐만 아니라 심각한 경제적 손실을 발생시키기도 한다. 정민 & 백다미(2017)의 연구에서는 실제 기사 건수의 1% 수준의 가짜 뉴스가 유포되었을 때의 경제적 손실 비용 규모는 연간 약 30조 900억원에 이를 것으로 추정된다는 연구 결과를 발표했다. 한편, 2013년 4월 23에는 시리아 전자부대(SEA)가 The Associated Press라는 트위터 계정을 해킹하여 ‘백악관의 폭발 사건으로 버락 오바마 대통령이 부상을 당했다’는 내용

이 담긴 거짓 트윗을 게시하는 사건이 발생했다. 이로 인해 뉴욕증권거래소의 투자자들은 2분 만에 Standard & Poors Index 기준 약 1,360억원을 잃으며 막대한 피해를 입었다(Keller, 2013). 즉, 가짜 뉴스는 경제적, 정치적 이익을 목적으로 누군가가 허위 정보를 의도적으로 포함시킨 것이기에 개인과 사회에 막대한 악영향을 끼칠 수 있다.

따라서 가짜 뉴스를 근절하기 위해 전세계적으로 다양한 연구들이 진행되고 있다. 전통적인 해결책은 언론 전문가에게 뉴스의 사실 여부를 검증 받는 것이지만 이는 시간과 비용 문제를 야기한다(Oshikawa, 2018). 따라서 국외에서는 자동화된 가짜 뉴스 탐지 연구가 다각도로 진행되고 있는 실정이다. 특히 소셜 미디어의 영향력의 증대와 함께 가짜 뉴스 문제가 가속화되고 있어 소셜 미디어 상에 생성된 뉴스의 진위 여부를 자동으로 분류해주는 알고리즘을 개발하기 위한 연구가 이뤄지고 있다. 일례로, 페이스북은 독일에서 치뤄질 선거에 대비하여 외부검증기관으로부터 진위 여부를 판독 받아 논란의 여지가 있는 단어가 사용된 뉴스들은 페이스북에 업로드 되지 않는 방식의 가짜 뉴스 판별 시스템을 도입하였다. 또한, 프랑스는 구글이 주도하는 ‘크로스체크(crosscheck)’ 프로젝트를 통해 프랑스 현지 언론사들과 협력하여 허위 정보를 사전에 차단하는 알고리즘을 구현하였다(최홍규, 2017).

한편, 국내에서는 가짜 뉴스가 심각한 문제로 여겨지고 있지만, 이를 해결하기 위한 자동화된 가짜 뉴스 탐지 관련 연구가 부족한 실정이다. 따라서, 본 연구에서는 텍스트 분석과 기계 학습을 활용하여 국내 가짜 뉴스의 진위 여부를 자동으로 분류해주는 모형을 구축하고자 한다.

B. 연구 목적

본 연구의 목적은 가짜 뉴스의 진위 여부를 파악해주는 분류기를 구축하는 것이다. 그 중에서도 가짜 뉴스 문제가 소셜 네트워킹 서비스(SNS)를 통해 가속화되고 있는 점에 주목하여 특정 이슈에 대한 트위터 포스트의 진위 여부를 파악해주는 분류기를 구축하고자 한다. 한편, 한국어를 대상으로 한 가짜 뉴스 분류 연구가 전무하다는 점에 주목하여, 한국어 트위터 텍스트를 대상으로 연구를 진행하고자 한다. 이때, 가짜 뉴스와 진짜 뉴스의 텍스트가 다른 언어학적 특성을 가지고 있다는 가정 하에, 자연어처리 관점의 뉴스 콘텐츠 기반 가짜 뉴스 분류기를 구축하고자 한다. 이를 위해, 전통적인 텍스트 특징 추출 방법인 TF나 TF-IDF에서 나아가 텍스트의 문체적 특징에 주목한 ‘콘텐츠 기반 변수 추출 방법’을 사용하여 보다 다양한 범주의 언어학적 특징을 담은 변수들을 추출해보고자 한다.

II. 선행연구

A. 콘텐츠 기반 가짜 뉴스 탐지 연구

가짜 뉴스 탐지 연구는 ‘뉴스 콘텐츠 중심의 접근법’과 ‘사회적인 문맥 중심의 접근법’ 2가지로 구분된다(Shu et al., 2017; 한상기, 2018). 첫 번째 방법은 뉴스의 제목, 본문 등의 텍스트의 특징에 주목하여 가짜와 진짜를 구분하려는 자연어처리 관점의 연구이고, 두 번째 방법은 소셜 네트워크 서비스 사용자들의 행위에 주목하여 특정 뉴스에 달린 페이스북의 ‘좋아요’ 수와 트위터의 ‘리트윗’ 수와 같은 외부 변수들을 통해 뉴스의 진위여부를 파악하려는 연구이다(Della Vedova et al., 2018). 본 연구에서는 첫 번째 방법인 자연어처리관점의 뉴스 콘텐츠 중심의 접근법을 사용할 것이므로 이에 해당되는 선행연구를 집중적으로 살펴보고자 한다.

콘텐츠 기반의 접근법은 가짜와 진짜 뉴스의 텍스트는 언어학적으로 구별되는 다른 특징을 가지고 있음을 전제로 한다. <표2-1>을 통해 알 수 있듯이, 국외에서는 신문 기사 형식의 텍스트와 소셜 미디어 포스팅 형태의 텍스트를 대상으로 콘텐츠 기반의 특징들을 추출하고 이를 토대로 분류 모델을 만드는 연구들이 활발히 진행되었다.

Conroy et al. (2015)은 언어학적 접근법과 네트워크 분석을 결합한 하이브리드 형태의 가짜 뉴스 탐지 방법론을 제안하였다. 해당 연구는 언어학적 특징을 4가지로 범주화 하였다. 우선, 텍스트를 n-grams 형태의 단어 주머니(Bag of Words)로 변환하여 단어 빈도수 기반의 특징을 변수로 삼았다. 이외에도, Probability

Context Free Grammars(PCFG) 기반 구문 파싱을 통한 문법적 특징, 가짜와 진짜 텍스트에 사용된 핵심 단어의 차이를 기반으로 한 의미론적 특징, 수사적 구조와 담화 분석에 기반한 특징을 변수로 선정하였다. 사기성 메시지 내용의 패턴을 추출하기 위해 다양한 언어학적 자질들을 범주화 했다는 점에서 의미가 있지만 실험 결과에 대한 서술 없이 방법론만을 제안하였다는 점에서 한계점이 존재한다.

다음으로, Zubiaga (2016)은 소셜 미디어 중 트위터 게시글의 루머 여부를 파악하기 위해 뉴스 본문 중심의 특징들과 사회적인 특징들을 결합한 하이브리드 형태의 가짜 뉴스 분류 모형을 고안하였다. 연구에서는 단어의 유사도를 계산하는 대표적인 워드 임베딩 방법인 Word2Vec을 사용하여 어휘 특징을 추출하였다. 또한 형태소 분석을 통해 품사를 부착하여 각 품사별 빈도수를 변수로 선정하였다. 이외에도, 문서 별로 띄어쓰기로 구분되는 단어의 빈도를 계산하여 변수로 선정했다. 마지막으로 여러가지 문장 부호의 사용 여부를 변수로 선정하였는데, 이는 불확실성을 나타내는 물음표, 강조나 놀라움을 나타내는 느낌표, 정확한 서술을 뜻하는 마침표를 포함한다.

Potthast et al. (2017)은 정치적 당파성이 존재하는 신문 기사들의 문체를 파악할 수 있는 자질들을 추출하고 이를 통해 기사의 진위 여부를 분류하는 모형을 구축하는 연구를 하였다. 연구에서는 문체 분석에서 흔히 사용되는 글자 단위의 n-grams, 불용어, 품사 태깅의 자질을 사용하였다. 이에 더해, 10가지 지수를 사용하여 readability 점수를 계산한 값과 특정 사전에 포함된 단어의 빈도와 같은 사전 기반 변수를 사용하였다. 또한, 인용된 단어와 외부 링크의 비율, 문단 내 평균 단어 수와 문서 별 평균 길이도 독립변수로 사용하였다.

Perez-Rosas et al. (2017)은 온라인 신문 기사 텍스트로부터 언어학적 자질들을 추출하여 자동화된 가짜뉴스 탐지모델을 구현하였다. 해당 연구는, 우선 텍스트로부터 unigrams와 bigrams 형태의 자질을 추출하고, 이를 바탕으로 단어 빈도-역문서 빈도(TF-IDF)를 산출하여 변수로 사용하였다. 나아가, LIWC(Linguistic Inquiry Word Count) 프로그램을 이용하여 문서 별로 마침표, 쉼표, 줄표, 물음표, 느낌표 등 11개의 문장 부호를 사용한 비율을 산출하였다. 이외에도, LIWC에서 만든 언어심리학적 단어 사전을 바탕으로 긍정 어휘, 부정 어휘, 지각과 관련된 어휘 등이 문서 별로 얼마나 사용되었는지 계산하여 변수로 이용하였다. 또한, 음절 수와 긴 단어의 수, 문단의 수 등을 계산하고 이를 readability metrics를 기반으로 산출한 readability 정도를 변수로 사용하였다. 마지막으로, Stanford Parser를 사용하여 Context Free Grammar(CFG) 기반의 구문 파싱을 실시하였고, 이를 기반으로 구문론과 관련된 변수를 선정하였다.

Rashkin et al. (2017)은 언어학적 변수들을 사용하여 정치 분야의 뉴스들을 대상으로 자동화된 가짜 뉴스 분류기를 구축하였다. 뉴스 콘텐츠의 언어학적 특성으로는 우선, LIWC 사전에 기반한 단어들의 사용 비율을 사용하였다. 또한, 주관적인 언어의 사용을 변수로 사용하였는데, 주관적인 단어들은 뉴스 내용을 새롭게 각색할 시에 사용될 수 있다는 점을 전제로 하였다. 다음으로는, 모호함을 뜻하는 회피형(hedging)의 단어들의 사용 정도를 변수로 선정하였다. 마지막으로, Wiktionary에 기반한 5가지 척도의 단어들을 변수로 사용하였다. 이들은 각색(dramatization)의 정도를 나타내는 지표로 비교급, 최상급, 행위 부사, 양태 부사, 법 부사가 포함된다.

Della Vedova et al. (2018)은 페이스북 포스트와 이와 관련된 기사를 대상으로 가짜뉴스 탐지 연구를 진행하였다. 이 때, 텍스트 분석에서 텍스트의 특징을 대변하는 자질로 자주 사용되는 TF-IDF 벡터를 변수로 사용하였다. 해당 연구는 텍스트를 추출하는 자질 선정보다는 우수한 성능을 도출할 수 있는 분류기를 선정하는 과정에 초점을 맞추어서 연구를 진행하였다.

이와 같은 기존의 연구들을 통해 가짜 뉴스 분류 모형을 구축할 시에 다양한 언어학적 변수들을 사용하는 것이 효과적인 방법임을 확인할 수 있다. 본 연구에서는 트위터라는 소셜 미디어 데이터를 대상으로 자연어처리 관점에서 텍스트의 특징에 주목하여 콘텐츠 기반의 변수들을 추출하여 분류 모델을 만들고자 한다. 기존의 자연어처리 관점의 연구들은 영어 데이터를 대상으로 한 반면, 본 연구는 한국어 대상의 텍스트를 대상으로 가짜 뉴스 분류 연구를 진행해본다는 점에서 차이점이 존재한다.

표 2-1. 콘텐츠 기반 가짜 뉴스 탐지 연구

Author(s)	Approach	Content-based Features	Data	Classifier
Conroy et al. (2015)	Hybrid (Linguistic Ques + Network Analysis Approaches)	1. Bag of Words 2. Parsing Tree 3. Semantic Analysis 4. Rhetorical Structure & Discourse Analysis	Deceptive Messages	Support Vector Machine, Naïve Bayes classifier
Zubiaga (2016)	Hybrid (Content-based Features + Social Features)	1. Word Vectors(Word2Vec) 2. Part-of-Speech Tags 3. Capital Ratio 4. Word Count 5. Use of Question Mark 6. Use of Exclamation Mark 7. Use of Period	Posts on Social Media (Twitter)	Conditional Random Fields, Maximum Entropy classifier, Enquiry-based approach, Naïve Bayes classifier, Support Vector Machine, Random Forests
Potthast et al. (2017)	Writing Style Features	1. N-grams of Character 2. Stop Words 3. 10 Readability Indices 4. Ratios of Quoted Words 5. External Links 6. Average Number of Words Per Paragraph 7. Average Length in a Document	Articles	Naïve Bayes Classifier
Perez-Rosas et al. (2017)	Linguistic Features	1. Bag of N-grams 2. Punctuation 3. Psycholinguistic Features (LIWC) 4. Readability 5. Syntax	Articles	Support Vector Machine
Rashikin et al. (2017)	Linguistic Features	1. Linguistic Inquiry and Word Count(LIWC) 2. Use of Subjective Words 3. Use of Hedging Words 4. Use of Five Lists from Wiktionary	Articles	Long Short Term Memory, Maximum Entropy classifier, Naïve Bayes classifier
Della Vedova et al. (2018)	Hybrid (Content Analysis + Social Context)	1. Vector of TF-IDF Frequencies	Posts on Social Media (Facebook) and Linked Articles	Logistic Regression, Content-based, Harmonic Boolean Label Crowdsourcing

B. 국내 가짜 뉴스 분류 연구

텍스트 마이닝과 기계 학습을 이용한 가짜뉴스 탐지 연구들이 해외에서는 활발하게 진행되고 있는 반면, 국내에서는 그에 비해 아직은 연구가 미흡한 실정이다. 국내 가짜뉴스 연구의 동향은 다음의 <표2-2>와 같다.

우선, Park & Kim(2017)은 페이스북에서 공유되는 정치 관련 뉴스를 대상으로 사용자가 웹페이지의 URL을 입력하면 해당 기사가 가짜 뉴스일 확률을 도출하고, 관련 키워드를 포함하는 실제 뉴스들을 제공해주는 시스템을 제안하였다. 해당 연구는 서포트 벡터 머신(SVM)을 활용하여 분류 모델을 만들었으며, TF-IDF 기법을 기반으로 키워드를 추출하였다. 해당 연구는 가짜 뉴스 분류 모형을 구축하는 것에서 나아가 모형을 사람들이 실제로 활용할 수 있는 시스템을 마련하는 것에 보다 초점을 맞춘 연구이다.

윤태욱 & 안현철 (2018)은 서울대학교 팩트체크 사이트로부터 짧은 문장으로 이루어진 200개의 데이터를 수집하여 텍스트 마이닝과 기계학습 기반의 가짜 뉴스 예측 모형을 구축하는 연구를 진행하였다. 해당 연구에서는, 텍스트를 TF-IDF에 기반한 문서-토픽 가중치들로 변환한 정량화된 특징값을 변수로 사용하였다. 이를 기반으로 다중판별분석(Multiple Discriminant Analysis, MDA), 사례기반추론(Case Based Reasoning, CBR), 인공신경망(Artificial Neural Network, ANN), 서포트 벡터 머신(Support Vector Machine, SVM)을 활용하여 분류 예측 모델을 구축하고 분류 기법들 간의 성과를 검증하였다.

이동호 외. (2018)은 가짜 신문기사는 제목과 본문이 다른 내용을 담고 있거나

뉴스 본문 중 맥락에 관계 없는 내용을 담고 있다는 특징에 주목하여 CNN 딥러닝 기반의 가짜뉴스 탐지 모델을 구축하였다. 이 때, 한글은 영어에 비해 형태소 중의성으로 인해 의미 분석이 어렵다는 점에 주목하여 음절 단위로 학습하는 단어 임베딩 모델인 'Fasttext'를 기반으로 한 가중치를 입력 변수로 사용하였다.

기존의 국내 연구들은 텍스트의 특징을 정량화된 특징 값으로 변환하기 위한 방법으로 TF-IDF 혹은 워드 임베딩을 사용하였다. 이는 단어 기반의 특징만을 변수로 사용한 것으로, 가짜와 진짜 텍스트가 어휘 이외의 다양한 언어학적 차이를 가진다는 점을 고려하지 못했다는 한계를 지닌다. 따라서, 본 연구에서는 한국어 기반의 가짜 뉴스와 진짜 뉴스 텍스트의 문체적 특징을 대변할 수 있는 변수들을 다각도로 추출하고, 이를 기반으로 자연어처리 관점에서 가짜뉴스 탐지 모델을 구현해보고자 한다.

표 2-2. 국내 가짜 뉴스 분류 연구

Author(s)	Research Approach	Feature(s)	Classifier
Park & Kim (2017)	페이스북에서 공유되는 신문기사가 가짜일 확률도출하고, 관련 키워드를 포함하는 실제 뉴스를 제공하는 시스템 구축	단어 빈도-역문서 빈도 (TF-IDF)	서포트 벡터 머신
윤태욱 & 안현철 (2018)	텍스트 마이닝과 기계학습 기반의 가짜 뉴스 예측 모형 구축	단어 빈도-역문서 빈도 (TF-IDF) 기반 문서-토픽 가중치	다중판별분석, 사례기반추론, 인공신경망, 서포트 벡터 머신
이동호 외. (2018)	1)신문기사의 제목과 본문이 다른 내용을 담고 있는 경우, 2)뉴스 본문 중 맥락에 관계 없는 내용을 가지는 경우를 판별하여 가짜뉴스를 탐지하는 모델 구축	워드 임베딩 (FastText)	합성곱 신경망

Ⅲ. 연구 방법론

A. 텍스트 분류

텍스트 분류(Text Classification)는 문서 본문의 특징을 기반으로 문서를 정해진 범주로 분류하는 모형을 구축하는 기법이다. 텍스트 분류는 카테고리 별 뉴스 분류, 카테고리 별 영화 장르 분류, 스팸 이메일 분류에서부터 최근에는 가짜뉴스 분류에 이르기까지 다양한 분야에서 사용되고 있다(Wang et al., 2014). 텍스트 분류를 수행하는 전반적인 과정은 <그림3-1>과 같다.

한편, 비정형 구조를 가진 텍스트를 입력 값으로 하는 텍스트 분류 모형을 구축할 시에서는 텍스트를 고정된 길이의 자질 벡터로 바꿔서 수치화하는 ‘텍스트 표현’(Text Representation) 작업이 매우 중요하다. 기계 학습은 고정된 길이의 정형화된 데이터만을 입력 값으로 사용할 수 있기 때문이다. ‘텍스트 표현’의 대표적인 방법으로는 단어 주머니(Bag-of-Words) 모델이 있다(Le & Mikolov, 2014). 단어 주머니 모델은 문서 내의 단어들의 순서는 고려하지 않은 채, 단어들의 출현 빈도에만 집중하여 텍스트 데이터를 수치로 표현하는 방법이다. 구체적으로, 전체 텍스트를 단어 기준으로 토큰화(Tokenization)하여 단어 행렬을 산출하고, 각 단어마다 고유한 인덱스(index)를 부여한다(Sriram, 2010). 이 후, 문서 별로 해당 단어가 몇 번 등장하였는지 계산하여 최종적으로 정형화된 자질 벡터를 생성한다.

대표적으로 사용되는 또 다른 ‘텍스트 표현’ 방법은 단어 빈도-역문서 빈도 (Term Frequency-Inverse Document Frequency, TF-IDF)이다. 이는, 단어의 빈도와 역문서 빈도를 곱한 값으로, 단어의 중요 정도에 따라 가중치를 부여해주는 방법이다. 단어 빈도(TF)는 특정한 단어가 특정 문서 내에서 얼마나 자주 등장하는지를 나타내는 값으로, 단어 빈도가 클수록 개별 문서에서 중요한 키워드라고 할 수 있다. 문서 빈도(DF)는 특정 단어가 등장한 문서의 수를 나타내는 값으로 특정 단어가 얼마나 자주 전체 문서에 등장했는지 알려준다. 하지만, 특정 단어가 여러 문서에서 빈번하게 출현한다는 것은 흔하게 사용되는 단어이므로 중요도가 떨어진다는 것을 의미하기도 한다. 역문서 빈도(IDF)는 문서 빈도의 반비례 값에 해당한다. TF-IDF는 TF와 IDF를 곱한 값으로, 여러 문서 집합에서 특정 단어가 얼마나 중요한가를 판단하는 값이다. 즉, 모든 문서에서 자주 등장하는 단어는 중요도가 낮다는 것을 전제로 하며, 특정 문서에서만 자주 등장하는 단어의 중요도가 높다고 판단한다. TF-IDF 값이 낮으면 중요도가 낮은 것이며, TF-IDF 값이 크면 중요도가 높은 단어라고 할 수 있다. TF-IDF(w_{ij})를 구하는 산술식은 다음과 같다.

$$w_{ij} = tf_{ij} \times \log\left(\frac{N}{df_i}\right)$$

특정 문서 j 내의 특정 단어 i 에 대하여,
 tf_{ij} = 문서 j 내 단어 i 의 빈도
 df_i = i 가 출현한 문서의 빈도
 N = 전체 문서 수

비정형 텍스트를 정형화된 자질 벡터로 변환한 후에는 분류의 과정을 거친다. 분류를 수행하는데 사용되는 대표적인 기계학습 방법으로는 서포트 벡터 머신(Support Vector Machine, SVM), 나이브 베이즈(Naive Bayes, NB), 의사결정나무(Decision Tree, DT), 인공신경망(Artificial Neural Network, ANN) 등이 있다. 그 중에서도 SVM은 텍스트 분류 문제에서 우수한 성능을 보여주는 것으로 알려져 있다(Joachims, 1998).

한편, 지도 학습 기반의 텍스트 분류는 이미 레이블링이 완료된 학습용 데이터를 기반으로 분류 모형을 구축하고, 이를 통해 시험용 데이터의 레이블을 예측하여 성과를 검증하는 방식으로 진행된다. 이 때, 학습용 데이터와 시험용 데이터의 크기를 지정하는 것은 매우 중요하다. 학습용 데이터의 크기가 작다면 분류 모형이 충분한 학습을 할 수 없으며, 반대로 시험용 데이터에 비해 학습용 데이터의 크기가 지나치게 크면, 학습용 데이터에만 최적화된 모형을 구축하여 ‘과적합(Overfitting)’의 문제를 야기할 수 있다.

모델 학습을 통해 분류 모형을 구축한 후에는 시험용 데이터에 적용하여 예측 결과를 도출하고, 이를 바탕으로 모델의 성능을 검증한다. 지도학습 기반의 텍스트 분류 모형의 성능을 평가하는 대표적인 척도는 혼동행렬 기반의 정확도, 재현율, 정밀도, F-값 등이 있다.




그림 3-1. 텍스트 분류 과정

IV. 제안 모형 및 실험 설계

A. 제안 모형

본 연구의 제안 모형은 다음의 <그림4-1>과 같다. 우선, 데이터 수집을 위해 팩트체크 사이트에서 진위 여부가 확정된 이슈들을 모으고, 해당 이슈들의 키워드를 기반으로 한국어 트위터 가짜뉴스 데이터셋을 수집하였다. 이후에는, 분석에 앞서 텍스트를 정제하는 전처리 단계를 거치는데, 이는 단어 기준의 토큰화(Tokenization), 불필요한 문장 부호, 이모티콘, URL 주소 및 불용어 제거(Stopwords Removal), 동일한 어간을 가지고 있는 단어를 하나의 단어로 처리하는 작업인 어간 처리(Stemming) 등을 포함한다.

텍스트를 전처리한 후에는 독립 변수로 사용될 자질을 추출하는 작업을 수행하였다. 본 연구에서는 가짜와 진짜 뉴스의 언어학적 특징에 주목한 ‘콘텐츠 기반의 변수 추출 방법’을 사용하였다. 구체적으로 어휘 변수, 구문론 변수, 심리언어학 변수 3가지로 범주화하고, 이를 기준으로 총 9개의 콘텐츠 기반 변수들을 추출하였다. 한편, 본 연구에서는 추출한 9개의 변수를 모두 입력 변수로 사용하는 것이 아니라 보다 통계적으로 유의미한 변수 집단을 선정하기 위해 변수 선정 단계를 거쳤다. 이를 위해, 전진 선택법과 후진 제거법을 번갈아 가며 진행하는 단계적 회귀분석(Stepwise Regression)을 실시하였다. 결과적으로 AIC 값이 최소가 되는 변수 집단이 산출되었는데, 최종적으로는 6개의 변수가 선정되었다.

다음으로는 텍스트 분류에 있어서 좋은 성능을 보이는 것으로 알려진 서포트

벡터 머신 기법을 활용하여 분류 작업을 수행하였다. 이 때, 모형의 통계적 신뢰성을 높이기 위해 k-fold 교차검증을 실시하였고, k번의 분류 작업 결과 나온 k개의 모형에 대한 값의 평균을 구하여 성과를 평가하였다. 성과 측정의 척도로는 혼동 행렬 기반의 정확도, 재현율, 정밀도, F값을 사용하였다. 본 연구는 전통적인 자질 추출 방법인 단어 빈도(TF)와 단어 빈도-역문서 빈도(TF-IDF)를 적용한 모형을 베이스라인으로 설정하여 보다 다양한 언어학적 변수들을 기반으로 하는 제안 모형의 성능과 비교하고자 한다. 제안 모형의 진행 과정과 관련된 구체적인 설명은 다음의 ‘실험 설계’에서 서술하고자 한다.




그림 4-1. 제안모형 과정

B. 실험 설계

단계1: 데이터 수집

본 연구에서는 서울대학교 팩트체크 사이트에서 진위여부가 판정된 이슈들을 기반으로 200여개의 한국어 트위터 가짜 뉴스 데이터를 수집하였다. 서울대학교 팩트체크는 22개의 언론사와 대학들이 협업하여 공적으로 논쟁이 되었던 이슈들의 진위 여부를 검증하여 국민들에게 알려주는 사이트로, 서울대학교 언론정보연구소에서 비정치적, 비영리적으로 운영하는 정보서비스이다(윤태욱 & 안현철, 2018). 해당 사이트는 정치, 경제, 국제, 사회, IT/과학과 관련하여 사실 여부가 논란이 되었던 이슈들에 대해 언론사들이 검증한 결과를 보여주는데, 판정 결과는 ‘전혀 사실 아님’, ‘대체로 사실 아님’, ‘절반의 사실’, ‘대체로 사실’, ‘사실’, ‘판단 유보’의 6가지 범주로 구분된다. 본 연구에서는 정치와 관련된 이슈들 중 사실 여부가 명확하게 판정된 뉴스들을 선별하여 해당 이슈를 키워드로 트위터 데이터를 수집하였다. 구체적으로, ‘사실’ 혹은 ‘대체로 사실’로 판정된 것은 ‘사실’로 분류하고, ‘전혀 사실 아님’ 혹은 ‘대체로 사실 아님’으로 판정된 것은 ‘거짓’으로 분류하였다. 그 외의 ‘절반의 사실’이나 ‘판단 유보’로 판정된 이슈들은 데이터 수집 대상에서 제외하였다. 한편, 수집된 가짜 뉴스와 진짜 뉴스 샘플 수는 6:4 비율의 분포를 보인다.

단계2: 텍스트 전처리

텍스트 전처리를 위해서는 <표4-1>과 같은 작업을 수행하였다. 우선 불필요한 특수문자와 문장부호들을 제거하였다. 트위터의 특성상 많이 사용되는 @와 #를 포함하는 모든 특수문자를 제거하였다. 추후 ‘문장부호 사용 비율’ 변수를 생성하기 위해 물음표와 느낌표는 제외하고 문장부호를 제거하였다. 또한 외부 링크 주소는 해당 연구와 무관하므로 텍스트에 포함된 모든 URL 주소를 제거하였다. 이후에는 한국어 자연어처리를 위한 대표적인 Python 라이브러리인 KoNLPy의 Customized 버전을 활용해 형태소 분석에 앞서 고유명사들을 사용자 사전에 등록하였다. 예를 들어, ‘문재인’, ‘더불어민주당’, ‘안랩코코넛’과 같은 정치인, 정당 이름, 기업명 등의 고유명사는 띄어쓰기 여부에 따라 토큰화 과정에서 분리되지 않도록 하나의 단어로 지정해주었다. 형태소 분석 단계에서는 KoNLPy의 Twitter 형태소 분석기를 사용하였으며, 내재된 기능을 통해 어형의 변화된 형태를 원형으로 바꿔주는 어근화(stemming)를 수행하였다. 예를 들어, ‘입니다’를 ‘이다’의 기본 형태로 변형시켜주었다.

표 4-1. 텍스트 전처리 예시

문장부호 및 특수문자 제거	?와 !를 제외한 모든 문장부호와 특수문자
URL 주소 제거	외부 링크 주소
사전 등록 예시	더민당, 더불어민주당, 미르K, 탈원전, 안랩코코넛, 팩트체크, 해피아, 투표지, 최순실, 문재인, 문준용, 우병우, 정유라, 선관위
토큰화	KoNLPy의 Twitter 형태소 분석기
품사 부착 예시	선관위는 당장 개표 분류기 사용 금지해라 → [('선관위', 'Noun'), ('는', 'Josa'), ('당장', 'Noun'), ('개표', 'Noun'), ('분류기', 'Noun'), ('사용', 'Noun'), ('금지하다', 'Verb')]
어간 추출 예시	입니다 → 이다, 유리한 → 유리하다, 만듭니다 → 만들다, 만난 → 만나다

단계3: 변수 추출

본 단계에서는 아래의 <표4-2>와 같이 텍스트의 언어적 특징을 대변해 줄 수 있는 ‘콘텐츠 기반의 변수 추출 방법’에 기인하여 변수를 추출하고자 한다. 본 연구에서는 선행연구에서 자주 사용되었거나, 실험 결과 분류 성과에 주요한 영향을 미치는 것으로 알려진 변수들을 사용하였다. 결과적으로 어휘 변수, 구문론 변수, 심리언어학 변수 3가지로 범주화하고 그에 해당되는 세부적인 변수들을 선정하여 총 9개의 자질들을 추출하였다.

표 4-2. 변수 추출

어휘 변수 (Lexical Features)	문서 별 토큰 개수 (형태소 기준)
	문서 별 음절 개수
구문론 변수 (Syntactic Features)	문서 별 문장부호 사용 개수 (물음표, 느낌표)
	문서 별 명사 개수
	문서 별 형용사 개수
	문서 별 부사 개수
	문서 별 동사 개수
심리언어학 변수 (Psycholinguistic Features)	문서 별 긍정어 개수
	문서 별 부정어 개수

1) 어휘 변수(Lexical Features)

문서의 어휘 특징을 추출하기 위해 뜻을 가진 가장 작은 말의 단위인 형태소기준의 문서 별 토큰 개수, 문서 별 음절 개수 2가지를 독립변수로 선정하였다. 선행 연구에서도 문서 별 단어의 개수, 음절 수, 문단 별 평균 단어의 개수 등의 어휘 변수들을 사용한 연구들이 다수 진행되었다(Zubiaga, 2016; Potthast et al., 2017).

2) 구문론 변수(Syntactic Features)

문서의 구문적 특징을 추출하기 위한 변수로는 우선 물음표와 느낌표를 포함하는 문장부호 사용 개수를 사용하였다. 물음표는 불확실성을 뜻하며, 느낌표는 강조와 놀라움을 뜻하는 기호로 가짜 뉴스에 더욱 많이 사용될 것이라는 전제 하에 선행 연구에서도 가짜 뉴스 분류를 위한 변수로 사용 되곤 했다(Zubiaga, 2016). 한편, Perez-Rosas et al. (2017)의 연구에서 유명인사에 대한 루머와 관련된 기사들을 모아 놓은 Celebrity dataset을 대상으로 실험한 결과, 문장부호 사용 비율 변수만을 사용한 분류 모델(70%)이 모든 변수를 사용한 분류 모델(73%)을 이어 두번째로 높은 정확성을 보이면서 거짓과 사실을 구별해줄 수 있는 유의미한 변수임을 입증하였다.

문장부호 이외에도 명사, 형용사, 부사, 동사 네 가지 품사의 문서 별 사용 빈도를 후보 변수로 선정하였다. 문서 별 품사 사용 빈도는 자연어처리 기반의 가짜뉴스 분류 연구에서 다수 사용되었다(Zubiaga, 2016; Potthast et al., 2017; Perez-Rosas et al., 2017). 특히, Perez-Rosas et al. (2017)은 LIWC(Linguistic Inquiry and Word Count)를 통해 문서 별 품사 사용 비율을 산출하였는데 가짜 뉴스는 부사와 동사 사용 빈도가 높으며, 진짜 뉴스는 대명사의 사용 빈도가 높다는 실험 결과를 발표했다. 본 연구에서는 Python KoNLPy 패키지의 Twitter 형태소 분석기를 사용하여 형태소 별 품사 부착(Part-of-Speech Tagging)을 하고, 명사, 형용사, 부사, 동사의 네 가지 품사의 문서 별 사용 빈도를 변수로 산출하고자 한다.

3) 심리언어학 변수(Psycholinguistic Features)

심리언어학 변수는 감성을 기반으로 어휘를 구분하여, 거짓 혹은 진실로 구성된 텍스트가 어떤 감성을 지닌 어휘들을 주로 사용하였는지 알아보기 위한 자질이다. Perez-Rosas et al. (2017)은 어휘를 심리요인 별로 세분화한 LIWC 카테고리들을 기반으로 뉴스 기사 텍스트의 감성 어휘 사용 비율을 분석하였다. 연구 결과, 가짜 뉴스는 긍정적인 어휘, 확신을 뜻하는 어휘를 더욱 많이 사용하며, 진짜 뉴스는 인지적 어휘를 더욱 많이 사용하는 경향이 있다고 언급했다. 해당 연구는 한국어 소셜 미디어를 대상으로 한 가짜 뉴스 관련 텍스트의 어휘들이 지니는 감성에 주목하여 분류 기준으로 사용해보고자 한다. 이를 위해, 감성 사전을 기반으로 문서 별 부정어와 긍정어 사용 빈도를 산출하고자 한다.

한편, 감성 사전을 구축하는 방법은 크게 사전 기반(Dictionary-based)의 접근과 말뭉치 기반(Corpus-based)의 접근 두 가지로 나뉜다. 사전 기반의 접근법은 이미 구축되어 있는 사전을 활용하는 방법이다. 예를 들어, 한국어 대상의 연구에서 KNU 한국어 감성사전, KOSAC(Korean Sentiment Analysis Corpus), 오픈한글 등 이미 만들어져 있는 한국어 감성사전을 활용하는 방법을 뜻한다. 이에 반해, 말뭉치 기반 감성 사전은 해당 도메인에 맞게 연구자가 새롭게 사전을 구축하는 방법이다. 본 연구에서는 해당 도메인에 최적화된 한국어 감성 사전을 활용하고자 말뭉치 기반의 접근법을 사용하였다. 감성을 지닐 수 있는 명사, 형용사, 동사, 부사에 해당되는 형태소들을 대상으로 사전을 구축하였는데, 예를 들어, ‘의심’, ‘안타깝다’, ‘체포하다’ 등의 단어들은 부정어로, ‘공정성’, ‘명확하다’, ‘해결하다’ 등의 단어들은 긍정어로 구분하였다(표4-3).

표 3-3. 감성사전 예시

부정어 예시	의심, 비자금, 불법, 배후, 사죄, 부정선거, 냄새, 걱정, 부정개표, 내막, 의혹, 마비, 해킹, 우려, 불량, 탕, 조작, 폐수, 안타깝다, 충격, 폭로, 왜곡, 유감이다, 고발, 내란, 범죄, 털리다, 급급하다, 은폐, 쿠데타, 감옥, 사기질, 무기징역, 위장, 구속, 미르K, 불법행위, 체포하다, 분노, 거짓말, 문란하다, 불편하다
긍정어 예시	공정성, 환경, 자연, 무료, 시민혁명, 속행, 답, 잘하다, 사실, 예우, 명확하다, 국익, 균형, 발전하다, 이행, 해결하다, 방지, 미래, 지식인, 맞다, 혁신, 클린, 정확하다, 확인, 확충, 인정, 정화, 실적, 구매, 본질, 전문가, 동맹국, 경쟁력, 우위, 청정, 입증하다, 근거, 명시하다, 준비하다, 업적, 팩트, 고려하다

단계4: 변수 선정

본 연구에서는 추출한 9개의 변수를 모두 사용하는 것이 아니라 ‘변수 선정’ 단계를 통해 통계적으로 보다 유의미한 변수 집단을 선정하였다. 우선, 다중공선성을 검사하였는데, 독립 변수들 간의 분산 팽창 인수(VIF)가 모두 1 근처의 값을 보여 9개 변수들 간의 상관성이 낮음을 확인하였다. 이후에는 9개의 변수를 대상으로 단계적 회귀분석(Stepwise Regression)을 수행하여 AIC 값이 최소화되는 변수 집단을 산출하였다. 결과적으로, 토큰 개수, 문장 부호 개수, 부사 개수, 명사 개수, 긍정어 개수, 부정어 개수의 6가지 변수가 최종 변수로 선정되었다(표4-4).

표 4-4. 최종 독립변수

변수 종류	변수명
어휘 변수	토큰 개수
구문론 변수	문장부호(느낌표, 물음표) 개수
구문론 변수	명사 개수
구문론 변수	부사 개수
심리언어학 변수	긍정어 개수
심리언어학 변수	부정어 개수

단계5: 분류

본 연구에서는 대표적인 분류 기법인 서포트 벡터 머신(Support Vector Machine, SVM)을 수행하여 분류 모형을 구축하고자 한다. 분류는 두 카테고리 중 어느 하나에 속하는 데이터 집합이 주어졌을 때, 새로운 데이터가 어느 카테고리에 속할지 판단하는 모델을 만드는 작업이다. 이 중에서도 SVM은 각 군집의 최전선에 존재하는 두 서포트 벡터(Support Vector) 사이의 간격(margin)을 최대화하는 분류 경계면(hyperplane)을 찾는 기법이다(그림4-2). SVM은 훈련 속도가 느림에도 불구하고, 비선형 문제에도 적용할 수 있으며 다른 기계학습에 비해 과대적합 되는 경향이 매우 낮아 많은 분류 문제 연구에 사용되고 있다(Jiawei Han, 2006). 또한 SVM은 적은 양의 데이터에서도 높은 예측 정확도를 보인다는 장점을 가지고 있

다. 본 연구에서는, 기계 학습 수행에 필요한 패키지를 제공하는 Python의 scikit-learn 라이브러리를 활용하여 SVM 분류를 수행한다.




그림 4-2. 간단한 서포트 벡터 머신(SVM)

단계6: 평가

본 연구에서는 분류기 성능 측정의 통계적 신뢰도를 높이기 위해 K겹 교차검증(K-fold Cross Validation)을 수행하고자 한다. 구체적으로는, 다음 <그림4-3>과 같은 방식으로 전체 데이터 셋을 임의로 같은 크기의 10개의 겹(fold)으로 나누어 10겹 교차검증을 실시한다. 10개의 fold를 돌아가며 한번씩 학습용 데이터로 사용하여 10차례 실험을 반복하는데, 각 차례마다 검증용으로 사용되는 1개 fold를 제외한 9개의 fold는 분류 모형을 만들기 위한 학습용 데이터로 사용한다. 최종적으로는, 10차례 실험을 반복하여 나온 10개 값의 평균을 구하여 모델의 성능을 평가한다(Wong, 2017).




그림 4-3. 10겹 교차검증(10-fold Cross Validation)

분류 모형의 성능을 평가하기 위한 척도로는 알고리즘 성능 평가에 널리 사용되는 혼동 행렬(Confusion Matrix)을 사용하고자 한다(표4-5). 혼동행렬은 실제 값과 예측 값을 비교하여 분류 결과를 “True Positive(TP)”, “False Positive(FP)”, “True Negative(TN)”, “False Negative(FN)”의 네 가지 범주로 나눈다. 이를 기반으로 하는 성능 검증 지표에는 정확도(Accuracy), 재현율(Recall), 정밀도(Precision), F값(F-measure) 등이 있다. 한편, 본 연구에서는 ‘가짜 뉴스’를 Positive, ‘진짜 뉴스’를 Negative로 구분하였다.

표4-5. 혼동 행렬 (Confusion Matrix)

Confusion Matrix		Predicted Class	
		Positive	Negative
Actual Class	Positive	True Positive	False Negative
	Negative	False Positive	True Negative

- 1) 정확도(Accuracy): 학습된 예측 모델을 기반으로 산출한 데이터 값의 전체에서 실제 값을 맞춘 비율을 뜻한다. 학습 결과 만들어진 예측 모델이 올바르게 실제 값을 예측했는지를 판단하는 척도이며, 해당 값은 1에 가까울수록 우수한 성능에 해당한다. 정확도를 계산하는 산식은 다음과 같다.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- 2) 재현율(Recall): 민감도(Sensitivity)라고도 불리며, 실제 값이 Positive인 전체 Positive 데이터 중에서 Positive라고 올바르게 예측한 비율을 뜻한다. 재현율은 1에 가까울수록 성능이 높다고 해석할 수 있다. 재현율을 계산하는 산식은 다음과 같다.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- 3) 정밀도(Precision): Positive라고 예측한 것 중에서 실제 값이 Positive인 것의 비율을 뜻한다. 해당 값은 1에 가까울수록 성능이 높다고 해석할 수 있으며, 정밀도를 계산하는 산식은 다음과 같다.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- 4) F값(F-measure): F값은 재현율과 정밀도를 모두 고려한 것으로, 두 값의 조화 평균(harmonic mean)을 의미한다. F값은 단일 값으로 요약하기 위한 방법으로 1에 가까울수록 우수한 성능을 가진다고 해석할 수 있다. F값을 도출하는 산식은 다음과 같다.

$$F - \text{measure} = \frac{2 * \text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$

본 연구에서는 10겹 교차검증을 수행하여 만들어진 10개의 모델에 대해 위의 4개의 척도를 각각 총 10차례 계산하고, 각각의 값의 평균을 구해 최종 결과를 산출한다. 이후에는, TF와 TF-IDF를 적용한 모형의 평균 성능 값과 비교하여 다양한 언어학적 범주의 독립 변수들을 활용한 본 모형의 우수성을 확인해보고자 한다.

V. 실험결과 및 분석

A. 실험결과 및 분석

10겹 교차검증을 수행하여 산출된 10개의 모델에 대한 정확도, 재현율, 정밀도, F값은 <표5-1>과 같다. 본 연구에서는 성능 평가를 위해 10개의 모델에 대한 평균값을 산출하였는데, 최종적으로 선정된 콘텐츠 기반의 변수 집단(`Feature_Set`)을 적용한 모형은 시험용 데이터셋에서 정확도 70.53%, 재현율 85.76%, 정밀도 71.18%, F값 77.24%의 성능을 보였다. <그림5-1>은 혼동행렬에 기반한 4개의 척도에 있어서 학습용 데이터셋과 시험용 데이터셋의 각각의 평균값을 그래프로 비교해 놓은 그림이다.

<표5-2>와 <그림5-2>는 제안 모형과 전통적인 텍스트 자질 추출방법인 단어 빈도(TF), 단어 빈도-역문서 빈도(TF-IDF)를 적용한 분류 모형의 성과를 비교한 수치를 나타낸다. 제안 모형은 TF를 자질로 사용한 모형보다 정확도, 재현율, 정밀도, F값의 모든 척도에서 더욱 우수한 성능을 보이며, TF-IDF를 적용한 모형보다는 정확도, 정밀도, F값에 있어서 더욱 높은 수치를 보이고 있다. 이를 통해 다양한 언어학적 변수들을 활용한 본 연구가 더욱 우수한 모형임을 입증할 수 있다. 또한, 대체적으로 4개 척도에 있어서 제안모형(`Feature_set`), 단어 빈도-역문서 빈도(TF-IDF), 단어 빈도(TF) 순으로 높은 성능을 보여주었다. 이를 통해, 텍스트의 다양한 언어학적 특징에 주목한 ‘콘텐츠 기반의 변수 선정 방법’이 전통적인 자질 추출 기법인 어휘 기반의 TF나 TF-IDF만을 사용하는 것보다 가짜 뉴스 분류 문


제에 있어 더욱 유의미한 변수 집단을 추출해 줄 수 있음을 확인하였다.

표 5-1. 10-fold Cross Validation 수행 결과

(단위: %)

Feature_set		Accuracy	Recall	Precision	F-measure
Fold 1	Train	75.86	90.20	74.20	81.42
	Test	75.00	91.67	73.33	81.48
Fold 2	Train	75.86	89.22	74.59	81.25
	Test	65.00	75.00	69.23	72.00
Fold 3	Train	75.86	90.20	74.19	81.42
	Test	75.00	100.00	70.59	82.76
Fold 4	Train	74.71	89.22	73.39	80.53
	Test	85.00	100.00	80.00	88.89
Fold 5	Train	77.14	90.29	75.61	82.30
	Test	63.16	100.00	61.11	75.86
Fold 6	Train	77.14	92.23	74.80	82.61
	Test	63.16	72.73	66.67	69.57
Fold 7	Train	77.14	94.17	74.05	82.91
	Test	47.37	63.64	53.85	58.33
Fold 8	Train	74.29	88.35	73.39	80.18
	Test	78.95	100.00	73.33	84.62
Fold 9	Train	73.71	87.38	73.17	79.65
	Test	94.74	90.91	100	95.24
Fold 10	Train	76.57	91.26	74.60	82.10
	Test	57.90	63.64	63.64	63.64
Average	Train	75.83	90.25	74.20	81.44
	Test	70.53	85.76	71.18	77.24

그림 5-1. 제안 모형의 정확도, 재현율, 정밀도, F값



구체적으로, 제안 모형은 TF를 적용한 모델 보다는 약 2.4%, TF-IDF를 적용한 모델 보다는 약 0.87% 높은 정확도를 보였다. 정확도란, 전체 데이터 중에서 실제 가짜 뉴스인 샘플을 가짜로, 실제 진짜 뉴스인 샘플을 진짜로 옳게 예측한 모든 경우의 수를 비율로 나타낸 것이다. 이를 통해, 제안 모형이 TF와 TF-IDF를 기반으로 한 모형보다 실제 데이터를 분류 클래스에 맞게 더욱 잘 예측해주는 분류기임을 알 수 있다.

실제 가짜 뉴스를 가짜라고 잘 분류할 수 있는지를 나타내는 지표인 재현율에 있어서 제안 모형은 TF를 적용한 모델 보다는 약 4.09% 높은 수치를 보였으나

TF-IDF를 적용한 모델 보다는 약 1.21% 정도 낮은 성과를 보여주었다. 가짜 뉴스에 사용되는 단어를 기반으로 중요도를 산출한 TF-IDF를 이용한 모형은 우수한 재현율을 보였지만 이는 해당 데이터 셋에서만 제한적으로 사용할 수 있는 단어 가중치라는 점에서 한계점을 지닌다.


정밀도를 살펴보면, 제안 모형은 TF와 TF-IDF를 적용한 모델보다 각각 1.37%, 1.88% 더욱 높은 성능을 보였다. 정밀도는 가짜 뉴스라고 예측한 것 중에서 실제 가짜 뉴스인 경우의 비율을 뜻한다. 정확도에 이어 정밀도에서도 제안 모형은 다른 기법들 보다 더욱 좋은 성능을 보여주었다.

재현율과 정밀도를 모두 고려하여 산출한 F-값은 제안 모형이 TF를 사용한 모델 보다는 약 2.67%, TF-IDF를 사용한 모델 보다는 약 0.64% 더욱 높은 성능을 보여주었다. F-값에서도 제안 모형은 두 가지 베이스라인보다 더욱 높은 수치를 나타냄을 확인하여 제안 모형의 우수성을 입증하였다.

표 5-2. 변수 추출 방법 별 성과 비교

	Accuracy	Recall	Precision	F-measure
Feature_set	70.53	85.76	71.18	77.24
TF	68.13	81.67	69.81	74.57
TF_IDF	69.66	86.97	69.30	76.60

그림 5-2. 변수 추출 방법 별 성과 비교 그래프



VI. 결론

본 연구에서는 텍스트의 언어학적 특성에 주목하여 변수들을 추출하고 이를 기계학습 방법에 적용하여 우수한 성능의 가짜 뉴스 분류 모형을 구축하였다. 가짜 뉴스는 정치적, 경제적 문제를 야기하는데 SNS의 특성상 생성되기 쉬우며 한번 생성되면 확산되는 속도도 빠르기 때문에, 이를 사전에 방지하는 것은 매우 중요하다. 실제로, 페이스북과 트위터는 자체적으로 가짜 뉴스를 거를 수 있는 알고리즘을 개발하고 있을 만큼 가짜 뉴스 탐지는 전세계적으로도 주목받고 있는 연구 분야이다. 가짜 뉴스 탐지 연구의 중요성이 제기되고 있는 현 시점에서, 본 연구는 SNS상의 가짜 뉴스의 문체적 특징에 주목하여 가짜 뉴스를 탐지할 수 있는 연구를 진행하였다는 점에서 의의가 있다. 또한, 가짜 뉴스는 전세계적인 문제임에도 불구하고 한국에서는 이에 대한 연구가 미흡한 실정임에 주목하여 한국어 대상의 가짜뉴스 분류기를 만드는 것을 목적으로 하였다는 점에서 의미가 있다.

또한, 텍스트 분류에서 일반적으로 사용되는 TF나 TF-IDF에서 나아가 다양한 범주의 언어학적 특징들을 입력 변수로 사용하여 우수한 성능의 분류 모형을 구축하였다는 점에서 의의점을 지닌다. 텍스트를 기계학습 방법에 적용하기 위해서는 비정형 구조를 정량화된 특징 값으로 변환하여야 하는데, 본 연구에서는 TF나 TF-IDF와 같은 단어 기반의 자질 벡터에서 나아가 다양한 문체적 특징을 담은 콘텐츠 기반의 변수들을 직접 추출하여 입력 변수로 사용하였다. 결과적으로 제안 모형이 기존의 두 기법을 적용한 모형에 비해 전반적으로 우수한 분류 성과를 보여줄 수 있었다. 즉, 본 연구를 통해 보다 고차원적인 언어학적 특징을

고려한 콘텐츠 기반의 변수 추출 방법이 가짜뉴스 분류 도메인 문제에 효과적인 방법임을 확인할 수 있다.

반면, 본 연구의 한계점들은 다음과 같다. 우선, 한국어 데이터 확보의 어려움으로 인해 크기가 큰 데이터셋을 기반으로 실험을 진행하지 못하였다. 따라서, 본 연구 모형의 일반화된 성능 향상을 기대할 수 있는지 검토하기 위해 보다 많은 데이터를 추가적으로 확보하여 방대한 양의 데이터를 통해 실험을 수행해야 할 필요가 있다. 또한, 콘텐츠 기반의 변수들을 더욱 세분화한다면 뉴스의 진위여부의 차이를 나타낼 수 있는 더욱 유의미한 변수들을 도출할 수 있을 것으로 예상된다. 예를 들어, 품사를 명사, 부사, 형용사, 동사의 네 가지 범주로 나누던 방식을 더욱 세분화하거나 언어심리학 변수를 긍정어, 부정어의 두 가지로 범주로 나누던 방식을 더욱 다양한 감정을 지니는 변수들로 세분화한다면 텍스트의 언어학적 특징을 보다 잘 반영할 수 있을 것이다. 마지막으로, 가짜 뉴스 도메인에서는 레이블링 된 데이터 확보가 어렵다는 점에 주목하여 적은 수의 레이블링 데이터만으로도 가짜 뉴스를 분류해줄 수 있는 준지도 학습 기법(Semi-supervised Learning) 기반의 연구를 진행한다면 Cold-start 문제를 해결할 수 있는 방안을 마련할 수 있을 것으로 예상된다.

참 고 문 헌

- Allcott, H., & Gentzkow, M. (2017). Social media and fake news in the 2016 election. *Journal of Economic Perspectives*, 31(2), 211-36.
- Amiri, H., Resnik, P., Boyd-Graber, J., & Daumé III, H. (2016). Learning text pair similarity with context-sensitive autoencoders. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) (Vol. 1, pp. 1882-1892)*.
- Conroy, N. J., Rubin, V. L., & Chen, Y. (2015, November). Automatic deception detection: Methods for finding fake news. In *Proceedings of the 78th ASIS&T Annual Meeting: Information Science with Impact: Research in and for the Community (p. 82)*. American Society for Information Science.
- Della Vedova, M. L., Tacchini, E., Moret, S., Ballarin, G., DiPierro, M., & de Alfaro, L. (2018, May). Automatic Online Fake News Detection Combining Content and Social Signals. In *2018 22nd Conference of Open Innovations Association (FRUCT) (pp. 272-279)*. IEEE.
- Gottfried, J., & Shearer, E. (2016). News use across social media platforms 2016. Pew Research Center, May 26. [http://www. journalism. org/2016/05/26/news-use-across-social-media-platforms-2016/](http://www.journalism.org/2016/05/26/news-use-across-social-media-platforms-2016/), accessed

on October 30, 2018.

Han, J., Pei, J., & Kamber, M. (2011). Data mining: concepts and techniques. Elsevier.

Joachims, T. (1998, April). Text categorization with support vector machines: Learning with many relevant features. In European conference on machine learning (pp. 137–142). Springer, Berlin, Heidelberg.

Keller, J. (2013). A fake AP tweet sinks the DOW for an instant. Bloomberg Businessweek.

Le, Q., & Mikolov, T. (2014, January). Distributed representations of sentences and documents. In *International Conference on Machine Learning* (pp. 1188–1196).

Newman, N., & Levy, D. A. (2016). Digital News Report. Reuters Institute for the Study of Journalism, Oxford.

Oshikawa, R., Qian, J., & Wang, W. Y. (2018). A Survey on Natural Language Processing for Fake News Detection. arXiv preprint arXiv:1811.00770.

Pérez-Rosas, V., Kleinberg, B., Lefevre, A., & Mihalcea, R. (2017). Automatic Detection of Fake News. arXiv preprint arXiv:1708.07104.

Potthast, M., Kiesel, J., Reinartz, K., Bevendorff, J., & Stein, B. (2017). A stylometric inquiry into hyperpartisan and fake news. arXiv preprint arXiv:1702.05638.

Rashkin, H., Choi, E., Jang, J. Y., Volkova, S., & Choi, Y. (2017). Truth of

- varying shades: Analyzing language in fake news and political fact-checking. In Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (pp. 2931-2937).
- Suh, J. H. (2016). Comparing writing style feature-based classification methods for estimating user reputations in social media. SpringerPlus, 5(1), 261.
- Shu, K., Sliva, A., Wang, S., Tang, J., & Liu, H. (2017). Fake news detection on social media: A data mining perspective. ACM SIGKDD Explorations Newsletter, 19(1), 22-36.
- Sriram, B., Fuhry, D., Demir, E., Ferhatosmanoglu, H., & Demirbas, M. (2010, July). Short text classification in twitter to improve information filtering. In Proceedings of the 33rd international ACM SIGIR conference on Research and development in information retrieval (pp. 841-842). ACM.
- Wong, T. T. (2015). Performance evaluation of classification algorithms by k-fold and leave-one-out cross validation. Pattern Recognition, 48(9), 2839-2846.
- Zubiaga, A., Liakata, M., & Procter, R. (2016). Learning reporting dynamics during breaking news for rumour detection in social media. arXiv preprint arXiv:1610.07363.
- 김대근, 임석순, 유진. (2017). 가짜뉴스 등 허위사실 유포로 인한 사이버상 유권자의사 왜곡 방지에 관한 연구. 중앙선거관리위원회.
- 박재형, & 김영인. (2017, June). SVM 분류기를 이용한 가짜 뉴스 판별 시스템

- 개발. In Proceedings of KIIT Summer Conference (pp. 354-355).
- 윤태욱, & 안현철. (2018). 텍스트 마이닝과 기계 학습을 이용한 국내 가짜뉴스 예측. Journal of Information Technology Applications & Management, 25(1), 19-32.
- 이동호, 이정훈, 김유리, 김형준, 박승면, 양유준, 신웅비. (2018). 딥러닝 기법을 이용한 가짜뉴스 탐지. 한국정보처리학회 2018년도 춘계학술발표대회 (pp. 384 -387).
- 정민, & 백다미. (2017). 가짜 뉴스 (Fake News) 의 경제적 비용 추정과 시사점. 한국경제주평, 736, 1-15.
- 최홍규. (2017). 가짜 뉴스 관련 논점과 페이스북·구글의 대응 방안. KISA Report, 2, 8-16.
- 한상기. (2017). 가짜뉴스의 현황과 원인, 그리고 대응 방안. KISA Report. 2, 3-7.
- 한상기. (2018). 페이크 뉴스 또는 허위정보 판별 연구현황. KISA Report. 11, 1-5.

ABSTRACT

Fake News Detection Using Content-based Feature Extraction Method

Hosun Jung

Major in Big Data Analytics

The Graduate School of Ewha Womans University

Since the advent of social media, more people have been consuming news through Social Network Services(SNS) such as Facebook and Twitter rather than through traditional media such as television and newspapers. News Consumption using SNS has the advantage of being accessible and less expensive. However, it also has some serious disadvantages. First, because anyone can generate information on social media, false information can be easily generated. Secondly, because any information can be spread quickly on social media, there is always the risk of exposure to fake news for SNS users. Fake news is problematic because it can cause political and economic problems to news consumers and the entire community. For example, if SNS is misused for political purposes, voters using SNS can make wrong decision by being affected by fake news. In addition, if fakes news about certain individuals or companies spread, there is a possibility that their economic value will decrease. Concerns over the seriousness of the fake news problem have spread around the world since the 45th U.S. presidential election in 2016. Therefore, the importance of detecting fake news has emerged and studies to prevent fake news on social media have been actively conducted overseas.

On the other hand, domestic research on fake news detection is not enough even though fake news problems are rampant in Korean society as well. Therefore, in this study, we aim to detect

Korean fake news on SNS. Specifically, the goal of this study is to build a classification model that identifies the authenticity of the Korean Twitter. To achieve the goal, this research extracts a variety of linguistic input variables that can represent the textual characteristics of news on Twitter rather than extracting feature vectors using “Term Frequency(TF)” or “Term Frequency-Inversed Document Frequency(TF-IDF)” techniques that are commonly used in feature extraction. In addition, a meaningful group of variables was selected by conducting feature selection using Stepwise Regression.

According to the study, the proposed model showed 70.53% accuracy, 85.76% recall, 71.18% precision, and 77.24% F-measure by outperforming the performance of TF-based model and TF-IDF based model in general.

The main contribution of this research is to build a Korean fake news classifier since there has not been enough research about Korean fake news detection before. Also, the proposed model using content-based features outperformed the models using TF and TF-IDF, which identifies the importance of various types of linguistic features in fake news classification.

On the other hand, our research has a limitation of not having enough data. Therefore, it is necessary to collect more data in future studies to explore ways to make the research more reasonable. Furthermore, it is expected to be a meaningful follow-up study to conduct semi-supervised learning-based research because it can build a high-performance automated classifier even when data size is not large.