

<https://doi.org/10.7236/JIIBC.2022.22.6.165>

JIIBC 2022-6-24

FitRec 기반 달리기 심박수 예측 시스템

Prediction System of Running Heart Rate based on FitRec

김진욱*, 김광현*, 선준호*, 이승우*, 김수현*, 김진영**

Jinwook Kim*, Kwanghyun Kim*, Joonho Seon*,
Seongwoo Lee*, Soo-Hyun Kim*, Jin-Young Kim**

요약 사람의 심박수는 운동 강도 측정의 기준으로 사용되는 중요한 지표이다. 만약 심박수를 예측한다면 운동 중 운동 강도를 미리 조절하여 효율적으로 운동할 수 있다. 본 논문에서는 FitRec 기반 달리기 운동을 수행하는 사용자의 심박수를 예측하는 모델을 제안한다. 학습을 위해 Endomondo의 데이터를 사용하여 예측 모델에 적용한다. 성능 비교를 위해 시계열 데이터 처리 알고리즘 LSTM(long short term memory)과 GRU(gated recurrent unit)를 사용하였다. FitRec에 유산소 운동 중 달리기 데이터만 학습한 결과 여러 유산소 운동 데이터를 모두 학습한 모델보다 MAE(mean absolute error)와 RMSE(root mean squared error) 둘 다 성능이 향상됨을 확인하였다.

Abstract Human heart rate can be used to measure exercise intensity as an important indicator. If heart rate can be predicted, exercise can be performed more efficiently by regulating the intensity of exercise in advance. In this paper, a FitRec-based prediction model is proposed for estimating running heart rate for users. Endomondo data is utilized for training the proposed prediction model. The processing algorithms for time-series data, such as LSTM(long short term memory) and GRU(gated recurrent unit), are employed to compare their performance. On the basis of simulation results, it was demonstrated that the proposed model trained with running exercise performed better than the model trained with several cardiac exercises.

Key Words : Regression, Recurrent neural network, Deep learning, FitRec

1. 서 론

2020년 2월 이후 COVID-19 확산으로 인해 전 세계적으로 건강에 대한 국민적 관심이 높아지고 있다. 한 연구에 따르면 2018년 WHO에서 발표한 신체 활동 지침에 부합하는 유산소 운동과 근육 강화 활동을 수행한 성인은 COVID-19 감염 위험도가 20% 감소했고, COVID-19

감염 이후 중증 진행 가능성과 사망률이 각각 60%, 80% 이상 감소한다는 사실을 밝혀냈다¹⁾. 미국심장협회(American Heart Association, AHA)에 따르면, 올바른 유산소 운동을 수행하기 위해서는 목표 심박수를 최대 심박수의 50%와 80% 사이에서 운동하는 것을 권고하고 있다²⁾.

최근 유산소 운동과 관련하여 심박수 예측과 관련된

*준회원, 광운대학교 전자융합공학과

**정회원, 광운대학교 전자융합공학과, 교신저자

접수일자 2022년 9월 22일, 수정완료 2022년 11월 16일

게재확정일자 2022년 12월 9일

Received: 22 September, 2022 / Revised: 16 November, 2022 /

Accepted: 9 December, 2022

*Corresponding Author: jinyoung@kw.ac.kr

Dept. of Electronic Convergence Engineering, Kwangwoon University, Korea

다양한 연구가 진행되고 있다³⁻⁴. 한 논문에서는 DARNN (dual-stage attention based recurrent neural network) 기반 FitRec를 통해 유산소 운동의 운동 경로 추천과 심박수를 예측하였다³. 다른 논문에서는 키, 성별 그리고 몸무게 등의 개인정보에 해당하는 데이터를 제외하고 심박수, 고도 그리고 속도 등의 운동 정보에 해당하는 데이터를 학습에 사용하여 유산소 운동의 운동 경로 추천과 심박수를 예측하는 P3FitRec를 제안하였다⁴.

그러나 두 연구 모두 각각의 운동이 일정 시간마다 거리, 속도, 심박수 등의 값이 다르지만, 운동데이터를 분리하지 않고 하나의 유산소운동 데이터로써 사용하였다. 그리고 운동별 운동데이터 차이를 원한 인코딩된 운동 id로 표현하였다. 이는 각각의 운동별 심박수 예측값 차이를 운동 임베딩 벡터에만 의존하여 온전히 한 운동의 심박수를 예측에 어려움을 겪는다. 본 논문에서는 예측 정확도를 높이기 위해 유산소 운동데이터 중 달리기 운동데이터만 사용하여 달리기 운동에 대한 심박수를 예측하는 시스템을 제안한다.

본 논문의 구성은 다음과 같다. II장에서는 모델 관련 알고리즘을 소개한다. III장에서는 본 논문에서 제안한 시스템 모델을 소개한다. IV장에서는 실험 및 결과를 확인하고 V장에서 결론을 내리며 마무리 짓는다.

II. 관련 알고리즘

1. 순환 신경망

순환 신경망이란 은닉층으로 순환하는 층을 이용하여 이전 상태의 은닉층 출력이 현재 상태의 은닉층 입력으로 들어가 연산에 포함되는 구조를 의미한다⁵. 그림 1은 순환 신경망 모델 구조를 보여준다. t 시점에서의 입력 x 가 활성화 함수를 통해 출력층으로 나올 때 $t-1$ 시점에서의 은닉 상태가 추가된다. 수식은 다음과 같다.

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b), \quad (1)$$

$$y_t = \sigma(W_y h_t + b). \quad (2)$$

(1)은 t 시점의 은닉 상태를 나타내고, (2)는 t 시점의 출력값을 나타낸다. σ 는 비선형 활성화 함수 중 하나이다. t 시점의 은닉 상태는 t 시점의 입력값 x_t 와 $t-1$ 시점의 은닉 상태 h_{t-1} 이 활성화 함수인 $\tanh$ 함수를 통과한 값이다. t 시점의 출력값 y_t 는 t 시점의 은닉 상태 h_t 가 활성화 함수 σ 를 통과한 값이다.

2. 장단기 메모리 네트워크

장단기 메모리 네트워크는 은닉층을 장단기 메모리 블록으로 이용하는 네트워크로 순환 신경망의 종류 중 하나이다⁶. 순환 신경망 모델은 시점이 길어질수록 앞의 정보가 충분히 전달되지 못하는 현상이 발생한다. 이를 장기 의존성 문제라고 하며 이 문제를 보완한 구조를 장단기 메모리라고 한다. 장단기 메모리는 망각 게이트, 입력 게이트, 그리고 출력 게이트로 구성되어 있다. 그림 2는 장단기 메모리 네트워크 모델 구조를 보여준다.

망각 게이트는 얼마만큼의 장기 정보를 삭제할지 결정하는 게이트이다. 수식은 다음과 같다.

$$f_t = \sigma_g(W_f x_t + U_f h_{t-1} + b_f). \quad (3)$$

(3)에 따르면 망각 게이트는 t 시점의 입력값 x_t 와 $t-1$ 시점의 은닉 상태 h_{t-1} 가 활성화 함수를 통과하여 출력된 값이다.

입력 게이트는 기억할 단기 정보의 양을 결정하는 게이트이다. 수식은 다음과 같다.




그림 1. 순환 신경망 모델 구조.

Fig. 1. Structure of recurrent neural network model.




그림 2. 장단기 메모리 네트워크 모델 구조.

Fig. 2. Structure of long short term memory network model.

$$i_t = \tanh(W_i x_t + U_i h_{t-1} + b_i). \quad (4)$$

(4)를 통해 입력 게이트는 t 시점의 입력값 x_t 와 t-1 시점의 은닉 상태 h_{t-1} 가 활성화 함수를 지나 값을 출력한다.

기존 순환 신경망 모델이 t-1 시점의 은닉 상태가 t 시점에 추가되었다면 장단기 메모리 네트워크 모델은 셀 상태가 추가되었다. 셀 상태 또한 은닉 상태처럼 t-1 시점의 셀 상태가 t 시점의 셀 상태를 구하기 위해 사용된다. t 시점의 셀 상태는 다음과 같이 표현된다.

$$\tilde{c}_t = \sigma_g(W_c x_t + U_c h_{t-1} + b_c), \quad (5)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t. \quad (6)$$

(5)에서 t시점의 입력값 x_t 와 t-1 시점의 은닉 상태 h_{t-1} 이 $\tanh$ 함수를 지나서 $\tilde{c}_t$ 를 출력한다. (6)에서 망각 게이트에서 출력한 f_t 와 t-1 시점의 셀 상태 c_{t-1} 를 원소 간 곱으로 계산하고, 입력 게이트에서 출력한 i_t 와 (5)에서 출력한 $\tilde{c}_t$ 를 원소 간 곱으로 계산한 두 식을 더하여 t 시점의 셀 상태 c_t 를 출력한다.

출력 게이트는 t 시점의 입력값 x_t 와 t-1 시점의 은닉 상태 h_{t-1} 이 활성화 함수를 지난 값이다. 이 값과 t 시점의 셀 상태 c_t 를 이용하여 t 시점의 은닉 상태를 결정한다. 출력 게이트를 수식으로 표현하면 다음과 같다.

$$o_t = \sigma_g(W_o x_t + U_o h_{t-1} + b_o), \quad (7)$$

$$h_t = o_t \odot \tanh(c_t). \quad (8)$$

(7)을 통해 출력 게이트의 값을 구하고 (8)을 통해 t 시점의 셀 상태의 값이 $\tanh$ 함수를 지나 출력 게이트의 값과 연산이 되어 t 시점의 은닉 상태를 구할 수 있다. t 시점의 은닉 상태는 t+1 시점의 입력층과 t 시점의 출력층으로 보내진다.

3. GRU (Gated recurrent unit)

GRU는 장단기 메모리 네트워크(long short term memory: LSTM)의 장기 의존성 문제에 대한 해결책을 유지하면서, 은닉 상태를 업데이트하는 계산을 줄였다⁷. LSTM과 달리 셀 상태가 없고 출력, 입력 그리고 망각 게

이트 대신에 업데이트, 리셋 게이트가 존재한다. GRU의 구조를 수식으로 다음과 같이 표현된다.

$$r_t = \sigma(W_{xr} x_t + W_{hr} h_{t-1} + b_r), \quad (9)$$

$$z_t = \sigma(W_{xz} x_t + W_{hz} h_{t-1} + b_z), \quad (10)$$

$$\tilde{h}_t = \tanh(W_{xh} x_t + W_{hh}(r_t \odot h_{t-1}) + b_h), \quad (11)$$

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t. \quad (12)$$

(9)는 리셋 게이트, (10)은 업데이트 게이트를 나타낸다. (11), (12)는 (9), (10)에서 구한 리셋 게이트와 업데이트 게이트의 값을 통해 그림 3에서처럼 연산하여 은닉 상태 h_t 을 출력한다.




그림 3. GRU 모델 구조.
Fig. 3. Structure of GRU model.

III. 시스템 모델

1. 실험 데이터

본 논문에서는 Endomondo에서 제공하는 데이터를 이용하였다¹³. 원본 데이터는 253,020개의 운동데이터가 있으며 1,104명의 사용자로 구성되어 있다. 표 1은 운동데이터 중 학습에 사용할 feature를 정리한 표이다. 표 1에서 나오는 것과 같이 학습에 사용할 feature 들은

표 1. 학습에 사용할 특징.
Table 1. Feature used in training.

	feature	종류
input	distance	sequence
	altitude	sequence
	user id	categorical
target	heart rate	sequence

distance, altitude, user id 그리고 heart rate이다. 학습 입력값에 distance, altitude, user id를 출력값에 heart rate가 들어간다. feature 중 user id를 제외하고 시계열 데이터로 구성되어 있으며 user id는 범주형 데이터로 구성되어 있다. 운동데이터 중 달리기의 심박수를 예측하기 위해 달리기 데이터만 사용하여 총 37,841개의 운동데이터를 사용한다. 37,841개 중 학습에 30,064개, 검증에 3,753개 그리고 테스트에 4,024개를 사용한다.

2. 제안한 모델 구조

본 논문에서는 다수의 유산소 운동에서의 심박수를 예측하는 것이 아닌 달리기 운동에서의 심박수를 예측하는 것을 목표로 한다. 기존의 FitRec 모델에서 sport id feature가 빠졌으며 시계열 feature를 처리할 RNN에 LSTM과 GRU를 각각 사용하여 두 모델의 비교 성능을 확인한다.




그림 4. 제안한 심박수 예측 모델.

Fig. 4. Proposed heart rate prediction model.

제안된 모델은 그림 4와 같다. 입력값은 두 가지의 종류로 구성되어 있다. 시계열 데이터와 범주형 데이터로 시계열 데이터인 고도(altitude)와 거리(distance)는 RNN을 통해 user id는 임베딩을 거쳐 연결(concatenate)된다. 연결된 값을 input attention과 RNN으로 구성된 인코더와 temporal attention과 RNN으로 구성된

decoder를 거쳐서 심박수를 예측한다.

3. 손실 함수

본 논문은 제안한 시스템 모델에 대해서 MSE(mean squared error)를 손실 함수로 사용한다. 수식은 다음과 같다.

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2. \quad (13)$$

(13)에서 n 은 입력 데이터 수를 나타내며, Y_i 는 실제 값을 나타내고, $\hat{Y}_i$ 는 예측값을 나타낸다.

IV. 실험 및 결과

1. 데이터 전처리

앞서 실험 데이터에서 선택된 데이터 필드에서 스포츠 종류 중 달리기를 사용하였다. 데이터의 입력값으로 사용할 거리 데이터를 위도, 경도 값을 통해 계산하였다. 거리의 경우 위도, 경도로 구성된 2개의 지점을 haversine을 통해 유도한다. 수식은 다음과 같다⁸.

$$h = \sin^2\left(\frac{\phi_2 - \phi_1}{2}\right) + \cos\phi_1 \cos\phi_2 \sin^2\left(\frac{\lambda_2 - \lambda_1}{2}\right), \quad (14)$$

$$d = 2r \arcsin(\sqrt{h}).$$

(14)에서 ϕ_1, ϕ_2 는 지점 1과 지점 2의 위도이다. λ_1, λ_2 는 지점 1과 지점 2의 경도이다. d 는 유도한 거리이다. r 은 지구의 반지름이다.

2. 하이퍼파라미터

본 연구에서 설정한 하이퍼파라미터는 총 5개이다. Dropout, 학습률, 셀의 개수, 배치 크기, 그리고 epoch이다. 각 파라미터에 대해 간략히 서술하겠다.

Dropout은 과적합을 막기 위한 층으로 정해진 비율로 무작위로 Dropout 층에 들어오는 입력값들을 0으로 설정한다. 본 논문은 이 값을 0.1로 설정한다.

학습률은 최적화 알고리즘의 조정 파라미터이다. 학습률이 너무 높으면 overshooting 현상이 발생할 수 있

다. 학습률이 너무 낮으면 손실 함수의 최소화에 수렴하는 데 오래 걸릴 수 있다. 본 논문에서는 실험을 통해 이 값을 0.001로 설정한다.

셀의 개수는 은닉층의 셀 개수를 정하는 파라미터이다. 셀의 개수가 커지면 네트워크의 크기가 커지고 더 복잡한 데이터 처리가 가능하다고 예상된다. 실험을 통해 이 값을 64로 설정한다.

배치 크기는 학습 단위를 정해주는 파라미터이다. 모델이 학습데이터를 얼마나 받아들여 모델 내부의 변수들을 업데이트할 것인지 결정하는 파라미터이다. 이 값을 2048로 설정한다.

epoch는 주어진 데이터를 몇 번 반복 학습할 것인지 결정하는 파라미터이다. 대체로 이 값을 증가시키면 학습 성과가 잘 나타나는 경향이 있지만 큰 값을 설정하면 과적합에 빠져 유의미한 학습 결과를 얻기 힘들다. 본 논문에서는 이 값을 20회로 설정한다. 추가로 과적합을 방지하기 위해서 early stopping을 설정하여 검증 손실 값이 3회 안에 향상되지 않으면 학습이 중단된다. 표 2는 본 논문에서 사용한 하이퍼파라미터를 정리한 표이다.

표 2. 실험 파라미터.
Table 2. Simulation parameters.

Parameter	Value
dropout	0.1
learning rate	0.001
number of cell	64
epoch	20
batch size	2048

3. 실험 결과

평가 지표는 RMSE(root mean squared error) 그리고 MAE(mean absolute error)를 사용하였다^[9]. RMSE와 MAE는 예보 오류와 시계열 분석에 사용되는 지표^[10]이며 수식은 다음과 같다.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2}, \quad (15)$$

$$MAE = \frac{\sum_{i=1}^n |y_i - x_i|}{n}. \quad (16)$$

(15), (16)에서 y_i 는 예측값, x_i 는 실제값 그리고 n 은 입력 데이터 수를 나타낸다. 표 3은 실제 데이터와 설계한 모델 간의 오차를 (15), (16)을 통해 계산한 결과를 정리한 표이다. 기존의 연구와 비교해서 달리기 데이터만 학습한 모델이 더 좋은 성능을 보여주고 있다. 두 모델 중에는 GRU를 사용한 모델이 더 좋은 성능을 보여줌을 확인한다. 그림 5, 6은 달리기 모델에서의 GRU, LSTM의 학습 손실을 나타낸다. 그림 7, 8은 GRU, LSTM의 테스트 데이터의 심박수 예측 결과 표본을 나타낸다. 두 모델 모두 높은 정확도의 예측을 보여준다.

표 3. 모델 성능평가.
Table 3. RMSE and MAE of models.

Model	Heart Rate	
	RMSE	MAE
FitRec-Attn	2.783	1.695
FitRec-Attn (Run/LSTM)	2.425	1.543
FitRec-Attn (Run/GRU)	2.391	1.54




그림 5. GRU 모델의 학습 손실.
Fig. 5. Training loss of GRU model.




그림 6. LSTM 모델의 학습 손실.
Fig. 6. Training loss of LSTM model.




그림 7. GRU 모델 심박수 예측 결과.
Fig. 7. Heart rate prediction result of GRU model.




그림 8. LSTM 모델 심박수 예측 결과.
Fig. 8. Heart rate prediction result of LSTM model.

V. 결 론

본 논문에서는 FitRec 기반 딥러닝 모델을 통해 달리기 운동의 심박수를 예측하는 모델을 제안하였다. 유산소 운동 중 달리기 데이터만 사용하여 데이터셋을 구성하였고, 시계열 데이터 처리를 위해 LSTM과 GRU 모델을 사용하여 비교 성능을 확인하였다. 심박수 예측에 대한 성능 지표인 RMSE와 MAE 관점에서, 제안한 모델이 FitRec과 비교하여 성능이 향상된 것을 확인하였다. 또한, LSTM 기반 모델이 GRU 기반 모델과 비교하면 향상된 성능을 보이는 것을 확인하였다.

추후 연구로는 더 다양한 feature 들을 추가하는 것을 생각해볼 수 있다. 심박수와 연관된 키, 몸무게, 나이 등의 사람의 신체적인 특징정보를 추가함으로써 각각의 지

표들이 더 향상될 수 있을 것으로 예상된다.

본 논문에서 제안한 방식은 미래의 심박수를 예측하여 예측한 심박수를 토대로 사용자의 운동 강도를 추천하는데 활용할 수 있다.

References

- [1] S. W. Lee, J. Lee, S. Y. Moon, et al "Physical activity and the risk of SARS-CoV-2 infection, severe COVID-19 illness and COVID-19 related mortality in South Korea: a nationwide cohort study," *British Journal of Sports Medicine*, vol. 56, no. 16, pp. 901-912, June 2022.
DOI: <https://doi.org/10.1136/bjsports-2021-104203>
- [2] D. K. Arnett, et al "2019 ACC/AHA guideline on the primary prevention of cardiovascular disease: a report of the american college of cardiology/american heart association task force on clinical practice guidelines," *Circulation*, vol. 140, no. 11, pp. 596-646, Mar. 2019.
DOI: <https://doi.org/10.1161/CIR.0000000000000678>
- [3] J. Ni, L. Muhlstein, and J. McAuley, "Modeling heart rate and activity data for personalized fitness recommendation," *The World Wide Web Conference*, no. 11, pp. 1343-1353, May 2019.
DOI: <https://doi.org/10.1145/3308558.3313643>
- [4] X. Liu, et al "Privacy-preserving personalized fitness recommender system (P3FitRec): a multi-level deep learning approach," *CoRR*, Mar. 2022.
DOI: <https://doi.org/10.48550/arXiv.2203.12200>
- [5] R. Jozefowicz, W. Zaremba, and I. Sutskever, "An empirical exploration of recurrent network architectures," *International Conference on Machine Learning*, vol. 37, no. 9, pp. 2342-2350, July 2015.
DOI: <https://dl.acm.org/doi/10.5555/3045118.3045367>
- [6] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735-1780, Nov. 1997.
DOI: <https://doi.org/10.1162/neco.1997.9.8.1735>
- [7] K. Cho, B. van Merriënboer, D. Bahdanau, and Y. Bengio, "On the properties of neural machine translation: encoder decoder approaches," *Association for Computational Linguistics*, pp. 103-111, Oct. 2014.
DOI: <https://doi.org/10.48550/arXiv.1409.1259>
- [8] C. C. Robusto, "The cosine-haversine formula," *The American Mathematical Monthly*, vol. 64, no. 1, pp. 38-40, Jan. 1957.
DOI: <https://doi.org/10.2307/2309088>
- [9] T. Chai and R. R. Draxler, "Root mean square error (RMSE) or mean absolute error (MAE)? - Arguments against avoiding RMSE in the literature," *Geoscientific Model Development*, vol. 7, no. 3, pp. 1247-1250,


June 2014.

DOI: <https://doi.org/10.5194/gmd-7-1247-2014>

- [10] Rob J. Hyndman and Anne B. Koehler, "Another look at measures of forecast accuracy," International Journal of Forecasting, vol. 22, no. 4, pp. 43-46, May 2006.
DOI: <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- [11] D. Lee, "Cross correlation based signal classification for monitoring system of abnormal respiratory status," Journal of the Korea Academia-Industrial, vol. 21, no. 5, pp. 7-13, May 2020.

저 자 소 개

김 진 욱(준회원)



- 2017년 3월 ~ 현재 : 광운대학교 전자융합공학 학사과정
- 관심분야 : 딥러닝, 디지털통신, 무선통신시스템

김 광 현(준회원)



- 2017년 3월 ~ 현재 : 광운대학교 전자융합공학 학사과정
- 관심분야 : 인공지능, 디지털통신, 영상처리

선 준 호(준회원)



- 2021년 2월 : 광운대학교 전자융합공학 학사 졸업
- 2021년 3월 ~ 현재 : 광운대학교 전자융합공학과 석박사통합과정
- 관심분야 : 딥러닝, 에너지인터넷, 스마트헬스케어, 이상탐지, 스마트 그리드

이 승 우(준회원)



- 2021년 2월 : 광운대학교 전자융합공학 학사 졸업
- 2021년 3월 ~ 현재 : 광운대학교 전자융합공학과 석박사통합과정
- 관심분야 : 인공지능, 스마트 그리드, 에너지 관리 시스템, 차세대이동통신

김 수 현(준회원)



- 2019년 2월 : 광운대학교 전자융합공학 학사 졸업
- 2019년 3월 ~ 현재 : 광운대학교 전자융합공학과 박사과정
- 관심분야 : 인공지능, 전력선통신, 스마트 그리드

김 진 영(정회원)



- 1998년 2월 : 서울대학교 전자공학과 공학박사
- 2001년 2월 : SK텔레콤 네트워크 연구소 책임연구원
- 2001년 3월 ~ 현재 : 광운대학교 전자융합공학과 교수
- 관심분야 : 차세대이동통신, 가시광통신, 전력선통신, 인공지능

※ 본 논문은 문화체육관광부 및 한국콘텐츠진흥원의 2022년도 문화기술 연구개발 사업(과제명: 스포츠 중소제조기업 디지털 전환을 위한 스포츠 데이터 유통연계 제조서비스 기술개발, 과제번호: SR202107001, 기여율: 50%)과 2022년도 광운대학교 우수연구자 지원 사업에 의해 연구되었음