

0. 개요

- (수강 과목) 머신러닝기반의 연구방법론
- (담당교수) 양희정 교수
- (논문 리뷰 과제 발표자) 인공지능전공 장민창 (학번 : 202476634)

1. 논문 정보

- (제목) 실거래가 예측을 위한 텍스트 기반 가격 변동 지수 모델링
- (저자) 이은지
- (연도) 2021년
- (발행기관) 숙명여자대학교 대학원

2. 논문 수집 출처 및 검색 키워드


- (논문 수집 출처) DBpia
- (검색 키워드) 부동산, 자연어

3. 연구 배경

- 기존 부동산 가격예측은 주로 정형 데이터 중심으로 수행되어 시장 심리를 반영하지 못함
- 실제 가격은 정책, 여론, 경기전망, 소비심리 등 비정형 요인의 영향을 크게 받음
- 이에 따라 뉴스·트위터 텍스트를 감성지수로 정량화하고 실거래가 예측에 활용하고자 함

4. 연구 목적

- 부동산 관련 텍스트를 감성적으로 분석하여 일별 감성지수(DNS·DTS)를 산출
- 두 지수를 융합한 DNTS(Daily News-Tweet Sentiment) 가격변동지수를 개발
- DNTS 지수를 정형 데이터와 결합하여 실거래가 예측 모델의 정확도를 실증적으로 평가
- 기계학습 기반 모델의 예측 결과를 SHAP 분석을 통해 해석함으로써 어떤 요인들이 가격 형성에 가장 크게 기여하는지 구조적으로 규명



5. 데이터 구성


- 연구는 서울·부산·세종 세 지역의 2017~2020년 아파트 실거래가 약 54만 건을 기반으로 하며, 거시경제·인구통계·세대 구조 등 주요 정형 데이터를 포함함
- 또한 뉴스 2만여 건과 트위터 4만7천여 건을 수집하여 비정형 텍스트 데이터로 활용함. 텍스트 데이터는 중복 제거, 문장 단위 분리, 불용어 필터링 등 일련의 전처리를 거쳐 감성 분석 모델의 입력으로 사용됨
- 이와 같은 정형·비정형 데이터의 결합을 통해, 시장 심리를 반영한 다층적 예측 모델을 구축

6. 감성사전 구축 및 BERT 기반 감성분석

- 본 연구는 범용 감성사전에 의존하지 않고, 부동산 가격 움직임과 직접적으로 연관된 상승·하락 표현을 중심으로 부동산 도메인 맞춤형 감성사전을 구축
- 상승 관련 어휘는 가격 상승 가능성을 높이는 단어로 분류하고, 하락 관련 어휘는 시장 위축 또는 부정적 상황을 반영하는 단어로 구성
- 이 감성사전을 기반으로 한 라벨링 데이터를 활용하여 BERT 모델을 파인튜닝하였으며, BERT 모델은 문맥적 의미를 고려하여 문장 전체의 분위기를 정밀하게 판단할 수 있음
- 학습 결과는 Accuracy 0.96, AUC 0.97로 매우 우수한 성능을 보였으며, 이를 통해 뉴스·트위터 각각에 대한 일별 감성지수(DNS·DTS)를 계산함

[표 8] BERT를 활용한 감성분류 모델의 성능측정 결과.

	Precision	Recall	F1-Score
하락	0.97	0.92	0.94
상승	0.96	0.99	0.97
Accuracy			0.96



[그림 11] BERT 감성분류 모델의 ROC 그래프.

5. DNTS 가격변동지수 개발 및 분석

- DNS와 DTS는 각각 실거래가와 약 0.3 이상의 양의 상관성을 보였으며, 이는 텍스트 기반 감성이 실제 시장 가격 움직임과 일정 수준 동조함을 의미함.
- 연구에서는 두 지수의 상관성 정도와 정보 기여도를 고려하여 DNTS 지수를 개발하였으며, 이 지수는 단일 지수보다 더 큰 설명력을 가지는 것으로 나타남. DNTS는 부동산 시장 심리의 변화를 일별로 반영하는 가격 변동지수로서, 실거래가 예측에 활용하기 위한 핵심 변수로 사용됨.

6. 기계학습 기반 실거래가 예측 모델

- 예측 모델은 RandomForest, XGBoost, LightGBM, AdaBoost 등 네 가지 트리 계열 모델을 기본으로 하고, 각 모델의 예측값을 1단계 입력으로 활용하는 Stacking Ensemble 구성을 적용함
- 특히 네 모델을 모두 결합한 RXLA 조합은 R^2 0.88 수준으로 가장 높은 설명력을 보였고,

정형 데이터만 사용한 경우보다 모델 성능이 뚜렷하게 개선됨. 이는 DNTS 지수가 실거래가 예측에서 실질적인 설명력 증대 역할을 수행함을 의미함


- 서울·부산·세종 지역별 예측에서도 모두 일정 수준 이상의 성능을 확보하였으며, 지역별 데이터 특성에 따라 예측 오차가 차등적으로 나타나는 점도 확인됨

7. SHAP 기반 변수 중요도 해석

- SHAP 분석 결과, 전용면적, 출생아 수, 건축년도, 혼인 건수 등이 전체적으로 높은 기여도를 보이는 변수로 나타남. 이는 가격 형성에 주택 물리적 특성 + 인구·가구 구조 변수가 동시에 영향을 미친다는 점을 보여줌
- 또한 지역별 분석에서는 변수 유형은 비슷하지만 중요도 순위는 서로 달라, 지역별 수요·공급 구조가 상이하게 작동하고 있음이 드러남. 이는 모델 해석 측면뿐 아니라 지역 맞춤형 부동산 정책 설계에도 활용 가능함

[표 15] 스택킹 모델 결과 비교 분석.

분류	MAE	MSE	RMSE	R^2
LA	0.230944	0.087191	0.295281	0.853879
RA	0.215518	0.077223	0.277690	0.870583
RL	0.217004	0.077836	0.278992	0.869556
RN	0.214511	0.075880	0.275463	0.872834
XA	0.214454	0.074910	0.273698	0.874459
NL	0.217178	0.076660	0.276875	0.871527
RLA	0.214233	0.076359	0.276332	0.872031
RXA	0.209795	0.073187	0.270530	0.877348
RNL	0.212778	0.074814	0.273522	0.87462
NLA	0.21372	0.074423	0.272806	0.875276
RXLA	0.209478	0.072961	0.270113	0.877726



[그림 19] 전체 데이터 Shapley value 결과 Top 20.

8. 결론

- 텍스트 기반 감성지수(DNTS)를 정형 데이터와 결합한 예측 모델은 기존 접근보다 높은 예측력과 현실성을 보여줌
- 특히 뉴스·트위터 감성은 실거래가와 동조하는 경향을 나타내며, 스택킹 모델과 결합할 경우 가격 변화의 방향성과 크기를 보다 정밀하게 설명할 수 있음
- 더불어 SHAP 분석을 통해 부동산 가격 형성 과정에서 인구·가구 구조 요인과 주택 물리적 특성이 동일하게 작용하고 있음을 확인함

9. 한계 및 향후 연구

- 텍스트 데이터를 전국 단위로 수집하여 지역별 심리 차이를 반영하지 못함
- 실거래 신고 시차(lag) 처리가 단순하여 정책 영향 분석에 제약이 있음
- 감성사전 기반 라벨링의 한계가 존재하여 문장 단위 정교 라벨링이 필요함
- 향후 지역별 텍스트 수집, Transformer 기반 시계열 예측 모델 도입, 공간경제모형·그래프 기반 분석 등을 통해 확장 가능함