



# 생성형 AI의 RAG를 활용한 개인 신용대출 부도예측에 대한 연구

A study on predicting default on personal credit loans using RAG of  
generative AI

발 표 자 최 태 양  
소 속 건국대학교 정보통신대학원  
논문저자 김창효, 정재학, 이군희

<http://doi.org/10.35214/rfis.14.1.202502.006>



## 목 차

1. 연구 배경 및 목적
2. 연구 방법 및 설계
3. 실험 결과
4. 결론 및 시사점

# 연구 배경 및 목적

---

## 연구 배경: 신용평가 기술의 진화와 한계

- 기술의 발전: 전통적 통계 기법(로지스틱 회귀)에서 머신러닝(XGBoost, 딥러닝)으로 발전.
- 새로운 시도: 최근 금융권에서 생성형 AI(LLM) 도입 시도 활발.
- 문제점: LLM의 금융 도메인 지식 부족 및 환각(Hallucination) 현상 우려.
- 해결책: 외부 데이터를 검색해 답변의 정확성을 높이는 RAG(검색증강생성) 기술 주목.

## 연구 목적: RAG의 실효성 검증

- 모델 제안: 개인 신용대출 데이터에 RAG 기술을 적용한 새로운 부도 예측 모델 구현.
- 성능 비교: 기존 우수 모델(XGBoost 등)과 RAG 기반 모델의 예측 성능 비교 분석.
- 핵심 타겟: 데이터가 부족한 '썸파일러(Thin-filer)' 심사에서 RAG가 대안이 될 수 있는지 검증.

# 연구 방법 및 설계

## 정형 데이터 RAG 구축

- 텍스트 분할(Chunking) 없이 각 관측치 (Row)를 하나의 청크로 벡터화하여 DB 구축.
- 테스트 데이터 입력 시 벡터 DB에서 가장 유사한 Top-k개(30개) 사례 검색.


## 이원화된 예측 모델 제안

1. **RAG 기반 예측 모델:** LLM 없이, 검색된 유사 사례의 가중 유사도 (Look-alike Model)를 계산하여 부도 확률 직접 산출.
2. **RAG-LLM 결합 모델:** 검색된 유사 사례를 맥락(Context) 정보로 프롬프트에 제공하여, **GPT-4/Llama 3**가 최종 부도 여부 판단.

## 실험 데이터 구성

- **Lending Club** 데이터 약 2.1만 건(일반 환경) 및 500건(실파일러 환경) 별도 구성하여 비교 실험.

[그림 2] RAG 아키텍처를 활용한 생성형 AI 구조



[그림 3] 예측모델 방법론별 RAG활용



[그림 4] 프롬프트 예시

```
template = ""
You are an expert in financial loan prediction. Based on the
following customer data, predict whether the loan status will be 1
(default) or 0 (non-default).

Question: {question}
Context: {context}

Answer (0 or 1):
""
```

# 실험 결과 1: 일반 데이터 환경

## ■ 실험 조건

- 데이터 : Lending Club 데이터 중 학습 21,317건 / 테스트 1,000건 (데이터 풍부).
- 비교 대상 : 기존 머신러닝 (로지스틱, XGBoost, MLP) vs RAG 기반 모델.


## ■ 주요 결과: 기존 머신러닝 모델의 우위

- 전통적 모델이 우세 : 로지스틱 회귀(AUC 0.82)와 XGBoost(AUC 0.82)가 가장 높은 예측 성능을 기록함.
- RAG 모델의 한계 : RAG 기반 모델 중 가장 성능이 좋은 \*\*Look-alike Model(LAM)\*\*도 AUC 0.75에 그쳐, 기존 모델 대비 성능이 낮게 나타남.
- 원인 분석 : 데이터가 충분히 많은 환경에서는 기존 머신러닝 모델이 변수 간의 복잡한 상관관계를 학습하는 데 더 효과적임.

[표 4] RAG 기반 부도 예측모델 성능 결과

| 평가 지표   | 기존 방법론        |               |         | RAG 기반 방법론 |              |               |
|---------|---------------|---------------|---------|------------|--------------|---------------|
|         | 로지스틱 회귀       | XG Boost      | 다층 퍼셉트론 | 임베딩 모델     |              | LAM           |
|         |               |               |         | open AI    | hugging face |               |
| AUC(↑)  | 0.8205        | <b>0.8240</b> | 0.8120  | 0.6130     | 0.6284       | <b>0.7546</b> |
| RMSE(↓) | <b>0.3276</b> | 0.3284        | 0.3336  | 0.3750     | 0.3690       | <b>0.3484</b> |

[그림 5] RAG 기반 방법론과 기존 방법론 AUC 지표



## 실험 결과 2: 씬파일러 (Thin-filer) 환경


### ■ 실험 조건

- 데이터: 학습 데이터를 **500건으로 극단적으로 줄여**, 금융 이력이 부족한 씬파일러 환경을 가정.
- 변수: 가용 정보가 적은 상황을 고려해 설명 변수도 9개로 축소.

### ■ 주요 결과: RAG 기반 모델의 역전

- 기존 모델 성능 급락: 학습 데이터가 줄자 XGBoost의 AUC가 0.82 → 0.59로 급격히 저하됨.
- RAG 모델의 안정성: 반면 RAG(HuggingFace 임베딩) 모델은 AUC 0.69를 기록하며 XGBoost를 크게 상회함.
- 시사점: 데이터가 부족한 환경에서는 통계적 학습보다 유사 사례 참조(RAG) 방식이 더 강력한 예측 성능을 발휘함.

[그림 7] 데이터 그룹2의 기존 vs. RAG 기반 방법론 AUC 지표



## 실험 결과 3: RAG-LLM 결합 및 시사점

[표 5] RAG 및 LLM 결합 부도 예측모델 성능 결과

| 평가 지표        | 기존 방법론  |          |               | RAG 및 LLM 결합 방법론 |                   |               |
|--------------|---------|----------|---------------|------------------|-------------------|---------------|
|              | 로지스틱 회귀 | XG Boost | 다층 퍼셉트론       | 임베딩 모델           |                   | LAM/ Llama3.0 |
|              |         |          |               | open AI/ GPT-4   | hugging/ Llama3.0 |               |
| 정밀도 (↑)      | 0.6500  | 0.6912   | <b>0.7083</b> | 0.2725           | 0.2633            | 0.2951        |
| 재현율 (↑)      | 0.3059  | 0.2765   | 0.3000        | <b>0.6588</b>    | 0.4647            | 0.3176        |
| F1-Score (↑) | 0.4160  | 0.3950   | <b>0.4215</b> | 0.3855           | 0.3362            | 0.3059        |

### ■ RAG-LLM 결합 모델 (GPT-4/Llama 3) 결과

- 성능 저조: 검색된 정보를 LLM에게 주고 판단하게 했을 때, F1-Score 0.38(GPT-4)로 기존 MLP(0.42)보다 낮은 성능을 보임.
- 원인: 범용 LLM은 텍스트 처리에 강점이 있으나, 금융 도메인의 정형 데이터 패턴을 파악하는 능력은 아직 부족함.

### ■ 종합 결론

- 일반 환경: 데이터가 풍부할 때는 여전히 **XGBoost** 등 기존 머신러닝 이 최적.
- 특수 환경 (실파일러): 금융 데이터가 부족할 때는 **RAG 기반 모델** 이 효과적인 대안.
- 향후 과제: 금융 특화 LLM(FinBERT 등) 도입 및 파인튜닝을 통해 정형 데이터 이해도 향상 필요.

# 결론 및 시사점

## 연구 요약: 데이터 환경에 따른 성능 차이

- **일반 환경 (Data-Rich):** 대량의 학습 데이터가 존재할 경우, 변수 간 복잡한 패턴 학습에 최적화된 기존 머신러닝(XGBoost 등)이 여전히 우수한 성능을 보임.
- **썬파일러 환경 (Data-Scarce):** 학습 데이터가 부족한 상황에서는 **RAG 기반 모델**이 기존 모델보다 안정적이고 높은 예측력을 발휘함.

## 주요 시사점

- **RAG의 역할 재정의:** RAG는 기존 신용평가 모델을 완전히 대체하기보다는, 데이터가 부족한 **금융 소외 계층 (Thin-filer)** 평가를 보완하는 **효과적인 대안**으로 활용 가능.
- **범용 LLM의 한계:** 범용 모델은 금융 도메인 지식 부족과 정형 데이터 처리의 한계로 인해, 별도 튜닝 없이는 신용평가에 즉시 적용하기 어려움

**한 줄 요약:** 고정된 단일 모델이 아닌 데이터 특성과 환경에 따라 가장 적합한 **AI 기법**을 유연하게 선택 및 적용해야 함을 실증적으로 보여준다.



—

Q&A  
감사합니다