

[1] “머신러닝을 활용한 내부 정보 유출 정황 탐지 연구”에 대한 리뷰 보고서, 정경서

1. 서론

검색한 논문은 ‘머신러닝을 활용한 내부 정보 유출 정황 탐지 연구(최현석 / 2026년 2월 / 중앙대학교 보안 대학원 산업융합보안학과 석사학위논문)’으로 DBpia에서 ‘머신러닝 정보 유출’ 키워드로 검색하였다.

AI 기술의 발달과 함께 업무 환경이 다변화되면서 정보 유출의 통로와 위험성은 더욱 높아지고 있다. 특히 외부 해킹보다 기업 기밀 등 내부 정보 유출이 초래하는 피해 규모가 치명적임에도, 기존 임계치 기반 보안 시스템의 한계가 명확하여 머신러닝을 활용한 효과적인 대응 및 실무적 탐지 방안이 필요하다고 생각하여 본 논문을 선정하였다.

2. 연구 개요

전 세계적으로 내부자 위협이 증가하고 있으나, 소수의 보안 인력이 하루 수백만 건의 로그를 실시간 분석해 유출을 적시에 탐지하기는 불가능에 가깝다. 또한, 기존의 많은 연구가 제한된 가상 데이터(CERT)를 활용하는 데 그쳐 실제 기업의 복잡한 환경을 반영하지 못하는 한계가 있다.

본 연구는 실제 기업 환경에서 내부 정보 유출 탐지에 가장 적합한 머신러닝 분류 모델을 제시하고, 유출 정황 판단에 중요한 특성(Feature)을 설명 가능한 인공지능(XAI)을 통해 해석하며, 지속 가능한 탐지 방안을 모색하는 것을 목적으로 한다.

이기종 보안 시스템 로그 수집 및 통합 → 데이터 전처리(이상값 처리 및 3단계 교차 검증을 통한 레이블링) → 탐색적 데이터 분석(EDA) → 머신러닝 모델 적용(불균형 처리 및 6개 분류 모델 비교) → 최적 모델 선정 및 교차 검증 → XAI(SHAP)를 활용한 결과 분석의 순서로 진행되었다.

3. 데이터

3.1 데이터 종류

국내 대기업의 3개 보안 시스템(DRM 문서보안, EDLP PC정보유출방지, 메일 시스템) 로그 사용

3.2 데이터 건수

대상자 총 8,839명(퇴사자), 행위 로그 28,707,206건

3.3 수집 방법

2024년 7월부터 2025년 6월까지 총 1년간 발생한 실제 퇴사자의 이기종 보안 시스템 로그 수집

3.4 전처리 방법

서로 다른 형식의 로그를 공통 형식(사용자 ID, 시간, 행위 유형 등)으로 변환하여 사용자 단위로 통합했다.

결측치 및 이상값을 처리한 후, 실제 유출 사건 기록과 객관적 증거를 결합한 ‘3단계 검증 프로세스’를 통해 종속변수(Leak)를 레이블링했다. (유출 정황 있음 613명, 없음 8,226명)

4. 모델 분석

불균형 데이터 처리의 경우 유출 정황이 극소수인 데이터 불균형(약 6.9%)을 해소하기 위해 일반 SMOTE가 아닌, 유출과 정상의 경계 데이터만 집중적으로 보강하는 ‘BorderlineSMOTE’ 기법을 적용했다.

의사결정나무(DecisionTree), 랜덤 포레스트(RandomForest), 엑스트라 트리(Extra Trees), 그래디언트 부스팅(GradientBoosting), XGBoost, LightGBM 총 6개의 머신러닝 모델을 구축하여 성능을 비교 분석했다.

유출 정황 누락(미탐)을 방지하기 위해 재현율(Recall)을 최우선 평가지표로 삼았으며, 원본 데이터 검증 결과 재현율 0.7787과 정밀도 0.6552로 가장 균형 잡힌 성능을 보인 ‘RandomForest’를 최종 모델로 선정하였다.

5. 결론

최종 선정된 RandomForest 모델은 50개의 폴드 교차 검증에서도 매우 낮은 표준편차로 강건성을 입증했다. 특히 SHAP 및 SHAP Feature Dependence 분석을 통해 출력(Print), 네트워크 전송, 외부 클라우드 업

로드 등의 행위가 일정 임계치를 넘을 때 강한 유출 신호로 작용함을 시각적으로 증명했다.

본 연구는 가상 데이터가 아닌 실제 기업의 2,800만 건 방대한 로그를 분석했다는 점에서 실무적 가치가 매우 뛰어난 실증 연구이다. 보안 도메인의 특성을 정확히 이해하여 '오탐'이 다소 늘더라도 치명적인 '미탐'을 막기 위해 재현율(Recall)을 최우선 지표로 삼은 점이 탁월하다. 또한 블랙박스 모델의 결과만 제시하는 것을 넘어, XAI(SHAP) 기술을 통해 어떤 행위가 위험도를 높였는지 투명하게 시각화하여 현업 보안 담당자에게 명확한 조사 가이드를 제공한 점이 가장 큰 장점이다.

다만 1년 누적 행위 횟수를 Feature로 사용하다 보니, 퇴사 직전에 일어나는 특정 시점의 급격한 이상 행동 등 '시계열적 맥락'을 포착하는 데에는 한계가 보인다. 향후 LSTM 등 시계열 머신러닝 모델을 도입하여 시간적 흐름까지 학습하게 된다면, 보다 빈틈없고 강력한 내부 정보 유출 방어 체계로 고도화될 수 있을 것으로 평가된다.

[2] “전자결제 사기 탐지를 위한 신뢰도·시간 가중치 결합 부스팅 모델”에 대한 리뷰 보고서, 이지민

1. 서론

본 보고서는 유승연의 석사학위논문 “전자결제 사기 탐지를 위한 신뢰도·시간 가중치 결합 부스팅 모델”을 분석 대상으로 선정하였다. 해당 논문은 서강대학교 AI.SW대학원 데이터사이언스·인공지능 전공 석사학위논문이며, 발행연도는 2026년, 학위수여년월은 2026년 2월이다.

논문 검색은 DBpia, RISS, dCollection 등 국내 학술자료 검색 사이트를 기준으로 진행하였다. 검색 조건은 최근 논문(2025~2026년), 석·박사 학위논문, 키워드는 “머신러닝”, “XGBoost”, “LightGBM”, “CatBoost”, “전자결제 사기 탐지”, “불균형 데이터”, “라벨 지연”으로 설정하였다. 이 논문을 선택한 이유는 머신러닝 모델이 명확히 제시되어 있고, 데이터셋·평가지표·실험 결과가 보고서 항목에 맞게 구체적으로 정리되어 있기 때문이다.

키워드는 전자결제 사기 탐지가 대표적인 불균형 분류 문제이며, 실제 운영 환경에서는 사기 여부가 늦게 확정되는 라벨 지연 문제가 성능에 영향을 줄 수 있다는 점을 고려하여 선정하였다. 또한 XGBoost, LightGBM, CatBoost는 정형 데이터 기반 예측 문제에서 널리 활용되는 부스팅 모델이므로 머신러닝 모델 분석 과제에 적합하다고 판단하였다.

2. 연구 개요

이 연구의 필요성은 전자결제 사기 탐지에서 발생하는 라벨 지연 문제에서 출발한다. 전자결제 거래는 거래 발생 시점과 실제 사기 여부가 확정되는 시점 사이에 시간 차이가 생길 수 있다. 이때 최신 거래 데이터에 아직 확정되지 않은 라벨이 포함되면 모델 학습 과정이 왜곡되고, 결과적으로 사기 거래 탐지 성능이 낮아진다.

연구 목적은 기존 부스팅 모델의 구조를 크게 바꾸지 않으면서, 라벨의 신뢰도와 거래 시점의 중요도를 동시에 반영하는 가중치 기반 학습 방법을 제안하는 데 있다. 이를 위해 논문은 Proxy Label 기반 신뢰도 가중치와 시간 감쇠 가중치를 결합하여 XGBoost, LightGBM, CatBoost 모델에 적용하였다.

수행 절차는 다음과 같이 정리할 수 있다. 첫째, 전자결제 사기 탐지에서 라벨 지연이 모델 성능에 미치는 문제를 정의하였다. 둘째, 라벨의 확정 가능성과 불확실성을 반영하기 위해 Proxy Label 기반 신뢰도 가중치를 설계하였다. 셋째, 사기 패턴이 시간에 따라 변한다는 점을 반영하기 위해 최근 거래에 더 높은 중요도를 주는 시간 가중치를 적용하였다. 넷째, 세 가지 부스팅 모델에 동일한 가중치 구조를 적용하여 성능을 비교하였다. 마지막으로 AUPRC, F1-score, 추론시간, Ablation Study를 통해 제안 방법의 효과를 검증하였다.

3. 데이터

논문에서 사용한 데이터는 IEEE-CIS Fraud Detection 데이터셋이다. 이 데이터는 전자결제 거래의 사기 여부를 예측하기 위한 공개 벤치마크 데이터셋이며, 거래 관련 변수와 사용자·기기·결제 환경 관련 변수를 포함하는 정형 데이터로 볼 수 있다. 전체 데이터 규모는 약 636만 건이고, 사기 거래 비율은 약 3.5%로 제시되어 있다.

데이터 수집방법은 실제 금융기관 내부 데이터의 직접 수집이 아니라, 공개된 Kaggle Competition 데이터셋을 활용한 방식이다. 따라서 연구는 동일 데이터셋을 기준으로 다양한 모델의 성능을 재현·비교하기에는 적합하지만, 실제 금융기관의 운영 환경을 완전히 반영한다고 보기는 어렵다.

전처리 과정은 결측값 처리, 범주형 변수 처리, 사기-정상 거래의 분포 확인, 파생 변수 생성, 시간 구간별 학습 데이터 구성으로 정리할 수 있다. 특히 이 논문은 단순히 전체 데이터를 한 번에 학습하는 방식이 아니라, 거래 시점과 라벨 신뢰도에 따라 학습 샘플의 영향력을 다르게 주는 점이 특징이다. 또한 W_days 값을 조정하여 과거 거래 데이터를 어느 기간까지 활용할 때 성능과 운영 효율이 균형을 이루는지 비교하였다.

4. 모델 분석

논문에 포함된 머신러닝 모델은 XGBoost, LightGBM, CatBoost이다. 세 모델은 모두 그래디언트 부스팅 계열의 앙상블 모델로, 여러 개의 약한 결정트리를 순차적으로 학습시키면서 이전 모델의 오차를 보완하는 방식으로 예측 성능을 높인다.

XGBoost는 정규화와 병렬 처리 기능을 갖춘 대표적인 부스팅 모델로, 정형 데이터 분류 문제에서 강한 성능을 보인다. LightGBM은 대용량 데이터 처리와 빠른 학습 속도에 강점이 있어 실무 환경에서 많이 사용된다. CatBoost는 범주형 변수 처리에 강점을 가진 부스팅 모델로, 전자결제 데이터처럼 범주형 특성이 많은 데이터에서 활용 가치가 있다.

본 논문의 핵심은 세 모델 자체를 완전히 새로 만드는 것이 아니라, 기존 부스팅 모델의 구조는 유지하면서 손실 함수 또는 샘플 가중치 수준에서 신뢰도 가중치와 시간 가중치를 적용하는 점이다. 신뢰도 가중치는 라벨의 불확실성을 반영하여 더 신뢰할 수 있는 데이터가 학습에 더 큰 영향을 주도록 한다. 시간 가중치는 최신 거래 데이터에 더 큰 중요도를 부여하여 시간이 지남에 따라 변화하는 사기 패턴을 반영한다. 따라서 이 연구는 복잡한 딥러닝 모델보다 해석 가능성과 운영 효율성이 높은 부스팅 모델을 개선한 실무형 머신러닝 연구로 볼 수 있다.

5. 결론

실험 결과, 세 부스팅 모델 중 LightGBM이 가장 우수한 성능을 보였다. 특히 $W_days=60$ 조건에서 AUPRC 0.6218, F1-score 0.5153, 추론시간 43.67초를 기록하였다. Ablation Study에서는 신뢰도 가중치가 성능 향상에 핵심적인 역할을 했고, 시간 가중치는 약 1% 내외의 보조적 개선 효과를 제공한 것으로 제시되었다. 또한 60일 구간에서 이미 최적에 가까운 성능에 도달했으며, 90일로 확장했을 때 추가 개선 폭은 크지 않았다.

이 결과는 약 60일의 과거 거래 데이터만으로도 효율적인 모델 운영이 가능하다는 실무적 기준을 제시한다는 점에서 의미가 있다. 본인이 생각한 이 논문의 특징은 실제 전자결제 환경에서 자주 발생하는 라벨 지연 문제를 단순한 이론적 문제가 아니라 모델 운영상의 현실적 문제로 다루었다는 점이다. 또한 기존 부스팅 모델의 구조를 크게 바꾸지 않고 가중치 설계를 통해 성능을 개선하려 했기 때문에 실제 시스템에 적용하기 쉽다는 장점이 있다.

다만 공개 데이터셋 기반 실험이므로 실제 금융기관의 실시간 운영 환경, 비용 민감도, 임계값 설정, 오탐에 따른 고객 불편 등을 추가로 검증할 필요가 있다. 종합적으로 이 논문은 성능 향상과 실무 적용 가능성을 함께 고려한 머신러닝 모델 개선 연구라고 평가할 수 있다.

[3] “AI 기반 진로상담 챗봇 설계 실습을 위한 실행연구: 대규모 언어모델(LLM)을 중심으로”에 대한 리뷰 보고서, 이우진

1. 서론

최근 생성형 AI와 대규모 언어모델(LLM)의 발전으로 다양한 분야에서 AI 챗봇 활용이 확대되고 있다. 특히 전문 분야에서도 생성형 AI를 활용한 맞춤형 서비스에 대한 관심이 증가하고 있는 추세이며, 이에 따라서 AI 챗봇의 실제 활용 가능성과 교육적 효과를 검증하는 연구들이 활발히 진행되고 있다. 본 보고서에는 DBpia를 통해서 검색한 “AI 기반 진로상담 챗봇 설계 실습을 위한 실행연구: 대규모 언어모델(LLM)을 중심으로”를 분석하였다. 해당 논문은 비교적 최근인 2026년 02월에 발표하였으며, 상담 분야에서의 생성형 AI와 LLM을 활용한 진로상담 챗봇 설계 및 교육 효과를 다루고 있다. 논문 검색은 DBpia 학술 데이터베이스를 활용하였으며 ‘생성형 AI’, ‘AI 챗봇’등의 키워드를 사용하였다. 이러한 키워드들은 최근 인공지능 기술의 핵심 분야중 하나이며 실제 교육적 활용 사례를 조사하기 위해서 선정하였다. 특히 상담 분야는 전문적인 지식뿐만 아니라 공감 능력 및 의사소통 능력이 요구되는 영역이므로, AI가 이러한 분야에서 어떠한 역할을 수행할 수 있는지 분석하고자 본 논문을 선정하였다.

2. 연구 개요

최근 생성형 AI와 대규모 언어모델(LLM)의 발전으로 다양한 분야에서 AI 챗봇 활용이 확대되고 있다. 특히 교육 분야에서도 생성형 AI를 활용한 학습 지원 및 상담 서비스에 대한 관심이 높아지고 있으나, 실제 교육 현장에서 학습자가 AI 챗봇을 직접 설계하고 활용하는 경험에 대한 연구는 상대적으로 부족하다. 또한 진로상담 분야는 단순한 정보 제공을 넘어서서 사용자의 현재 상황을 확실히 이해하고 이에 따른 적절한 조언을 제공해야하는 전문성이 요구되기 때문에 생성형 AI의 활용 가능성을 검증할 필요가 있다. 이러한 배경에서 본 논문은 AI기반의 진로상담 챗봇 설계 실습이 학습자에게 어떠한 교육적 효과를 제공하는지 분석하고자 수행되었다. 본 연구의 목적은 진로상담 챗봇 설계 실습 과정을 교육 현장에 적용하고, 학습자의 AI 활용 능력 향상과 상담 역량 개발에 미치는 영향을 분석하는 데 있다. 또한 생성형 AI 챗봇을 직접 설계하고 평가하는 과정을 통해서 AI 기술의 교육적 활용 가능성과 한계점을 탐색하고자 하였다. 이를 위해서 해당 연구에서는 수업에 참여한 학습자들을 대상을 설계 실습을 진행하였다. 학습자들은 LLM 기반 플랫폼을 활용하여 직접 진로상담 챗봇을 설계하고 프롬프트를 작성하는 과정을 수행하였다. 이후에는 사용자 경험 평가와 개선과정을 반복적으로 수행하였으며, 연구자는 결과물과 경험 데이터들을 수집하여서 분석하였다. 이를 통해서 생성형 AI 챗봇 설계 과정에서 나타나는 학습 효과와 교육적 시사점을 도출하였다.

3. 데이터

해당 연구에서는 LLM 기반 AI 진로상담 챗봇 설계 실습 과정에서 생성된 다양한 참여 경험 자료를 데이터로 활용하였다. 연구 참여자들은 대학 정규 교과에서 생성형 AI와 대규모 언어모델(LLM)을 활용하여 진로상담 챗봇을 직접 설계하였으며, 이 과정에서 생성된 프롬프트 작성 내용, 대화 태스크 구성 자료, 사용자 경험(UX) 평가 결과, 챗봇 개선 과정 기록 등이 주요 분석 자료로 수집되었다. 데이터 수집은 AI 진로상담 챗봇 설계 실습 과정 전반에 걸쳐 이루어졌다. 학습자들은 노코드(No-Code) 기반의 LLM 플랫폼을 활용하여 챗봇을 설계하였으며, 프롬프트 설계, 대화 시나리오 구성, 사용자 평가 및 개선 과정을 반복적으로 수행하였다. 연구자는 이러한 실습 과정에서 생성된 결과물과 참여 경험 자료를 수집하여 학습자의 인식 변화와 교육적 효과를 분석하였다. 수집된 자료는 질적 연구 방법에 따라 분석되었다. 연

구자는 참여자들의 활동 기록과 성찰 내용을 반복적으로 검토하고, 유사한 의미를 갖는 내용을 범주화하여 분석을 수행하였다. 그 결과 총 6개의 상위 범주, 17개의 하위 범주, 48개의 의미 단위가 도출되었으며, 이를 바탕으로 생성형 AI 챗봇 설계 과정에서 나타난 학습자의 경험과 교육적 효과를 체계적으로 분석하였다.

4. 모델 분석

이 논문에서 사용된 머신러닝 모델은 LLM 기반 생성형 AI 모델이다. 본 논문에서는 특정 머신러닝 알고리즘의 성능을 비교하거나 학습시키는 연구가 아니라, 이미 학습된 LLM을 활용하여 학습자들이 진로상담 챗봇을 설계하고 평가하는 과정을 연구하였다. 학습자들은 프롬프트 엔지니어링을 통해 챗봇의 역할과 응답 방식을 설계하였으며, 이를 기반으로 상담 시나리오를 구현하였다. LLM은 입력된 문장의 문맥을 바탕으로 다음 단어를 예측하는 방식으로 동작한다. 이러한 특성 덕분에 인간과 유사한 자연어 대화가 가능하며, 진로상담과 같은 대화형 서비스에 효과적으로 활용될 수 있다. 그러나 학습 데이터에 존재하는 편향(Bias)이나 사실과 다른 정보를 생성하는 환각(Hallucination) 현상이 발생할 수 있다는 한계도 존재한다. 따라서 본 연구는 LLM 자체의 성능을 평가하기보다는, LLM 기반 생성형 AI 챗봇을 교육 현장에 적용했을 때 나타나는 학습 효과와 활용 가능성을 분석한 연구라고 볼 수 있다.

5. 결론

해당 논문은 대규모 언어모델(LLM)을 기반으로 한 생성형 AI 챗봇 설계를 적용하고, 학습자의 참여 경험 및 교육효과를 분석하였다. 연구 결과, 학습자들은 별도의 코딩 없이 생성형 AI 챗봇을 설계할 수 있었으며 대화 및 프롬프트 작성을 통해 AI활용 역량이 향상된 것으로 보여졌다. 또한 진로상담 과정에서 필요한 공감, 질문 능력이 챗봇 개발과정과 밀접하게 연결되어 있음을 확인하였다. 연구 참여자들은 직접 설계하고 개선하는 과정을 통하여 AI를 단순한 도구가 아닌 상담 지원도구의 일종으로 인식하였으며 개인 정보 보호와 관련된 생성형 AI의 한계점을 같이 인식한 것으로 보여졌다. 해당 논문의 가장 큰 특징으로는 단순히 AI를 사용하는 것이 아닌, 학습자가 직접 설계 및 평가하도록 구성된 '실행연구'라는 점이다. 기존의 연구들이 활용 여부, 만족도를 중심으로 분석한 것과 달리, 프롬프트 설계 및 UI/UX 평가를 포함한 실제 챗봇 개발 과정을 다루었다는 점에서 차별성이 있다. 해당 논문에 대한 긍정적인 평가로는 비교적 최근 연구로서 생성형 AI 및 LLM 기술을 실제 교육환경에 적용하였다는 점에서 연구가치가 높다. 또한 이론중심이 아닌 실습 중심 연구를 수행하는 점에서 학습자의 실제 경험과 변화를 분석하였으며 AI 활용 능력뿐 아니라 상담 역량과 인간 중심적 사고의 중요성을 함께 다루어서 기술과 인간의 협력 가능성을 보여주었다. 반면에 해당 논문에 대해 아쉬운 점으로는 연구 대상이 특정 교육 환경에 한정되어 있어서 연구 결과를 모든 교육현장에 일반화하는 데에는 다소 어려움이 있으며, 기간이 비교적 짧기 때문에 장기간 학습 효과나 실제 상담 현장에서의 활용 효과를 충분히 검증하지 못하였다는 점이다. 본 논문은 단순히 생성형 AI를 사용하는 점에서 벗어나서 학습자들이 직접 LLM 기반 챗봇을 설계하고 개선하도록 구성되었다는 점에서 의미가 크다고 생각한다. 특히 AI의 활용 능력과 상담 역량을 함께 향상시킬 수 있다는 점은 기존의 교육 방식과 차별화 되는 부분이라고 생각한다. 향후 연구에서는 RAG 기술과 실제 진로 상담 데이터베이스를 결합하여 생성형 AI 챗봇의 응답 정확도 및 신뢰성을 향상시키는 방향이 필요할 것으로 보인다. 또한 상담 분야의 특성을 고려해보면 전문 상담사와 생성형 AI의 정보처리 능력을 결합한 '하이브리드 상담 모델'에 대한 후속 연구가 지속적으로 수행될 필요가 있다고 생각한다.

[4] “지역화폐 이상거래 탐지를 위한 머신러닝 모델 성능 비교”에 대한 리뷰 보고서, 서민이

1. 서론

지역화폐는 특정 지역 내에서만 통용되는 대안화폐의 한 종류로 전 세계적으로 지역 경제 순환을 촉진하는 수단으로 활용되고 있다. 해외에서는 주로 지역 공동체 중심의 비영리 기반으로 운영되고 있으나 국내에서는 정부 주도하에 경제 활성화 및 복지 정책의 일환으로 도입되어 빠르게 확산되었다. 특히 경기도의 청년배당을 시작으로 여러 지방자치단체가 지역사랑상품권을 발행하며 시민들을 위한 실질적인 금융 인프라로 자리 잡았다. 전국 지자체를 통해 판매된 지역화폐는 2021년 이후부터 매년 20조 이상으로 집계되며 실제 사용자들의 적극적인 사용 사례가 보도되었다. 그러나 지역화폐의 긍정적 효과 이면에 ‘부정거래’라는 그림자가 존재한다. 부정거래란 할인된 가격에 구매한 지역화폐를 현금화하는 부정유통 행위나 실제 재화의 판매 또는 용역 제공 없이 거래를 위장하여 부당이익을 취하는 행위이다. 행정안전부가 발표한 ‘2024년 상반기 지역사랑상품권 일제단속 결과’에 따르면 부정유통 적발 사례는 꾸준히 증가하고 있으며, 특히 부정수취와 불법환전의 비중이 높아지는 추세이다. 이에 각 지자체는 특별 점검을 강화하고 이상거래 탐지 시스템(Fraud Detection System; FDS)을 도입하여 대응하고 있으나 그 실효성에는 여전히 한계가 있다[6]. 기존의 규칙 기반 FDS는 사전에 정의된 시나리오에 의존하기 때문에 이를 교묘히 회피하는 새로운 유형의 부정거래를 탐지하기 어렵다. 알려진 부정행위 적발에는 유용하지만 진화하는 사기 수법을 따라잡기에는 역부족이다. 또한 국내 지역화폐 연구는 주로 경제적 파급효과나 정책적 영향 분석과 같은 거시적 관점에 치중되어 있어 데이터 기반의 이상거래 탐지 연구가 필요하다. 본 연구는 데이터 주도적 접근을 통해 지역화폐 이상거래 탐지 방안을 다음과 같이 제안한다. 라벨이 없는 공공 데이터로부터 신뢰성 있는 이상거래 패턴을 식별하기 위해 비지도학습과 지도학습을 결합한 2단계 머신러닝 학습 프레임워크를 적용한다. 1단계에서는 비지도학습 알고리즘으로 데이터 내에 잠재된 이상 징후를 탐색하여 pseudo label(의사라벨)을 생성한다. 2단계에서는 pseudo label을 기반으로 다양한 지도학습 모델을 훈련한 후 성능을 비교하여 지역화폐 데이터의 특성에 적합한 이상거래 탐지 모델을 도출한다. 지역화폐 부정거래 방법이 다양해짐에 따라 본 연구는 지도학습과 비지도학습을 결합한 이상거래 탐지 프레임워크를 사용하여 사전에 정의된 규칙만으로는 발견하기 어려운 신규 이상 징후를 선별한다. 라벨이 없는 데이터에 pseudo label을 생성하여 이상거래를 탐지하고 개인 거래내역이 아닌 집계 데이터만으로도 탐지가 가능함을 입증한다. 이를 통해 알려지지 않은 지역화폐 부정거래로 인한 피해를 감소시키는 데 실질적으로 기여하고자 한다.

2. 연구 개요

2.1 지역화폐 공공데이터 활용 전자정부법에 기반하여 정부는 다양한 행정 데이터를 공공데이터로 개방하고 있다. 각 지자체는 지역화폐의 발행·사용 내역을 월별, 시·군·구 단위로 집계하여 제공하고 있다. 지역화폐의 경제적 효과를 분석하는 연구에 이러한 데이터가 활발하게 활용되어 왔으나 부정거래 탐지 목적의 연구는 부족한 실정이다. 공공데이터는 개인정보보호를 위해 개인 식별자가 제거된 월별 집계 데이터 형태를 띠며, 실제 부정거래 여부를 나타내는 정답 라벨(ground truth label)이 존재하지 않는 데이터 구조적 한계가 있다. 이는 주로 라벨이 있는 데이터를 학습에 사용하여 이상거래를 탐지하는 일반적인 지도학습 모델에 적용하기 어렵다.

2.2 이상탐지 연구머신러닝을 활용한 이상탐지 연구는 다양한 분야에서 활발히 진행되고 있다. 정보통

신 분야에서는 Auto Encoder나 Isolation Forest 등의 비지도학습 모델을 활용하여 네트워크 침입 및 보안 로그의 이상 패턴을 탐지하는 연구가 수행되었고 악성 URL의 특징을 학습 후 분류하는 지도학습 연구도 존재한다. 금융 분야에서도 전통적인 규칙 기반 FDS의 한계를 극복하기 위해 머신러닝 기반의 이상거래 탐지방법을 채택하고 있다. 특히 기업의 거래정보 데이터에 지도학습을 사용하여 알려진 사기 패턴을 분류하고, 알려지지 않은 이상 패턴은 비지도학습으로 발굴하는 하이브리드 기반의 다양한 연구가 진행되고 있다.

2.3 연구의 차별성대부분의 이상거래 탐지 연구는 이상거래로 라벨링된 개별 거래내역 데이터를 사용하지만 본 연구에서는라벨이 없는 집계 데이터를 사용한다는 차이가 존재한다. 거래금액 급증과 같은 이상거래 라벨 정보는 기업의 자산으로 외부에 공개되지 않으며 공공데이터 기반의 지역화폐 연구에 직접 적용하기는 어렵다. 또한 금융감독원에서 권장하는 이상거래 탐지 규칙들은 주로 개인 또는 단말 식별을 전제로 하고 있어 본 연구에서 다루는 집계 데이터 분석에 적합하지 않다. 이러한 문제를 해결하기 위해 라벨이 없는 데이터를 비지도학습으로 분석하여 pseudo label을 생성하고 이를 지도학습에 활용하는 하이브리드 형태의 접근법이 연구되고 있다. 특히 IFC Working Papers에서는 비지도학습 모델인 IF로 pseudo label을 생성하고 이를 지도학습 분류에 사용하여 이상징후를 탐지하는 방법을 제안하였다.본 연구는 이러한 하이브리드 머신러닝 프레임워크를 지역화폐 공공데이터에 적용하고, 한 단계 더 나아가 단일 비지도학습을 사용하는 여러 모델과 이들의 앙상블(Ensemble) 결과를 비교한다. 또한 내부 클러스터 검증 지표를 통해 생성된 pseudo label의 신뢰도를 정량적으로 평가하여 가장 안정적인 pseudo label을 선정한다. 이렇게 선정된 pseudo label을 시간 순서로 구조화된 지역화폐 데이터에 적용하여 이상거래 탐지에 가장 효과적인 지도학습 모델이 무엇인지 체계적으로 비교·분석한다는 점에서 기존 연구와 차별점을 갖는다.

3. 데이터

3.1 데이터 종류

본 연구에서는 경기데이터드림에서 제공하는 경기도 지역화폐 공공데이터를 사용하였다. 데이터는 월별 지역화폐 발행액, 사용액, 가맹점 정보, 행정동 단위 거래내역 등으로 구성되어 있으며 개인 식별정보는 포함되어 있지 않은 집계 데이터이다.

3.2 데이터 수집 방법

경기데이터드림 공공데이터 포털을 통해 지역화폐 관련 데이터를 수집하였다. 행정동 코드, 가맹점 정보, 월별 거래내역 데이터를 통합하여 분석용 데이터셋을 구축하였다.

3.3 데이터 전처리

데이터 전처리 과정에서는 다음과 같은 특징 변수를 생성하였다.

- 가맹점당 유입액
- 가맹점당 유출액
- 3개월 이동평균 대비 유입액 비율
- 규모 보정 변수
- Z-Score 표준화

이를 통해 지역별 규모 차이를 보정하고 시계열적 변동성을 반영하였다.

3.4 데이터 건수

논문에서는 사용 데이터의 정확한 건수는 공개하지 않았으며, 경기데이터드림에서 수집한 행정동 단위 지역화폐 집계 데이터를 활용했다고 설명하고 있다. 따라서 보고서에는 "논문에서 정확한 데이터 건수는

제시되지 않았다"고 작성하는 것이 맞다.

4. 모델 분석

본 연구는 라벨이 존재하지 않는 지역화폐 공공데이터에서 이상거래를 탐지하기 위해 비지도학습과 지도학습을 결합한 하이브리드 머신러닝 프레임워크를 적용하였다. 먼저 비지도학습을 이용하여 이상치를 탐지하고 의사라벨(Pseudo Label)을 생성한 뒤, 이를 지도학습 모델의 학습 데이터로 활용하였다.

4.1 비지도학습 모델

(1) Isolation Forest (IF)

Isolation Forest는 데이터를 무작위로 분할하여 이상치를 탐지하는 알고리즘이다. 정상 데이터는 여러 번 분할해야 고립되지만 이상치는 적은 횟수의 분할만으로 고립되는 특성을 이용한다. 대용량 데이터 처리에 효율적이며 본 연구에서는 이상거래 후보를 탐지하는 데 활용되었다.

(2) Local Outlier Factor (LOF)

LOF는 주변 데이터와의 밀도 차이를 이용하여 이상치를 탐지하는 기법이다. 특정 데이터의 밀도가 주변보다 현저히 낮으면 이상치로 판단한다. 지역적인 특이 패턴을 발견하는 데 효과적이다.

(3) One-Class SVM

One-Class SVM은 정상 데이터의 분포를 학습한 후 해당 경계를 벗어나는 데이터를 이상치로 분류하는 모델이다. 기존에 알려지지 않은 새로운 유형의 이상 패턴을 발견하는 데 적합하다.

(4) Ensemble 모델

본 연구에서는 IF, LOF, One-Class SVM 세 모델의 결과를 결합한 앙상블 기법을 적용하였다. 세 모델 중 2개 이상이 이상치로 판단한 경우 최종 이상거래로 분류하였다. 이를 통해 개별 모델의 편향을 줄이고 더욱 신뢰성 있는 Pseudo Label을 생성하였다. 실험 결과 앙상블 모델이 가장 높은 종합 점수를 기록하였다.

4.2 지도학습 모델

비지도학습 단계에서 생성된 Pseudo Label을 이용하여 다음과 같은 지도학습 모델의 성능을 비교하였다.

- Random Forest(RF)
- XGBoost
- LightGBM
- Decision Tree
- Support Vector Machine(SVM)
- Logistic Regression(LR)

각 모델은 Precision, Recall, F1-Score를 기준으로 평가되었다. 이상치 비율을 1%로 설정한 환경에서는 XGBoost가 가장 높은 F1-Score(0.537)를 기록하였다. 또한 모델별 최적 임계치를 적용한 환경에서는 Random Forest가 가장 높은 F1-Score(0.898)를 기록하여 가장 우수한 성능을 보였다. 특히 Random Forest, XGBoost, LightGBM과 같은 트리 기반 앙상블 모델이 전반적으로 우수한 이상거래 탐지 성능을 나타냈다.

Table. 2 Unsupervised learning Models Evaluation Result (Outlier Ratio: 1%)

Model	Silhouette (↑)	Extremeness (↑)	Cohesion (↓)	Separation (↑)	Mann-Whitney (↓)	Composite Score
IF	0.706	2.099	9.233	8.708	21951910	0.577
LOF	0.353	0.828	5.426	4.166	12523895	0.400
OC-SVM	0.688	1.961	10.338	8.409	18256042	0.578
Ensemble	0.731	2.368	11.027	9.792	14505830	0.758

Table. 3 Unsupervised learning Models Evaluation Result (Outlier Threshold: automatic model setting)

Model	Silhouette (↑)	Extremeness (↑)	Cohesion (↓)	Separation (↑)	Mann-Whitney (↓)	Composite Score
IF	0.664	1.781	8.478	7.555	29639538	0.519
LOF	0.398	0.889	5.930	4.469	7520398	0.400
OC-SVM	0.688	1.961	10.338	8.409	18256042	0.620
Ensemble	0.718	2.242	10.704	9.324	16310903	0.721

Table. 4 Supervised learning Models Evaluation Result (Outlier Ratio: 1%)

1%	Precision	Recall	F1-Score
XGBoost	0.4143	0.7632	0.5370
LightGBM	0.3919	0.7632	<u>0.5179</u>
RF	<u>0.3971</u>	0.7105	0.5094
DT	0.3380	0.6316	0.4404
SVM	0.2037	0.8684	0.3300
LR	0.1372	<u>0.8158</u>	0.2348

Table. 5 Supervised learning Models Evaluation Result (Outlier Threshold: automatic model setting)

Model	Precision	Recall	F1-Score
XGBoost	0.8298	0.9613	0.8907
LightGBM	<u>0.8303</u>	<u>0.9648</u>	<u>0.8925</u>
RF	0.8540	0.9472	0.8982
DT	0.8131	0.9190	0.8628
SVM	0.4722	0.9859	0.6385
LR	0.3865	0.9296	0.5460

5. 결론

본 연구는 비지도학습과 지도학습을 결합한 하이브리드 머신러닝 프레임워크를 통해 라벨이 부재한 지역화폐 공공데이터에서 이상거래를 탐지하는 최적의 모델을 제시하였다. 비지도학습 단계에서 IF, LOF, OC-SVM 및 이들의 앙상블을 활용하여 pseudo label을 생성하고, 내부 검증 지표로 신뢰도를 평가하였다. 그 결과 앙상블 방식이 가장 높은 신뢰도를 보였다. 이후 지도학습 성능 평가에서는 이상치 비율이 제한된 1% 환경에서는 XGBoost가, 자동 임계치 환경에서는 RF가 가장 높은 F1-Score를 기록했다. 이를 통해 복잡한 데이터 패턴의 정밀도와 재현율을 균형 있게 확보함에 있어 트리 기반 앙상블 모델이 가장 효과적임을 나타냈다. 본 연구는 기존의 개별 거래 수준 데이터를 활용한 연구들과 달리 공개된 지역화폐 월별 집계 데이터만으로도 이상거래 탐지가 가능함을 입증하였다. 이는 개별 거래 정보 접근이 어렵거나 개인정보보호 제약이 있는 데이터에 적용가능한 실용적인 접근법이다. 실제 금융분야에서 사용하는 이상거래 탐지 방향과도 일맥상통하며 데이터가 제한적이고 라벨링이 어려운 상황에서도 우수한 성과를 낼 수 있음을 증명하였다는 점에서 실무적 기여가 크다. 본 연구의 pseudo labeling 접근법은 한계를 지닌다. 비지도학습에 의해 생성된 라벨은 실제 부정거래정답 라벨(ground truth label)과 다를 수 있으며 모델의 오탐 가능성을 내포하므로, 실제 시스템 도입 시 FDS 또는 금융보안원에서 제공하는 라벨 기반의 규칙과 병행하여 정확도를 향상시킬 수 있다. 또한 본 연구에 사용된 개별 거래 정보를 이용하지 않는 집계 데이터 기반 방식은 직접적인 세부적인 거래 패턴 탐지에는 한계가 있으나 본 연구 결과를 통해서 집계 데이터만으로도 유의미한 이상거래 탐지가 가능함을 입증하였다.

이 논문은 지역화폐 데이터에 라벨이 없는 상황에서 비지도학습과 지도학습을 결합하여 이상거래를 탐

지했다는 점이 인상적이었습니다.

특히 실제 부정거래 여부를 알 수 없는 공공데이터를 활용하면서도 Pseudo Label을 생성해 학습을 진행한 점이 흥미로웠습니다. 또한 Random Forest, XGBoost와 같은 트리 기반 앙상블 모델이 높은 성능을 보였다는 결과도 확인할 수 있었습니다.

다만 아쉬운 점도 있다고 생각합니다. 논문에서 사용한 정답 데이터는 실제 부정거래 라벨이 아니라 비지도학습 모델이 생성한 Pseudo Label입니다. 따라서 성능이 높게 나타났더라도 실제 부정거래를 얼마나 정확하게 탐지하는지는 검증하기 어렵다고 생각합니다.

또한 월별 집계 데이터만 사용했기 때문에 실제 거래 시점이나 거래 패턴과 같은 세부 정보를 분석하는 데는 한계가 있다고 판단했습니다.

그럼에도 불구하고 개인정보 문제로 실제 거래 데이터를 확보하기 어려운 상황에서 공개 데이터만으로 이상거래 탐지 가능성을 보여주었다는 점은 의미 있는 연구라고 생각합니다. 향후에는 실제 부정거래 라벨이 포함된 데이터를 활용하여 성능을 검증한다면 더욱 실용적인 연구가 될 것이라고 생각합니다.

[5] “머신러닝 기반 고객 이탈 예측과 ERFM을 활용한 플랫폼 비즈니스의 고객 세분화 방법론”에 대한 리뷰 보고서, 박아름

1. 서론

본 보고서가 분석 대상으로 선정한 논문은 김유나 외(2025)의「머신러닝 기반 고객 이탈 예측과 ERFM을 활용한 플랫폼 비즈니스의 고객 세분화 방법론」으로, 2025년 2월 한양대학교 대학원 경영컨설팅학과 경영컨설팅전공에서 수여된 석사학위논문이다(RISS 청구기호 T17195460). 논문 검색은 RISS에서 자료유형을 ‘학위논문’, 발행연도를 최근(2025년)으로 한정하고, ‘머신러닝’과 ‘고객 이탈 예측·고객 세분화’를 키워드로 결합하여 수행하였다. 다만 해당 학위논문은 저작자 요청으로 원문보기가 비공개되어 있어, 세부 수치는 동일 제목·동일 연구를 바탕으로 한 학회 게재본인 김유나 외「머신러닝 기반 고객 이탈 예측과 ERFM을 활용한 플랫폼 비즈니스의 고객 세분화 방법론」(한국경영공학회지 제30권 제2호, 2025.6)을 교차 확인하여 작성하였다.

키워드로 ‘머신러닝’, ‘이탈 예측’, ‘고객 세분화’를 선정하였으며, 그 이유는 다음과 같다. 첫째, 학술·기술적 측면에서 고객 이탈 예측은 로지스틱 회귀, Random Forest, XGBoost 등 다양한 머신러닝 분류 모델이 활발히 적용되는 대표적인 예측 문제이다. 특히 최근에는 단순 이탈 예측을 넘어 고객 가치 평가(RFM·ERFM)와 결합하여 고객 관리 전략으로 확장하는 연구 흐름과도 연결된다. 본 논문은 이 두 축을 통합했다는 점에서 머신러닝 활용 사례로서 분석 가치가 크다. 둘째, 실무적 측면에서 본 주제는 보고서 작성자 본인이 직접 수행한 고객 이탈 예측 및 고객 세분화 프로젝트와도 밀접하게 관련되어 있다. 따라서 모델 선택 기준, 성능 평가 방식, 고객 세분화 방법을 비판적으로 검토하기에 적합하다고 판단하였다.

2. 연구 개요

플랫폼 비즈니스는 네트워크 효과를 바탕으로 빠르게 성장하고 있으나, 고객 이탈은 기업의 수익성에 직접적인 영향을 미치는 핵심 리스크이다. 일반적으로 신규 고객을 확보하는 비용은 기존 고객을 유지하는 비용보다 최대 5~6배 높기 때문에, 고객 이탈을 사전에 예측하고 방지하는 것은 플랫폼 기업의 중요한 과제라고 할 수 있다. 그러나 기존 연구는 주로 이탈 예측 모델의 성능을 높이는 데 초점을 두었으며, 예측 결과를 고객 가치 평가와 세분화 전략으로 연결하는 통합적 관점은 상대적으로 충분히 다루지 못했다.

이러한 문제의식에서 본 연구는 ‘단순히 누가 이탈할 것인가’를 예측하는 데 그치지 않고, ‘어떤 고객을 우선적으로 관리해야 하는가’를 함께 판단할 수 있는 고객 세분화 방법론을 제시하는 것을 목적으로 한다. 이를 위해 머신러닝 기반 이탈 예측 모델과 참여도(Engagement)를 반영한 ERFM(Extended RFM) 모델을 결합하여, 고객의 이탈 위험도와 고객 가치를 동시에 평가하였다.

연구 절차는 총 5단계, 세부적으로는 11단계로 구성된다. 첫째, 이탈 예측과 ERFM 점수 산출을 위한 데이터를 정제·전처리하여 분석용 데이터셋을 구성한다. 둘째, 고객의 활동 감소량을 기준으로 이탈 여부를 정의하고, ERFM 점수 산출 기준을 설정한다. 셋째, 로지스틱 회귀, SVM, Random Forest, XGBoost의 네 가지 분류 모델을 적용하고 성능을 비교하여 최적의 이탈 예측 모델을 선정한다. 넷째, 선정된 모델을 활용해 고객별 이탈 위험도를 측정하고 ERFM 점수를 산출한다. 마지막으로 이탈 위험도와 고객 가치를 결합하여 고객을 네 개 군으로 세분화한다.

3. 데이터

본 연구에서 사용한 데이터는 프라이빗 채팅 플랫폼 ‘팬심M(Fancim M)’의 사용자 로그 데이터이다. 데이터는 고객의 플랫폼 내 활동 기록, 상품 및 서비스 구매 기록, 팬과 셀럽 간 메시지 교환 내역 등으로

구성된다. 수집 기간은 2023년 1월 1일부터 2023년 12월 31일까지 총 12개월이며, 해당 기간 동안 플랫폼에 접속한 사용자 중 팬(fan)을 중심으로 분석이 수행되었다.

데이터는 크게 이탈 예측 데이터, Purchase RFM 데이터, Engagement RFM 데이터로 구분된다. 이탈 예측에 사용된 활동 로그 데이터는 원자료 기준 850,498행 규모이며, 논문의 표 1에서는 결측치 처리 전 850,498행 31열, 결측치 처리 후 205,602행 29열로 정리되어 있다. Purchase RFM 데이터는 결측치 처리 전 359행 5열에서 처리 후 356행 5열로, Engagement RFM 데이터는 4,109행 5열에서 4,106행 5열로 정제되었다. 이후 이탈 기준을 적용한 결과, 전체 6,036명 중 이탈 고객은 3,421명, 비이탈 고객은 2,615명으로 나타났으며, 이탈률은 56.68%였다.

전처리 과정에서는 데이터의 신뢰성을 높이고 불필요한 노이즈를 줄이기 위해 결측치를 완전제거법으로 제거하였다. 또한 개별 사용자의 활동 주기와 패턴을 분석하기 위해 사용자 활동 로그에 첫 활동일과 마지막 활동일을 추가하였다. 연구에서는 안정적인 사용자 유입과 활동 종료가 반영된다고 판단되는 2023년 9월 28일부터 2023년 12월 31일까지를 기준 구간으로 설정하고, 이 기간을 중심으로 전처리와 탐색적 데이터 분석을 수행하였다.

이탈 여부는 고객 활동 감소량을 기준으로 정의되었다. 연구에서는 7일, 14일, 21일 간격의 롤링윈도우를 적용하고, 활동 감소 임계치를 50%, 70%, 90%로 설정하여 여러 기준을 검토하였다. 그 결과 14일 동안 플랫폼 내 활동이 70% 이상 감소한 경우를 이탈로 정의하였다. 이 기준을 적용했을 때 이탈 고객과 비이탈 고객의 비율이 비교적 균형을 이루어 별도의 데이터 균형화 작업은 필요하지 않았다. 이후 이탈 고객은 1, 비이탈 고객은 0으로 표시하는 Churn 변수를 생성하여 머신러닝 기반 이탈 예측 모델의 주요 목표 변수로 활용하였다.

4. 모델 분석

본 논문은 고객 이탈 예측을 이탈 고객과 비이탈 고객을 구분하는 이진 분류 문제로 설정하고, 네 가지 지도학습 분류 알고리즘을 적용-비교하였다. 적용된 모델은 선형 모델인 로지스틱 회귀와 선형 SVM, 비선형 모델인 Random Forest와 XGBoost이다. 모델 성능은 정확도, 정밀도, 재현율, F1 점수, ROC-AUC를 기준으로 평가되었으며, 본 보고서에서는 이 중 핵심 지표인 F1 Score, ROC-AUC, 정확도를 중심으로 정리하였다. 주요 결과는 표1과 같다.

<표 1> 모델별 이탈 예측 성능

모델	F1 Score	ROC-AUC	정확도
로지스틱 회귀	0.625	0.629	0.591
Random Forest	0.635	0.700	0.644
SVM	0.666	0.400	0.500
XGBoost	0.727	0.805	0.725

비교 결과, XGBoost가 ROC-AUC 0.805로 가장 우수한 성능을 보였으며, F1 Score와 정확도에서도 가장 높은 값을 보여 최적의 이탈 예측 모델로 선정되었다. 반면 SVM은 F1 Score가 0.666으로 낮지 않게 나타났으나, ROC-AUC가 0.400으로 무작위 분류 기준인 0.5보다도 낮아 이탈 고객과 비이탈 고객을 안정적으로 변별하지 못한 것으로 판단된다. 이는 모델 성능을 단일 지표만으로 판단하기보다, F1 Score

와 ROC-AUC를 함께 고려해야 함을 보여준다.

XGBoost는 그래디언트 부스팅을 확장한 알고리즘으로, 여러 개의 얇은 결정 트리를 순차적으로 결합하면서 이전 모델이 발생시킨 오류를 다음 모델이 보완하는 방식으로 작동한다. 또한 정규화 기법과 병렬 처리 구조를 활용하여 과적합을 억제하고 대규모 데이터에서도 높은 예측 성능과 확장성을 확보할 수 있다. 이러한 특성 때문에 플랫폼 사용자 로그와 같이 행위 패턴이 복잡한 데이터에서 상대적으로 우수한 성능을 보인 것으로 해석할 수 있다.

한편 고객 가치 평가는 ERFM(Extended RFM) 모델을 통해 수행되었다. ERFM은 전통적인 RFM 모델의 구성 요소인 최근성(Recency), 빈도(Frequency), 금액(Monetary)에 플랫폼 고객의 참여도(Engagement)를 추가한 확장 모델이다. 본 논문에서는 구매 데이터를 기반으로 Purchase RFM을 산출하고, 메시지 활동 데이터를 기반으로 Engagement RFM을 산출하였다. 각각의 RFM 요소는 5분위수로 점수화되었으며, 최근성과 빈도에는 각각 20%, 금액 또는 메시지 양에 해당하는 Monetary에는 60%의 가중치가 적용되었다. 이후 Purchase RFM 점수와 Engagement RFM 점수를 합산하여 최종 ERFM 점수를 도출하고, 이를 고객 가치 평가 지표로 활용하였다.

5. 결론

본 연구의 결과를 종합하면, 네 가지 머신러닝 분류 모델 가운데 XGBoost가 ROC-AUC 0.805로 가장 우수하여 최적 모델로 선정되었다. 연구자는 이를 활용해 고객별 이탈 확률, 즉 이탈 위험도를 산출하고, 이를 ERFM 점수와 결합하여 '이탈 위험도'와 '고객 가치'를 두 축으로 하는 2차원 평면을 구성하였다. 이후 중앙값을 기준으로 고객을 네 개 사분면으로 세분화하였으며, 분석 대상, 데이터 규모, 이탈 정의, 최적 모델 및 세분화 방식 등 핵심 내용은 <표 2>에 정리하였다.

이러한 세분화 결과는 고객군별 차별화된 유지 전략 수립에 활용될 수 있다. 예를 들어 고가치·고위험 고객에게는 맞춤형 혜택, 개인화 서비스, 참여 캠페인 등 집중적 개입이 필요하며, 수익성과 이탈 가능성이 모두 낮은 고객에게는 최소한의 유지 전략이 적절하다. 이처럼 본 연구는 한정된 마케팅 자원을 고객군별로 효율적으로 배분할 수 있는 근거를 제시했다는 점에서 의미가 있다.

<표 2> 연구 핵심 요약

항목	내용
대상	프라이빗 채팅 플랫폼 '팬심M(Fancim M)'
데이터	사용자 활동 로그 데이터 (결측치 처리 전 850,498행 → 처리 후 205,602행)
분석 대상	사용자 6,036명 (이탈률 56.68%)
이탈 정의	14일 동안 플랫폼 내 활동이 70% 이상 감소한 경우
최적 모델	XGBoost (ROC-AUC 0.805)
세분화 방식	ERFM × 이탈 위험도 기반 4사분면

본인이 평가하는 이 논문의 주요 특징은 다음과 같다. 첫째, 고객 이탈 예측에서 멈추지 않고 고객 가치 평가, 세분화, 유지 전략 수립으로 이어지는 통합 프로세스를 제시했다. 둘째, 기존 RFM에 참여도(Engagement)를 더한 ERFM을 활용하여 구매 행동뿐 아니라 메시지 활동과 같은 비구매 행동까지 반영하였다. 셋째, 85만 건 규모의 실제 사용자 로그 데이터를 활용했다는 점에서 실무적 설득력이 있다.

다만 본 연구는 단일 플랫폼인 팬심M 사례에 집중하고 있어, 다른 산업이나 플랫폼으로 일반화하기에는 추가 검증이 필요하다. 또한 시장 동향, 경쟁사 전략, 거시경제 변화와 같은 외부 요인을 모델에 직접 반영하지 못한 점도 한계로 볼 수 있다.

종합적으로 볼 때, 본 논문은 머신러닝 기반 이탈 예측과 ERFM 기반 고객 가치 평가를 결합하여 플랫폼 비즈니스의 고객 관리 전략을 보다 체계화했다는 점에서 의미가 있다. 특히 단순히 이탈 여부를 예측하는 수준을 넘어, 어떤 고객을 우선적으로 관리해야 하는지 판단할 수 있는 데이터 기반 의사결정 프레임워크를 제시했다는 점에서 연구적·실무적 가치가 있다고 평가된다.

[6] “딥러닝 기반 SAR 영상 객체 탐지 모델의 구조적 특성 분석”에 대한 리뷰 보고서, 박병운

1. 서론

논문은 RISS(학술연구정보서비스) 에서 발행기간이 2025년부터 2026년 사이인 학위수여 논문 중 논문명을 기계학습 또는 머신러닝으로 설정하여 검색하였고, 평소 관심 주제였던 위성 SAR 영상 분석 도메인 관련 논문을 발견했고 이에 선정 하였다. 선정된 논문에 대한 정보는 다음과 같다.

- 논문제목: 딥러닝 기반 SAR 영상 객체 탐지 모델의 구조적 특성 분석
- 논문저자: 양서정
- 발행년도: 2025년
- 발 행 처: 충남대학교 대학원

2. 연구 개요

연구 필요성

지구 관측 및 위성 데이터 분석 분야에서 광학 센서(수동형)와 SAR 센서(능동형)는 영상을 생성하는 물리적 원리에서부터 극명한 차이를 보인다. 광학 영상(Optical Image)은 태양광이 지표면에 부딪혀 반사되는 가시광선과 적외선 영역의 에너지를 수동적으로 받아들여 촬영하며, 사람이 눈으로 보는 것과 동일한 형태와 색상, 텍스처를 직관적으로 제공한다는 장점이 있다. 반면, SAR 영상(Synthetic Aperture Radar)은 위성 자체에서 마이크로파 레이더 신호를 지표면으로 직접 발사한 후, 객체로부터 반사되어 되돌아오는 후방산란(Backscatter) 신호를 수신하여 영상을 재구성한다. 이로 인해 물체의 색상이 아닌 재질(금속성 등), 거칠기, 기하학적 형태에 따라 명암이 결정되는 독특한 특성을 지닌다.

이러한 작동 원리의 차이로 인해, SAR 영상은 광학 영상이 극복하지 못하는 환경적 한계를 완벽히 보완한다. 태양 빛에 의존하지 않고 자체 전파를 활용하기 때문에 주야간 불문 관측이 가능하며, 마이크로파 대역 전파의 높은 투과성에 기반하여 구름, 안개, 비 등 기상 상황에 구애받지 않는 전천후(All-weather) 관측 능력을 제공한다. 이러한 독보적인 장점은 국가 안보, 해양 감시, 불법 어업 단속, 긴급 재난 대응 등 공백 없는 상시 모니터링이 필수적인 실무 분야에서 압도적인 가치를 지닌다.

최근 컴퓨터 비전 분야에서 제안된 최신 딥러닝 모델들은 풍부한 시각 정보와 직관적인 특징 추출이 가능한 광학 영상(ImageNet, COCO 등)을 중심으로 활발한 연구가 수행되어 왔다. 그러나 해양 감시 환경 등에서 SAR 영상이 가지는 독보적인 실무적 장점과 중요성에도 불구하고, 이를 대상으로 한 딥러닝 아키텍처 연구는 상대적으로 매우 부재한 상황으로 연구가 필요한 실정이다.

연구 목적

본 연구의 목적은 전천후 해양 감시의 핵심인 고해상도 SAR 영상을 대상으로, 대표적인 CNN 기반 모델인 YOLOv8과 최신 Transformer 기반 모델인 RF-DETR의 성능을 동일한 실험 조건하에서 실증 비교·분석하는 것이다. 이를 통해 두 아키텍처의 구조적 특성이 SAR 영상 내 탐지 성능과 해석 방식에 어떠한 차이를 유발하는지 규명하고, 다음과 같은 세부 목표를 달성하고자 한다.

- 동일 조건하의 정량적 성능 평가공개 벤치마크 데이터셋(HRSID)을 활용하고 해상도, 전처리, 증강 기법을 통일하여 mAP, Precision, Recall 등의 지표로 두 모델의 순수한 구조적 성능 차이를 공정하게 평가한다.

- 구조적 오류 패턴 분석혼동 행렬(Confusion Matrix)과 벡터 기반 분석을 도입하여 오탐(FP) 및 미탐(FN)의 분포를 파악하고, 소형 선박 밀집도나 저대비 환경 등 SAR 취약 조건에서 각 아키텍처가 유발하는 경계 오차의 원인을 규명한다.

- 상황별 실무 활용 전략 제안속도(실시간성)와 정확도(정밀 탐지) 간의 트레이드오프를 면밀히 평가하여 실시간 경보 시스템과 정밀 판독 시스템 등 운용 목적에 맞는 맞춤형 모델 선택 가이드라인과 두 모델을 연계하는 하이브리드 전략을 제시한다.

연구 절차

- HRSID 데이터셋 수집 및 구성
- 전처리: 리사이즈(800×800), 플립 증강
- 두 모델 훈련 (COCO 사전학습 가중치 활용)
- 성능 평가: mAP, Precision, Recall
- 오차 분석:Confusion Matrix, Vector Analysis
- 비교 분석 및 결론 도출

3. 데이터

데이터 종류 및 수량

본 연구는 HRSID(High-Resolution SAR Images Dataset)를 활용하였다. RADARSAT-2 및 TerraSAR-X 위성으로 취득한 SAR 영상으로 구성되며, 원본 이미지 5,604장을 수평·수직 플립으로 증강하여 16,797장을 확보하였다. 이 중 10,797장을 최종 사용하였으며, 학습 9,116장 / 검증 1,121장 / 테스트 560장으로 분할하였다.

수집 방법

공개 데이터셋(HRSID)을 다운로드하여 활용하였으며, 별도의 직접 수집은 수행하지 않았다.

전처리 방법

- 입력 크기 통일: 800×800 픽셀로 리사이즈
- 데이터 증강: 수평 플립(Horizontal Flip), 수직 플립(Vertical Flip)
- 어노테이션: COCO JSON 형식, 단일 클래스 'ship'

4. 모델 분석

YOLOv8 (CNN 기반)

YOLOv8은 One-Stage Anchor-Free 방식의 실시간 객체 탐지 모델이다. 백본으로 CSPDarknet을 사용하며, C2f 모듈로 특징을 추출한다. 넥(Neck)은 BiFPN으로 다중 스케일 특징을 융합하며, Decoupled Head로 분류와 회귀 연산을 분리하여 처리한다. 300 에포크 훈련하였으며, 빠른 추론 속도로 실시간 적용에 유리하다.

RF-DETR (Transformer 기반)

RF-DETR은 Roboflow에서 개발한 End-to-End Transformer 기반 탐지기이다. DINOv2(ViT 계열)를 백본으로 사용하며, Deformable Attention 메커니즘으로 연산 효율을 높였다. Dense Prior Query 방식을 사용하며 NMS 후처리가 불필요하다. Early Stopping 적용으로 약 100 에포크에서 훈련이 종료되었다.

공통 설정

두 모델 모두 COCO 사전학습 가중치 사용, 배치 크기 16, 입력 해상도 800×800으로 동일하게 설정하였다.

5. 결론

연구 결과

YOLOv8은 mAP@0.5(94.5%)와 Recall(88.4%), 오탐(FP 225건) 측면에서 우수하여 빠른 탐지 속도가 요구되는 실시간 해상 감시에 적합하다.

RF-DETR은 mAP@0.5:0.95(72.1%),

Precision(95.0%), 미탐(FN 706건) 측면에서

우수하여 정밀 탐지가 요구되는 군사·재난 대응에 적합하다.

개인 평가 및 논문 특성

본 논문은 SAR 영상이라는 특수한 원격탐사 도메인에서 CNN 기반 모델(YOLOv8)과 Transformer 기반 모델(RF-DETR)을 동일 조건으로 비교한 점에서 학술적 가치가 높다. Confusion Matrix 및 Vector Analysis를 통한 오차 유형 분석을 수행한 점이 차별점이다. 다만 단일 데이터셋(HRSID)만을 사용하여 일반화 가능성이 제한적이며, 추론 속도(FPS) 정량 비교가 부족하다. 향후 두 모델의 앙상블 또는 하이브리드 구조 연구로 SAR 객체 탐지 성능 향상이 기대된다.

[7] “공정성을 고려한 머신러닝을 위한 새로운 데이터, 알고리즘 및 평가지표”에 대한 리뷰 보고서, 임준영

1. 서론

본 보고서가 정리·평가 대상으로 선정한 논문은 정상원(Sangwon Jung, 학번 2022-31607)이 2025년 8월 서울대학교(Seoul National University) 공과대학(College of Engineering) 전기·정보공학부(Department of Electrical and Computer Engineering)에 제출한 국내 박사학위논문이다. 국문 제목은 「공정성을 고려한 머신러닝을 위한 새로운 데이터, 알고리즘 및 평가지표」, 영문 제목은 Novel Data, Algorithm and Metric for Fairness-aware Machine Learning 이며, 본문 분량은 8개 장과 부록을 포함해 약 117쪽에 달한다.

논문 검색은 서울대 학위논문 기관 리포지토리 SNU S-Space 를 1차 채널로, RISS·ScienceON·KCI·dCollection 을 보조 채널로 함께 활용하였으며, “최근 2년(2025~2026) · 석박사 학위논문 · 머신러닝 모델·기법 자체 연구”라는 과제 조건을 일관되게 적용하였다. 키워드는 fairness-machine learning 을 1차 주제어로, 보조로 Sangwon Jung-Seoul National University-Novel Data Algorithm Metric 을 결합하였다. 이러한 키워드 조합은 응용 사례 위주가 아닌 알고리즘·데이터셋·평가지표 3축에 모두 새로 기여한 박사학위 연구를 발굴하려는 의도였다. 본 보고서는 정상원 박사학위논문의 본문 PDF(SNU S-Space 공개판)를 직접 인용하여 작성되었다.

2. 연구 개요

2.1 필요시 구분

본 연구는 의료·법집행·금융·고용·콘텐츠 생성 등 고위험 의사결정 영역에 머신러닝이 광범위하게 배치되면서 기존 편향과 구조적 불평등이 증폭되는 문제의식에서 출발한다. 안면인식의 인종·성별 오차, 채용 알고리즘의 성차별, COMPAS의 인종 편향, 대형 언어 모델의 소수자 유해 표현 등이 대표 사례이며, GDPR-Algorithmic Accountability Act 같은 규제도 공정성·투명성을 의무화하고 있다. 그러나 공정성의 세 구성요소 — 평가지표(metrics) · 학습 방법(methods) · 평가 데이터셋(datasets) — 모두에서 한계가 누적되어 왔다. 지표는 분류 위주로 설계되어 생성 모델에 일반화되지 않고, 방법은 소규모에 한정되며 민감속성 라벨이 완전히 주석되었음을 가정하고, 데이터셋은 단순·좁은 범위에 머문다.

이에 본 학위논문은 세 축 모두를 제1원리로부터 새로 설계 하고 형식적 분석(formal analysis) 으로 뒷받침하는 통합 연구 의제를 제시한다. 수행 절차는 8개 장으로 구성된다. 먼저 Ch.2 에서 그룹·개인·반사실 공정성과 기존 In-/Pre-/Post-processing 방법론을 정리한 뒤, Ch.3~Ch.5 에서 알고리즘 3종(MFD·FairDRO·CGL)을 차례로 제안한다. 이어 Ch.6 에서 신규 반사실 데이터셋(CelebA-CF·LFW-CF)과 CKD 알고리즘을 결합 제안하고, Ch.7 에서 새로운 평가지표 MPR과 그 기반 미세조정 방법을 제시한다. 마지막 Ch.8 은 종합 결론과 실용 가이드라인으로 마무리된다. 다섯 신규 기여가 독립적으로 성립하면서도 “공정성 인지 머신러닝”이라는 단일 의제 아래 통합되는 구성이다.

3. 데이터

본 논문은 공정성 학습·평가의 다양한 시나리오를 포괄하기 위해 공개 벤치마크 8종과 직접 구축한 신규 데이터셋 2종 을 결합하여 사용하며, 비전(합성·실세계 얼굴), 표(tabular), 자연어, 생성 이미지 모달리티

를 모두 포괄한다.

먼저 비전 계열에서는 Ch.3 의 합성 비전 실험에 CIFAR-10S 가, 실세계 얼굴 실험에 UTKFace(Ch.3·4·5), CelebA(Ch.3·5·6), LFW(Ch.6) 가 사용된다. UTKFace 는 20K장 이상의 얼굴 이미지에 인종 4그룹(White/Black/Asian/Indian)과 연령 3클래스를 부여하며, CelebA 는 200K장 이상에 40 개 이진 속성을 부여하되 본 논문은 성별을 민감속성으로, Attractive 또는 Blond Hair 를 타겟으로 사용한다. 표 계열에서는 Ch.4·5 의 UCI Adult(약 45K 행, 연소득 50K 초과 예측)와 ProPublica COMPAS(약 5K 행, 재범 예측)가 활용되고, 자연어 계열에서는 Ch.4 의 CivilComments-WILDS(약 450K 코멘트, 인종 민감속성)가 사용된다. Ch.5·7 에서는 인종·성별·연령이 균형 잡힌 참조 분포로 FairFace(73,377장)가 활용되며, Ch.7 의 생성 모델 평가에서는 Stable Diffusion v1.4-v2.1-SDXL 로 프롬프트당 1,000장씩 생성한 이미지를 100회 부트스트랩 재추출하여 MPR 평균·표준편차를 산출한다. 마지막으로, 본 논문이 Ch.6 에서 자체 구축한 CelebA-CF / LFW-CF 는 원본 얼굴 이미지의 민감속성만을 변경한 반사실(counterfactual) 쌍 데이터셋으로, 각각 230쌍·144쌍을 검수 확정된 신규 평가 자산이다.

전처리기는 챕터별로 다르게 적용된다. CIFAR-10S 는 클래스별로 컬러:그레이 비율을 4:1 또는 1:4 로 편향시키되 테스트셋은 양쪽을 균형 유지하였고, CelebA-UTKFace 는 (그룹×클래스) 동수 샘플링으로 테스트셋을 균형화하였다. CivilComments 는 인종 정체성 연속값을 최댓값만 1로 두는 이진화로 변환하였다. 신규 데이터셋은 InstructPix2Pix(IP2P) 확산 모델로 민감속성만 변경한 반사실 쌍을 생성한 뒤, 수염·아담사과·턱·눈썹·광대·입술·헤어라인·피부·화장 등 9개 성·관련 시각 특징에 대해 5명 평가자가 점 검하여 2표 이하 후보를 탈락시키는 절차로 신뢰성을 확보하였다. 그 결과 민감속성 변경 정확도는 CelebA-CF 96.52%, LFW-CF 98.61%, 비민감속성 보존 정확도는 각각 95.98%, 93.75% 로 보고되었다.

4. 모델 분석

본 학위논문의 핵심은 다섯 가지 신규 기여이며, 챕터 순서대로 절차적으로 정리하면 다음과 같다. 첫째, Ch.3 의 MFD(MMD-based Fair Distillation) 는 알고리즘 계열의 기여로, 이미 배포된 불공정 교사 모델의 클래스 조건부 평균 특징 분포를 학생의 (그룹, 클래스) 조건부 분포에 RKHS 위 MMD 거리로 정합시키는 공정성 인지 지식 증류 기법이다. 둘째, Ch.4 의 FairDRO 는 x^2 -divergence 볼 위에서 음수도 허용하는 quasi-probability 가중치를 사용해 클래스별 Group DRO 를 푸는 알고리즘으로, 재가중과 정규화 두 계열을 통합한다. 셋째, Ch.5 의 CGL(Confidence-based Group Labeling) 은 그룹 라벨이 일부만 주석된 Fair-PG 환경을 다루는 알고리즘으로, 신뢰도 임계 τ 기반 의사 라벨링 방식이다. 넷째, Ch.6 의 CKD(Counterfactual Knowledge Distillation) 는 알고리즘과 데이터(CelebA-CF·LFW-CF)를 결합한 기여로, 반사실 쌍의 평균 표현을 교사로 삼아 학생이 원본과 반사실 모두를 추종하도록 정합한다. 다섯째, Ch.7 의 MPR(Multi-Group Proportional Representation) 은 평가지표와 그 기반 미세조정 알고리즘을 함께 제안한 기여로, 함수 클래스 위의 supremum 으로 교차군 표현 격차를 측정한다.

MFD 의 목적함수는 다음과 같이 표현된다.

$$\min_{\theta} L_{CE}(\theta, D) + (\lambda/2) \cdot \sum_y \sum_a D^2(p^{\theta}_{T_y}, p^{\theta}_{S_{\{a,y\}}})(\theta)$$

본문은 이 정규화 항이 교사-학생 분포 정합(Lemma 1)과 동일 클래스 내 그룹 간 학생 분포 정합(Lemma 2, Equalized Odds 총족)을 동시에 유도함을 증명한다. FairDRO 에 대해서는 Corollary 1 이식 (4.6)의 내부 최댓값이 "클래스-그룹 균형 ERM + DCA(Difference of Conditional Accuracy) 정규화"와 등가임을 보여 재가중과 정규화의 통합을 정당화하고, Algorithm 1 의 Smoothed Iterated Best Response 로 최적화한다. CGL 은 보조 분류기 신뢰도가 임계 τ 를 넘는 표본에 의사 라벨을 부여하고 나머지는 클래스 조건부 분포로 랜덤 할당하여, 단순 의사라벨 대비 DCA 근사 오차가 작거나 같음을

Proposition 3 으로 증명한다. CKD 는 Theorem 1 - "반사실 공정성(CF)을 만족해도 그룹 공정성(GF)이 깨질 수 있다" - 을 이론적 동기로 삼아, 교사 모델의 원본·반사실 표현 평균을 학생의 두 표현이 함께 추종하도록 손실을 설계한다. MPR 은 다음과 같이 정의된다.

$$\text{MPR}(C, G_q, R) = \sup_{\{c \in C\}} |E_{\{G_q\}}[c(X_g)] - E_R[c(X_r)]|$$

함수 클래스가 선형이거나 이진 결정트리일 때는 폐쇄형 해(Proposition 7·8)가 존재하며, 본 논문은 이를 손실로 활용해 LoRA 로 텍스트-이미지 생성 모델을 효율적으로 미세조정한다. 다섯 기여 모두 정식 정리·증명(Lemma 1~3, Proposition 1~8, Corollary 1, Theorem 1)으로 뒷받침되고, 비전·표·자연어·생성 네 모달리티에서 일관되게 실험적으로 검증된다.

5. 결론

5-1. 연구 결과

본 논문의 다섯 기여는 모달리티·시나리오를 가로질러 일관되게 우수한 성능을 보였다. 원논문 Table 3.1, 6.3, 7.4 의 핵심 결과를 발췌하면 다음과 같다.

먼저 MFD 는 CIFAR-10S 데이터셋에서 정확도 82.77%, DEOA 2.73, DEOM 6.08 을 기록하여, 교사 (Acc 79.62 / DEOA 15.63 / DEOM 31.32)와 강력한 베이스라인인 SS(Acc 82.69 / DEOA 3.29 / DEOM 7.13) 를 모두 능가했으며, 본문에서 정확도와 공정성을 교사 대비 동시 개선한 유일한 방법으로 보고되었다. 다음으로 CKD 는 CelebA(G=hair length 조작)에서 CD 4.44, DEO 13.23, RFP 10.85 를 달성하여, Scratch(CD 10.26 / DEO 47.10 / RFP 15.27)와 CP-only(CD 2.53 이지만 DEO 51.01 로 악화)를 모두 능가했고, 이는 반사실 학습이 그룹 공정성을 오히려 악화시키는 함정을 회피했음을 뜻한다. 마지막으로 MPR 미세조정 은 7개 직업 프롬프트에서 MPR(G) 0.08, MPR(GAR) 0.25, CLIP score 0.30 을 기록하여, Vanilla(MPR 1.18 / 1.89)·FairDiffusion(0.27 / 1.32)·ITI-GEN(0.13 / 0.44) 등 모든 비교 기법을 능가하면서도 이미지 품질(CLIP score)을 유지하였다. 이 밖에 FairDRO 는 Adult·COMPAS·UTKFace·CivilComments 전반에서 정확도-DCA Pareto frontier 의 우상단을 차지했고, CGL 은 CelebA 에서 그룹 라벨을 1% 만 사용했음에도 JTT·EIII 등 기존 약지도 baseline 을 능가하였다.

5-2. 본인 평가

본 논문의 강점은 세 가지로 요약할 수 있다. 첫째, 단일 응용이 아닌 알고리즘-데이터-지표 다섯 기여를 한 박사학위에 통합한 머신러닝 모델·기법 자체 연구의 모범 사례 라는 점이다. 둘째, 8개에 이르는 정리·명제·따름정리·정리(Lemma·Proposition·Corollary·Theorem)와 네 모달리티 실험으로 이론과 실증의 균형을 갖춘 점이다. 셋째, Ch.8 에서 MFD·FairDRO·CGL 을 도메인·라벨 가용성·모델 제약별로 권고하는 실용 가이드라인 을 명시한 점이다. 한계로는 두 가지를 들 수 있다. 우선 제한된 방법들이 모델 파라미터와 학습 파이프라인 접근을 가정하기 때문에 거대 LLM 이나 텍스트-이미지 모델 같은 블랙박스 환경에 직접 적용하기 어렵다는 점이며, 다음으로 CelebA·UTKFace 의 이진 성별 라벨 이 실제 정체성 스펙트럼을 충분히 반영하지 못한다는 점이다. 시사점으로는, 보건·금융·법집행 등 고위험 머신러닝 응용 도메인에서 즉시 활용 가능한 공정성 도구군을 제공함과 동시에, MPR 이 텍스트-이미지 생성 모델 공정성 평가의 표준 지표 후보가 될 잠재가 크다는 점이다. 끝으로, 본 보고서는 본문 8장 및 부록 중 핵심 정량 결과 일부를 발췌·요약한 것이며, 모든 상세 수식·증명·실험 조건은 원 논문 본문을 참조해야 한다.

[8] “머신러닝 및 딥러닝 모델을 이용한 개인 신용 리스크 예측 성능 비교 분석”에 대한 리뷰 보고서, 송민성

1. 서론

최근 금융 산업에서는 디지털 전환과 인공지능 기술의 발전에 따라 신용평가 체계에도 큰 변화가 나타나고 있다. 과거에는 신용점수 기반의 통계적 모형이 주로 활용되었으나, 최근에는 대규모 데이터를 기반으로 복잡한 패턴을 학습할 수 있는 머신러닝과 딥러닝 기술이 금융 의사결정 과정에 적극 활용되고 있다. 특히 대출 승인, 신용등급 산정, 연체 위험 예측과 같은 분야에서는 보다 정확한 예측 모델 개발이 금융기관의 경쟁력과 직결되고 있다.

본 보고서에서는 손지민(2025)의 석사학위논문 「머신러닝 및 딥러닝 모델을 이용한 개인 신용 리스크 예측 성능 비교 분석」을 대상으로 연구 내용을 분석하였다. 해당 논문은 서강대학교 AI SW대학원 데이터 사이언스 인공지능전공에서 수행된 연구로, 다양한 머신러닝 및 딥러닝 모델을 활용하여 개인의 신용리스크를 예측하고 각 모델의 성능을 비교하는 것을 목적으로 한다.

논문 검색은 DBpia 학위논문 검색 서비스를 활용하였으며, 검색 키워드는 ‘머신러닝’, ‘딥러닝’, ‘SVM’으로 설정하였다. 여러 후보 논문 중 본 논문을 선택한 이유는 실제 금융 데이터를 기반으로 다양한 머신러닝 모델과 딥러닝 모델을 동시에 비교하고 있으며, 연구방법론 수업에서 학습한 지도학습 기반 분류 문제를 이해하는 데 적합하다고 판단하였기 때문이다. 또한 Logistic Regression, SVM, XGBoost, CNN, RNN 등 대표적인 인공지능 모델들이 모두 포함되어 있어 모델 간 특성과 성능 차이를 비교·분석하기에 적절한 연구라고 판단하였다.

2. 연구 개요

2.1 연구 필요성 및 목적

전통적인 신용평가 시스템은 주로 신용점수 기반의 통계적 모형을 사용해왔다. 이러한 방식은 해석이 용이하고 실무 적용 경험이 풍부하다는 장점이 있으나, 복잡한 비선형 패턴을 반영하는 데에는 한계가 존재한다. 반면 머신러닝과 딥러닝 모델은 대규모 데이터에서 다양한 패턴을 학습할 수 있으며, 기존 모델보다 높은 예측 성능을 기대할 수 있다는 점으로 금융 분야에서 활발히 연구되고 있다.

이에 본 연구는 실제 금융 데이터인 HELOC 데이터를 활용하여 머신러닝 및 딥러닝 모델의 신용 리스크 예측 성능을 비교하고자 하였다. 특히 Logistic Regression을 기준 모델로 설정하고, SVM, XGBoost 등의 머신러닝 모델과 CNN, RNN 등의 딥러닝 모델을 비교하였다. 또한 RNN 구조에 정규화(Batch Normalization), Dropout, Bidirectional 기법을 적용하여 네트워크 구조 변화가 성능에 어떤 영향을 미치는지를 분석하였다.

2.2 연구 수행 절차

본 연구는 다음과 같은 절차로 수행되었다.

1. HELOC 데이터 수집
2. 데이터 전처리 수행
3. 머신러닝 모델 구축
4. 딥러닝 모델 구축
5. Accuracy 및 F1-Score 평가
6. 모델 성능 비교 분석
7. RNN 네트워크 구조 변경 실험

이와 같은 절차를 통해 동일한 데이터 환경에서 다양한 모델을 비교함으로써 각 알고리즘의 장단점을 객관적으로 분석하고자 하였다.

3. 데이터

본 연구에서는 FICO(Fair Isaac Corporation)에서 제공하는 HELOC(Home Equity Line of Credit) 데이터를 사용하였다. 해당 데이터는 실제 금융기관의 대출 심사 과정에서 활용되는 신용 관련 정보를 포함하고 있으며, 신용 리스크 예측 연구에서 널리 사용되는 공개 데이터셋이다.

데이터는 총 10,459개의 샘플과 23개의 설명변수로 구성되어 있다. 목표 변수는 RiskPerformance이며 고객의 향후 연체 여부를 나타낸다. Good은 정상 상황, Bad는 연체를 의미하며, 이를 기반으로 이진 분류 문제를 수행하였다.

전처리 과정에서는 먼저 특수값(-9, -8, -7)을 처리하였다. -9와 -8은 결측치로 간주하여 NaN으로 변환하였으며, -7은 0으로 대체하였다. 이후 변수 간 스케일 차이를 줄이기 위해 StandardScaler를 적용하여 평균 0, 표준편차 1로 정규화하였다. 마지막으로 목표 변수인 RiskPerformance를 Label Encoding하여 0과 1로 변환하였다.

〈표 1〉 HELOC 데이터 개요

구 분	내용
데이터 출처	FICO HELOC Dataset
샘플 수	10,459건
변수 수	23개
목표 변수	RiskPerformance
문제 유형	이진 분류
학습/검증 비율	7:3

본 연구에서 사용된 데이터는 정형 데이터(Tabular Data)이며 대부분 독립적인 금융지표들로 구성되어 있다. 따라서 이미지나 자연어 데이터와 달리 변수 간 관계를 얼마나 효과적으로 학습하느냐가 모델 성능에 중요한 영향을 미친다고 볼 수 있다.

4. 모델 분석

본 연구에서는 총 7개의 머신러닝 및 딥러닝 모델을 비교하였다.

머신러닝 모델로는 Logistic Regression, Decision Tree, SVM, XGBoost, Tuned XGboost가 사용되었다. Logistic Regression은 금융권에서 가장 널리 사용되는 전통적 신용평가 모델이며 높은 해석력을 가진다. SVM은 최적의 결정경계를 찾아 분류를 수행하는 모델로 일반화 성능이 우수하다. XGBoost는 부스팅 기반 알고리즘으로 복잡한 데이터 구조를 효과적으로 학습할 수 있다.

딥러닝 모델로는 CNN과 RNN이 사용되었다. CNN은 변수 간 국소적 패턴을 학습하기 위해 적용되었으며, RNN은 일부 변수의 시간적 특성을 반영하기 위해 설계되었다.

〈표 2〉 모델 성능 비교

모델	Accuracy	F1-Score
Logistic Regression	0.7059	0.6776
Decision Tree	0.6208	0.5891
SVM	0.7030	0.6683
XGBoost	0.6938	0.6646
Tuned XGBoost	0.6998	0.6688
RNN	0.7097	0.6831
CNN	0.7145	0.6899

실험 결과 CNN이 가장 높은 정확도를 기록하였다. 이는 HELOC 데이터가 정형 데이터임에도 불구하고 변수 간 국소적 관계를 효과적으로 학습한 결과로 해석할 수 있다. CNN은 Conv1D 구조를 활용하여 인접 변수들 사이의 상호작용을 학습하였으며, 상대적으로 단순한 구조 덕분에 과적합을 줄이고 일반화 성능을 확보할 수 있었던 것으로 판단된다.

반면 RNN은 원래 시계열 데이터 처리에 강점을 가지지만 HELOC 데이터는 시간 순서가 명확한 데이터가 아니기 때문에 RNN의 장점이 충분히 활용되지 못한 것으로 보인다. 따라서 데이터 특성상 CNN이 더 적합한 구조였다고 해석할 수 있다.

또한 Logistic Regression이 머신러닝 모델 중 가장 높은 성능을 기록한 점도 주목할 만하다. 일반적으로 최신 머신러닝 및 딥러닝 모델이 우수할 것이라고 예상할 수 있으나, 본 연구에서는 전통적인 통계 기반 모델이 여전히 높은 경쟁력을 보였다. 이는 HELOC 데이터가 비교적 구조화된 정형 데이터이며, 변수와 목표 변수 간 관계가 상대적으로 안정적이기 때문으로 판단된다. 또한 금융 분야에서는 예측 성능뿐 아니라 설명 가능성이 중요하기 때문에 Logistic Regression의 실무적 활용 가치는 여전히 높다고 볼 수 있다.

5. 결론

본 연구는 개인 신용 리스크 예측 문제에서 다양한 머신러닝 및 딥러닝 모델의 성능을 비교하고, 딥러닝 네트워크 구조 변경의 효과를 검증하였다. 연구 결과 CNN 모델이 Accuracy 0.7145로 가장 높은 성능을 기록하였으며, 머신러닝 모델 중에서는 Logistic Regression과 SVM이 우수한 성능을 보였다. 또한 RNN 모델에서는 Dropout 적용 시 성능이 향상되어 과적합 방지 기법의 효과를 확인할 수 있었다.

본 논문의 가장 큰 특징은 동일한 데이터셋을 기반으로 전통적인 통계모형부터 최신 딥러닝 모델까지 다양한 알고리즘을 비교했다는 점이다. 특히 CNN이 가장 높은 성능을 보인 반면, Logistic Regression 역시 매우 우수한 결과를 나타냈다는 점은 모델 선택에 있어 데이터 특성이 중요함을 보여준다.

개인적으로 본 연구는 머신러닝 연구방법론의 관점에서 의미 있는 사례라고 생각한다. 연구 결과는 최신 기술이 항상 최선의 선택은 아니라는 점을 보여주며, 데이터의 구조와 문제의 특성에 맞는 모델을 선택하는 것이 중요함을 시사한다. 또한 금융 분야에서는 예측 성능뿐 아니라 설명 가능성과 신뢰성 역시 중요하므로, Logistic Regression과 같은 전통적 모델의 가치도 여전히 높다고 판단된다.

다만 본 연구는 단일 데이터셋만을 사용하였고 Transformer 기반 모델이나 최근 금융 AI 모델을 포함하지 않았다는 한계가 있다. 향후 연구에서는 다양한 금융 데이터셋과 최신 딥러닝 구조를 적용하여 보다 종합적인 비교 분석이 수행될 필요가 있다. 이러한 연구가 지속된다면 더욱 정확하고 신뢰성 있는 금융 신용평가 시스템 구축에 기여할 수 있을 것으로 기대된다.

[9] “산불 피해 취약성 분석을 위한 머신러닝 알고리즘 비교”에 대한 리뷰 보고서, 차윤지

1. 서론

“산불 피해 취약성 분석을 위한 머신러닝 알고리즘 비교”는 2025년 8월에 제출된 석사학위 논문으로, 저자는 유호익이며 가천대학교 대학원에서 발행되었다. 본 논문은 최근 1년 이내 발표된 머신러닝 관련 석·박사 학위논문을 검색하는 과정에서 발견하였으며, 그 중 산불을 주제로 한 연구라는 점에 관심을 갖게 되어 선정하였다. 최근 기후변화의 영향으로 전 세계적으로 산불 발생 빈도와 피해 규모가 증가하고 있으며, 국내에서도 강릉, 울진·삼척, 경북 등 대형 산불로 인한 피해가 지속적으로 발생하고 있다. 이에 따라 산불 발생 이후의 피해를 최소화하기 위한 사전 예방 및 대응 전략의 중요성이 커지고 있으며, 본 논문은 머신러닝 알고리즘을 활용하여 산불 피해 취약성을 정량적으로 분석하고 비교하였다는 점에서 연구 가치가 높다고 판단하였다.

2. 연구 개요

2.1 연구 필요성

최근 기후변화의 영향으로 대형 산불의 발생 빈도와 피해 규모가 지속적으로 증가하고 있다. 기존 산불 연구는 위험 중심 접근과 취약성 중심 접근으로 수행되어 왔다. 그러나 위험 중심 연구는 실제 피해 규모를 충분히 반영하기 어렵고, 취약성 중심 연구는 전문가 판단에 의존하는 경우가 많아 변수 간 복잡한 관계를 분석하는 데 한계가 있었다. 이에 따라 머신러닝을 활용한 정량적 산불 취약성 평가의 필요성이 제기되었다.

2.2 연구 목적

본 연구는 강릉시를 대상으로 AdaBoost, CatBoost, LightGBM, XGBoost, Random Forest의 총 5개 알고리즘을 적용하여 산불 피해 취약성을 분석하고 알고리즘별 성능을 비교하는 것을 목적으로 한다. 또한 산불 피해에 영향을 미치는 주요 요인을 도출하고 취약 지역의 공간적 분포를 파악함으로써 산불 예방 및 피해 저감 전략 수립에 활용 가능한 기초 자료를 제공하고자 하였다.

2.3 연구 수행 절차

연구는 산불 피해 취약성 분석을 위해 공간 데이터를 구축하는 것으로 시작한다. 이후 머신러닝 모델을 설계하고 하이퍼파라미터 튜닝 및 교차검증을 통해 각 알고리즘의 예측 성능을 평가하였다. 또한 변수 중요도 분석과 민감도 분석을 수행하여 산불 피해에 영향을 미치는 주요 요인을 파악하였으며, 최종적으로 산불 취약성 지도를 작성하여 지역별 취약성 분포를 비교·분석하였다.

3. 데이터

3.1 데이터 종류

본 연구는 강릉시를 대상으로 산불 피해 취약성을 분석하기 위해 종속변수와 독립변수를 구축하였다. 종속변수는 산불 피해액의 공간적 밀도이며, 독립변수는 기후, 지형, 자연환경, 인문환경 요인으로 구성되었다. 기후 변수에는 연평균기온과 연평균강수량 등이 포함되었으며, 지형 변수에는 고도와 경사도 등이 활용되었다. 또한 자연환경 변수로는 수종, NDVI, 수관피복률 등이 사용되었고, 인문환경 변수로는 인구밀도, 건물밀도, 도로밀도, 공시지가, 토지이용 등의 공간정보가 활용되었다.

〈표 1〉 고려된 독립변수 목록

범주	변수명	가중 방법	출처
기후	연평균기온 연평균강수량 연평균풍속	정규 크리깅	WorldClim Version 2.1
지형	표고 경사도 사면방향 TWI	DEM	USGS, SRTM
지언 환경	수층 염광 경도 수관림도 수관피복률 수고 NDVI NDMI	Rasterize 원자료 활용 Resampling Landsat9 파생	산림청, 나무지도 Google Earth Engine, GPCC Version 4 Google Earth Engine, CHM USGS, Landsat9
인문 환경	임구 밀도 노인 밀도 유아 밀도 전통 밀도 목조 건물 밀도 노후 건물 밀도 취약 시설 밀도	커널 밀도 추정	국토지리정보원, 100m 격자 통계 국토교통부, GIS 건물통합정보
	문서지가 도도 밀도	Rasterize Line Density	여인이집 정보 공개포털, 국토교통부, 전국보통집사원, 광통시장
	소방물수 접근성	Cost-Distance	국도교통부, 개별공시지가정보 OpenStreetMap
	소방접근성 도지이용	G2SFCA 접근성 분석 Rasterize	OpenStreetMap, 소방청 화경공간정보서비스

3.2. 데이터 수집방법


산불 피해 데이터는 재난안전데이터공유플랫폼에서 제공하는 "산불발생이력" API와 "산불정보" API를 활용하여 수집하였다. 자료 수집 기준일은 2025년 5월 5일이며, 2015년 1월부터 2025년 4월까지의 산불 발생 정보를 통합하여 분석에 활용하였다. 수집된 산불 피해 데이터는 총 183건이다. 독립변수는 기온, 지형, 자연환경, 인문환경 관련 공간자료를 수집하였는데 이 출처는 위의 <표 1>과 같다.

3.3. 데이터 전처리

공간 범위는 강원특별자치도 강릉시 행정구역으로 한정하였다. Python 3.12 환경에서 일괄적인 전처리를 수행하였고, 모든 입력 자료는 30m 해상도로 통일하였다. 이때 수집된 피해액 데이터는 대부분이 0 원에 집중되어 있고 일부 값이 매우 큰 불균형 분포를 보였다. 이에 따라 데이터 분포를 안정화하기 위해 Yeo-Johnson 변환을 적용하였다. 또한 독립변수 간 중복성과 상관관계를 확인하기 위해 다중공선성 진단을 수행하였으며, 분석 결과를 바탕으로 상관성이 높은 변수를 제거하였다. 이후 최종적으로 18개의 독립변수를 선정하여 머신러닝 모델 학습에 활용하였다.

<그림 1> 연구대상지

<그림 1> 연구대상지



4. 모델 분석

4.1 적용된 머신러닝 모델

본 연구에서는 산불 피해 분석을 위해 AdaBoost, CatBoost, LightGBM, Random Forest, XGBoost의 5개 머신러닝 알고리즘을 도입하였다. 모든 모델은 회귀(Regression) 기반으로 설계되었으며, 산불 피해액의 공간적 밀도를 예측하도록 구축되었다. 또한 동일한 데이터셋과 분석 환경에서 각 알고리즘의 성능을 비교하여 산불 취약성 분석에 가장 적합한 모델을 도출하고자 하였다.

4.2 머신러닝 모델의 특징

AdaBoost는 이전 학습 과정에서 오차가 크게 발생한 데이터에 가중치를 부여하여 예측 성능을 향상시키는 부스팅(Boosting) 기법이다. Random Forest는 다수의 의사결정트리를 생성하고 결과를 종합하여 예측하는 배깅(Bagging) 기반 알고리즘으로 안정성이 높다는 특징이 있다. CatBoost, LightGBM, XGBoost는 모두 Gradient Boosting 계열 알고리즘으로, 복잡한 비선형 관계를 효과적으로 학습할 수 있어 최근 다양한 머신러닝 문제에서 높은 성능을 보이고 있다.

4.3 모델 학습 및 성능 평가

연구는 Python 3.12 환경에서 수행되었으며, 주요 분석 라이브러리는 scikit-learn, xgboost, lightgbm, catboost, numpy, rasterio 등을 활용하였다. 각 알고리즘에 대해 하이퍼파라미터 튜닝과 교차검증을 수행하여 최적의 모델을 구축하였다. 모델 성능 평가는 MAE(평균절대오차), MSE(평균제곱오차), RMSE(평균제곱근오차), R^2 (결정계수) 지표를 활용하였다. 또한 변수 중요도 분석과 민감도 분석을 수행하여 산불 취약성에 영향을 미치는 주요 요인을 해석하였으며, 최종적으로 각 모델의 예측 결과를 활용해 산불 취약성 지도를 작성하였다.

5. 결론

본 연구에서는 AdaBoost, CatBoost, LightGBM, Random Forest, XGBoost 알고리즘을 활용하여 산불 피해 취약성 예측 성능을 비교하였다. 하이퍼파라미터 튜닝 전후 성능 평가 결과 LightGBM이 MAE가 절반 가까이 감소해 0.0128, R^2 가 0.94857로 12% 이상 상승해 가장 큰 향상을 보였다. XGBoost와 CatBoost 또한 전반적으로 안정적이고 높은 예측력을 나타냈다. 반면 AdaBoost와 Random Forest는 상대적으로 낮은 성능을 보였다. 이를 통해 Gradient Boosting 계열 알고리즘이 산불 취약성 분석에 효과적임을 확인할 수 있었으며, 특히 LightGBM이 본 연구의 데이터 환경에서 가장 적합한 모델로 평가되었다.

<표 2> 머신러닝 알고리즘별
상위 20%의 변수와 변수 중요도

모델	1위 변수	2위 변수	3위 변수	4위 변수
AdaBoost	공시지가 (0.450)	연평균기온 (0.333)	토지이용 (0.085)	연평균강수량 (0.066)
CatBoost	공시지가 (0.287)	연평균기온 (0.227)	연평균강수량 (0.169)	토지이용 (0.050)
LightGBM	연평균강수량 (0.180)	연평균기온 (0.163)	공시지가 (0.140)	연평균풍속 (0.085)
RandomForest	연평균기온 (0.274)	공시지가 (0.190)	연평균강수량 (0.182)	토지이용 (0.144)
XGBoost	공시지가 (0.166)	토지이용 (0.137)	연평균기온 (0.120)	수고 (0.111)

변수 중요도 분석 결과 공시지가, 연평균기온, 연평균강수량, 토지이용이 산불 피해 취약성에 큰 영향을 미치는 주요 변수로 나타났다. 또한 산불 취약성 지도 분석 결과 강릉시 외곽 지역인 대전동과 성산면은 모든 머신러닝 알고리즘 결과에서 높은 취약성을 보인 반면, 운정동과 교동 등 도심 지역은 상대적으로 낮은 취약성을 나타냈다. 이러한 결과는 산불 피해가 자연환경 요인뿐만 아니라 인문환경 요인의 영향을 함께 받는다는 점을 보여주며, 향후 산불 예방 정책 수립 시 활용 가능한 기초자료를 제공한다.

본 논문의 가장 큰 특징은 동일한 지역과 동일한 데이터 조건에서 여러 머신러닝 알고리즘을 비교하여 최적의 모델을 도출하였다는 점이다. 특히 기존의 전문가 판단 기반 취약성 평가 방식과 달리 머신러닝을 활용하여 변수 간 복잡한 비선형 관계를 정량적으로 분석하였다는 점에서 의의가 있다. 또한 30m 해상도의 고해상도 공간 데이터를 활용하여 취약 지역을 세밀하게 분석하였으며, 변수 중요도와 취약성 지도를 함께 제시하여 결과를 직관적으로 해석할 수 있도록 하였다. 다만 연구 대상이 강릉시로 한정되어 있어 일반화에 한계가 있다. 다른 지역에도 동일한 결과가 적용될 수 있는지는 추가 검증이 필요해보이며, 데이터 수가 많지 않다는 점 또한 향후 보완이 필요하다고 생각한다. 그럼에도 불구하고 본 연구는 머신러닝을 활용한 산불 취약성 분석의 가능성을 제시하고, 향후 재난 예방 및 의사결정 지원 분야에 활용될 수 있는 실질적인 연구라고 평가할 수 있다.

[10] “기상 요인 및 시계열 패턴을 고려한 머신러닝 기반 의류 수요 예측 성능 비교 연구”에 대한 리뷰 보고서, 이유섭

1. 서론

본 보고서에서 분석한 논문은 이화정의 「기상 요인 및 시계열 패턴을 고려한 머신러닝 기반 의류 수요 예측 성능 비교 연구」이다. 이 논문은 숭실대학교 정보과학대학원 인공지능학과 석사학위논문으로, 2025년 12월에 제출되었다. 논문의 영문 제목은 A Study on Comparing the Performance of Machine Learning Based Clothing Demand Forecasting Considering Weather Factors and Time Series Patterns이다.

논문 검색은 “2025년 석사학위논문”, “머신러닝”, “수요 예측”, “판매 데이터”, “시계열 예측” 등의 키워드를 중심으로 진행하였다. 여러 후보 논문 중 이 논문을 선택한 이유는 머신러닝 수업의 지도학습 단원에서 다룬 트리 및 앙상블 기반 모델을 실제 산업 데이터에 적용한 사례이기 때문이다. 수업 11강에서는 Decision Tree, Random Forest뿐 아니라 GBM, XGBoost, LightGBM과 같은 트리 기반 앙상블 모델이 다뤄졌고, 이 논문 역시 GBDT, XGBoost, LightGBM을 사용해 의류 수요를 예측한다. 따라서 수업에서 배운 모델 개념이 실제 판매 데이터 예측 문제에서 어떻게 활용되는지 살펴보기에 적합하다고 판단하였다.

또한 이 논문은 단순히 모델만 비교하는 것이 아니라, 원본 판매 데이터를 일 단위 수요 데이터로 전처리하고, 기상·캘린더·시계열·스파이크 변수를 새롭게 만들어 모델 입력값으로 사용한다. 즉, 머신러닝 과목에서 강조되는 데이터 전처리, 파생 변수 생성, 지도학습 모델링, 성능 평가가 잘 드러나는 논문이라고 볼 수 있다.

2. 연구 개요

의류 산업은 수요 예측이 쉽지 않은 분야이다. 제품의 유행 주기가 짧고, 계절이나 날씨, 프로모션, 소비 트렌드에 따라 판매량이 크게 달라지기 때문이다. 예를 들어 겨울철에는 스웨터 수요가 증가하고, 여름철에는 반바지나 민소매 제품의 수요가 증가할 수 있다. 또 특정 기간에는 할인 행사나 재고 소진 등으로 인해 갑작스러운 수요 급증이 발생하기도 한다. 이러한 특성 때문에 단순히 과거 판매량만 보고 미래 수요를 예측하는 방식에는 한계가 있다.

이 논문의 목적은 의류 수요 예측에서 외생 변수를 추가했을 때 예측 성능이 얼마나 개선되는지 확인하는 것이다. 여기서 외생 변수란 판매량 자체가 아니라 판매량에 영향을 줄 수 있는 외부 요인을 의미한다. 논문에서는 기상 데이터, 날짜 기반 캘린더 변수, 과거 판매 흐름을 나타내는 시계열 변수, 갑작스러운 수요 증가를 나타내는 스파이크 변수를 외생 변수로 사용하였다.

연구 절차는 다음과 같이 정리할 수 있다. 먼저 Kaggle에 공개된 H&M Fashion Dataset을 수집하고, 원본 거래 로그를 제품군과 판매 채널 기준의 일 단위 판매량 데이터로 변환하였다. 이후 제품군을 상시형 제품과 계절형 제품으로 나누고, 온라인과 오프라인 판매 채널을 구분하였다. 여기에 Meteostat API를 통해 수집한 스웨덴 스톡홀름 지역의 기상 데이터를 결합하였다. 마지막으로 Baseline 모델과 외생 변수를 포함한 확장형 모델을 각각 구성한 뒤, GBDT, XGBoost, LightGBM 세 가지 모델의 예측 성능을 비교하였다.

3. 데이터

본 논문은 H&M Fashion Dataset을 활용하여 의류 수요를 예측하였다. 원본 데이터는 개별 거래 로그 형태였기 때문에, 연구에서는 이를 제품군·판매 채널·날짜 기준의 일 단위 수요 데이터로 변환하였다. 제품군은 티셔츠·바지와 같은 상시형 제품, 스웨터·반바지·민소매와 같은 계절형 제품으로 구분하였고, 판매 채널은 온라인과 오프라인으로 나누었다. 예측 목표는 향후 7일간의 누적 수요이다. 또한 판매량에 영향을 줄 수 있는 외부 요인을 반영하기 위해 Meteostat API에서 스웨덴 스톡홀름 지역의 기상 데이터를 수집하였다. 평균 기온, 최고·최저 기온, 일교차 등의 기상 변수와 함께 요일, 주차, 월 등의 캘린더 변수, lag와 rolling mean 같은 시계열 변수, 수요 급증을 나타내는 스파이크 변수를 생성하였다. 즉, 단순 판매량뿐 아니라 날씨, 날짜, 과거 판매 흐름, 갑작스러운 수요 증가 정보를 함께 모델 입력값으로 사용하였다.

<데이터 및 변수 구성>

구 분	내용	모델에서의 역할
판매 데이터	H&M Fashion Dataset, 제품군·채널별 일 단위 판매량	기본 수요 패턴 학습
기상 데이터	평균/최고/최저 기온, 일교차 등	계절형 제품 수요 설명
캘린더 변수	요일, 주차, 월	주기성과 계절성 반영
시계열 변수	lag, rolling mean	최근 판매 흐름 반영
스파이크 변수	spike_flag, spike_ratio 등	갑작스러운 수요 증가 반영

4. 모델 분석

본 논문은 의류 수요 예측을 위해 GBDT, XGBoost, LightGBM 세 가지 트리 기반 앙상블 회귀 모델을 사용하였다. 세 모델은 여러 개의 결정트리를 결합해 예측 오차를 줄이는 방식이며, 과거 판매량만 사용하는 Baseline 모델과 기상·캘린더·시계열·스파이크 변수를 포함한 확장형 모델의 성능을 비교하였다. 실험 결과, 외생 변수를 포함한 확장형 모델은 Baseline보다 평균 정확도가 약 6% 향상되었고, 평균 제공된 오차(RMSE)는 약 35% 감소하였다. 특히 XGBoost는 10개 실험 중 7개에서 가장 우수했으며, 전체 데이터 통합 실험에서 정확도 90.09%, 결정계수 0.96을 기록해 최종 예측 모델로 제안되었다.

입력 데이터 구성 2가지

- └─ Baseline: 과거 판매량만 사용
- └─ 확장형: 과거 판매량 + 외생 변수 사용

각 입력 데이터에 대해

- └─ GBDT 적용
- └─ XGBoost 적용
- └─ LightGBM 적용

5. 결론

본 논문은 의류 수요 예측에서 외생 변수를 추가하는 것이 예측 성능을 높이는 데 효과적이라는 점을 보여주었다. 연구에서는 과거 판매량만 사용하는 Baseline 모델과, 여기에 기상 변수, 캘린더 변수, 시계열 변수, 스파이크 변수를 추가한 확장형 모델을 비교하였다. 실험 결과 확장형 모델은 Baseline 모델보다 전반적으로 더 좋은 성능을 보였으며, 평균 정확도는 약 6% 향상되었고 RMSE는 약 35% 감소하였다. 이는 의류 판매량이 단순히 과거 판매량만으로 결정되는 것이 아니라, 날씨, 계절, 요일, 갑작스러운 수요 변화 같은 외부 요인의 영향을 크게 받는다는 점을 의미한다.

모델 비교 결과에서는 XGBoost가 가장 안정적인 성능을 보였다. 논문에서는 GBDT, XGBoost, LightGBM 세 가지 부스팅 기반 회귀 모델을 비교하였고, XGBoost는 10개 실험 중 7개에서 가장 좋은 결과를 보였다. 또한 전체 데이터를 통합한 실험에서 XGBoost는 정확도 90.09%, 결정계수 R^2 0.96을 기록하여 최종 예측 모델로 제안되었다. 여기서 R^2 0.96은 모델이 실제 수요 변동을 매우 높은 수준으로 설명했다는 의미이며, XGBoost가 다양한 제품군과 판매 채널에 비교적 안정적으로 적용될 수 있음을 보여준다.

이 논문의 특징은 단순히 여러 머신러닝 모델의 성능을 비교하는 데 그치지 않고, 데이터를 어떻게 구성하느냐가 예측 성능에 큰 영향을 준다는 점을 명확히 보여준다는 것이다. 원본 판매 데이터는 단순한 거래 로그였지만, 연구자는 이를 일 단위 수요 데이터로 변환하고, lag, rolling mean, 캘린더 변수, 기상 변수, 스파이크 변수 등을 생성하였다. 이러한 과정은 머신러닝에서 모델 선택만큼이나 데이터 전처리와 파생 변수 설계가 중요하다는 점을 잘 설명한다.

제가 생각하는 이 논문의 장점은 실제 서비스 개발과 연결하기 쉽다는 점이다. 모바일 쇼핑몰이나 이커머스 서비스에서는 상품이 얼마나 팔릴지 예측하는 것이 재고 관리, 발주, 물류, 프로모션 전략에 직접적인 영향을 준다. 이 논문처럼 판매 이력뿐 아니라 날씨, 요일, 계절성, 수요 급증 정보를 함께 반영하면 더 현실적인 예측 시스템을 만들 수 있다. 특히 개발자 관점에서는 단순히 모델을 학습시키는 것보다, 여러 출처의 데이터를 수집하고 정리하여 모델이 이해할 수 있는 입력 변수로 만드는 과정이 중요하다는 점을 확인할 수 있었다.

다만 한계도 있다. 연구 데이터는 H&M 브랜드와 스웨덴 스톡홀름 지역의 기상 데이터를 중심으로 구성되어 있어, 다른 브랜드나 국가의 의류 시장에 그대로 적용하기에는 추가 검증이 필요하다. 또한 실제 의류 수요에는 가격 할인, 광고, 재고 상태, 검색량, SNS 트렌드 등도 영향을 줄 수 있는데, 본 논문에서는 이러한 변수들이 충분히 반영되지는 않았다. 따라서 향후 연구에서는 프로모션 정보나 검색 트렌드, 재고 데이터를 추가하여 더 현실적인 수요 예측 모델을 구축할 수 있을 것이다.

종합하면, 이 논문은 머신러닝 기반 수요 예측에서 좋은 모델을 선택하는 것뿐만 아니라 좋은 데이터를 만드는 과정이 중요하다는 점을 보여주는 사례이다.

[11] “청년인구 유출에 따른 주거이동 영향요인에 관한 연구: 머신러닝 XGboost와 SHAP분석의 적용”에 대한 리뷰 보고서, 허운정

1. 서론

본 보고서에서는 「청년인구 유출에 따른 주거이동 영향요인에 관한 연구 : 머신러닝 XGBoost와 SHAP 분석의 적용」 논문을 분석하였다. 본 논문은 박재현, 강정규가 저술하였으며, 2026년 KCI 등재 학술지인 『토지주택연구(Land and Housing Review)』 제17권 제1호에 게재되었다. 논문은 DBpia를 통해 검색하였으며, 과제의 조건에 맞추어 최근(2025~2026년)에 발표된 논문 중 머신러닝 모델을 활용한 연구를 중심으로 탐색하였다.

검색 과정에서는 ‘머신러닝’, ‘XGBoost’, ‘SHAP’, ‘청년인구’, ‘주거이동’, ‘인구유출’ 등의 키워드를 활용하였다. 해당 키워드를 선정한 이유는 머신러닝 모델인 XGBoost를 실제 사회문제 분석에 적용한 사례를 다루고 있기 때문이다. 최근 수도권 집중 현상과 지방 소멸 문제는 우리 사회의 주요 이슈로 떠오르고 있으며, 특히 부산을 포함한 비수도권 지역의 청년인구 유출 문제는 지속적으로 관심을 받고 있다. 개인적으로 부산에서 성장한 후 취업을 위해 수도권으로 이동한 경험이 있어, 청년인구의 수도권 유출과 주거이동 문제를 더욱 현실적으로 체감할 수 있었다. 이러한 점에서 본 논문은 개인적인 경험과 사회적 현상이 맞닿아 있는 연구라고 판단하여 선정하였다.

2. 연구 개요

2.1 연구 필요성

우리나라는 수도권과 비수도권 간 경제·사회·문화·교육 여건의 격차가 심화되면서 청년인구의 수도권 집중 현상이 지속되고 있다. 이로 인해 지방은 인구 감소와 지역 쇠퇴, 지방 소멸 위험에 직면하고 있으며, 특히 청년층의 주거 이동은 이러한 문제를 가속화하는 주요 요인으로 작용하고 있다. 따라서 청년인구 유출의 원인을 파악하고 주거 이동에 영향을 미치는 요인을 분석하여 효과적인 청년정책과 지역 정주 정책을 마련할 필요가 있다.

2.2 연구 목적

본 연구의 목적은 부산·울산·경남 지역 청년층의 수도권 주거 이동 및 유출 현상을 분석하고, 이에 영향을 미치는 결정요인을 규명하는 것이다. 이를 위해 청년 실태조사 데이터를 활용하고, 머신러닝 모델인 XGBoost와 설명가능한 인공지능(XAI) 기법인 SHAP 분석을 적용하여 청년들의 주거 이동에 영향을 주는 경제적, 생활·환경적, 사회·심리적 요인을 다차원적으로 분석하였다. 또한 분석 결과를 바탕으로 지방 정부의 청년 정착 및 인구 유출 방지를 위한 정책적 시사점을 제시하고자 하였다.

2.3 연구 수행절차

- 1) 부산·울산·경남 지역에서 실시한 청년 실태조사 자료(2020, 2022, 2023년)를 수집하였다.
- 2) 수도권 주거 이동 의향을 종속변수로 설정하고, 개인적 요인, 경제적 요인, 생활·환경적 요인, 사회·심리적 요인 등 총 33개의 독립변수를 선정하였다.
- 3) 데이터 전처리 및 변수 선정을 수행한 후 학습 데이터(80%)와 테스트 데이터(20%)로 분할하였다.
- 4) 머신러닝 모델인 XGBoost를 적용하여 청년들의 수도권 주거 이동 의향을 예측하였다.
- 5) 5-Fold Cross Validation을 통해 모델을 검증하고 최적의 하이퍼파라미터를 설정하였다.
- 6) 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 Score, AUC 등의 지표를 활용하여 모델 성능을 평가하였다.

- 7) SHAP 분석을 수행하여 각 변수의 중요도와 영향력을 해석하였다.
- 8) 분석 결과를 바탕으로 청년인구 유출 및 주거 이동에 대한 정책적 시사점을 도출하였다.

3. 데이터

3.1 데이터 수집

본 연구는 부산광역시, 울산광역시, 경상남도에서 2020년부터 2023년까지 실시된 청년 실태조사 데이터를 활용하였다. 연구자는 지역별 청년 실태조사 원자료(raw data)를 수집한 후, 수도권 주거 이동 의향 대상자 청년들을 대상으로 분석을 수행하였다.

<표1> 연구 데이터 구성

지역	조사연도	전체 조사인원	최종 분석대상
부산	2022~2023	5,826명	3,434명
울산	2020,2023	1,500명	265명
경남	2020,2023	2,024명	356명
합계	-	9,350명	4,055명

조사 대상 규모는 부산광역시 5,826명(2022년 3,008명, 2023년 2,818명), 울산광역시 1,500명(2020년 1,000명, 2023년 500명), 경상남도 2,024명(2020년 1,018명, 2023년 1,006명)으로 구성되었다. 이 중 전체 청년 실태 조사자 중에서 수도권 주거 이동 의향 대상자 청년을 추출하여 최종 분석에 활용하였으며, 부산 3,434명, 울산 265명, 경남 356명의 데이터를 대상으로 실증분석을 수행하였다.

3.2 데이터 전처리

연구에 사용된 변수는 종속변수와 독립변수로 구분하였다. 종속변수는 수도권 주거 이동 의향으로 설정하였으며, 독립변수는 개인적 요인, 경제적 요인, 생활환경적 요인, 사회·심리적 요인 등 총 4개 영역, 33개의 세부 변수로 구성하였다. 주요 변수에는 성별, 연령, 학력, 고용 형태, 소득 수준, 주거 환경 만족도, 교통 및 문화 인프라 만족도, 청년정책 참여 경험, 삶의 질 만족도 등이 포함되었다.

데이터 전처리 과정에서는 청년 실태조사 원자료에서 연구 목적에 맞는 응답자와 변수를 추출하고, 머신러닝 분석이 가능하도록 데이터를 정리하였다. 이후 전체 데이터를 학습 데이터(80%)와 테스트 데이터(20%)로 분할하였으며, 5-Fold Cross Validation 기법을 적용하여 데이터 분포의 편향을 최소화하고 모델의 일반화 성능을 검증하였다.

4. 모델 분석

4.1 XGBoost 모델

XGBoost(eXtreme Gradient Boosting)는 여러 개의 의사결정나무(Decision Tree)를 순차적으로 학습시키는 앙상블 머신러닝 기법이다. 이전 모델의 예측 과정에서 발생한 오차를 다음 모델이 보완하는 방식으로 학습이 진행되며, 이를 반복하여 예측 성능을 향상시킨다. XGBoost는 변수 간의 복잡한 상호작용과 비선형 관계를 효과적으로 분석할 수 있으며, 높은 예측 정확도와 빠른 학습 속도를 제공하는 것이 특징이다. 또한 과적합을 방지하는 기능을 갖추고 있어 다양한 분야의 예측 및 분류 문제에 널리 활용되고 있다. 본 논문에서는 청년인구 유출과 주거 이동이 경제적 요인, 생활환경적 요인, 사회·심리적 요인 등 다양한 변수의 영향을 받는 복합적인 사회현상이라는 점에 주목하였다. 이에 연구자는 변수 간의 복

잡한 관계를 효과적으로 분석할 수 있는 XGBoost 모델을 활용하여 청년들의 수도권 주거 이동 의향을 예측하고 주요 영향 요인을 분석하였다. 연구자는 XGBoost 모델의 성능을 평가하기 위해 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 Score, AUC 등의 평가지표를 활용하였다. 지역별 분석 결과 경남 지역 모델이 가장 높은 AUC를 보였으며, 울산 지역 모델은 가장 높은 정확도를 나타냈다. 주요 성능 결과는 아래와 같다.

<표2> 지역별 XGBoost 모델 성능 비교

지역	Accuracy	AUC
부산	0.691	0.680
울산	0.849	0.644
경남	0.792	0.826

4.2 SHAP 분석

SHAP(Shapley Additive Explanations)은 머신러닝 모델의 예측 결과를 설명하기 위한 XAI(설명가능한 인공지능) 기법이다. 단순히 변수의 중요도만 제시하는 것이 아니라 각 변수가 예측 결과에 긍정적 또는 부정적으로 얼마나 영향을 미쳤는지 시각적으로 확인할 수 있다는 장점이 있다. 본 연구에서는 XGBoost 모델의 분석 결과를 해석하기 위해 SHAP 분석을 수행하였다. 이를 통해 각 변수가 수도권 주거 이동 의향에 미치는 영향력과 중요도를 정량적으로 확인할 수 있었으며, 청년정책 참여 경험, 창업 의향, 삶의 질 만족도 등의 주요 변수를 도출하였다.

5. 결론

5.1 연구 결과

본 연구는 부산·울산·경남 지역 청년들의 수도권 주거 이동 의향에 영향을 미치는 요인을 분석하기 위해 XGBoost와 SHAP 분석을 수행하였다. 분석 결과, 청년들의 수도권 이동은 단순히 소득이나 고용과 같은 경제적 요인만으로 결정되지 않았으며, 삶의 질, 지역 소속감, 청년정책 참여 경험, 창업 의향, 주거 환경 만족도, 심리적 안정감 등 다양한 요인이 복합적으로 작용하는 것으로 나타났다.

지역별로는 부산의 경우 지방정부에 대한 소속감과 박탈감·좌절감 경험이 중요한 변수로 나타났으며, 울산은 창업 의향과 일자리 만족도가 주요 요인으로 분석되었다. 경남은 청년정책 참여 경험과 삶의 질 만족도가 가장 큰 영향을 미치는 변수로 나타났다. 또한 XGBoost 모델의 성능 평가 결과 경남 지역 모델이 가장 우수한 예측 성능을 보였으며, 이를 통해 지역별 청년 유출 원인이 서로 다르게 나타날 수 있음을 확인하였다.

5.2 논문의 특징 및 평가

본 논문의 가장 큰 특징은 사회문제인 청년인구 유출 현상을 머신러닝 기법을 활용하여 분석하였다는 점이다. 기존 연구들이 회귀분석과 같은 전통적인 통계 기법을 주로 활용한 것과 달리, 본 연구는 XGBoost를 적용하여 변수 간의 복잡한 상호작용과 비선형 관계를 분석하였다. 또한 SHAP 분석을 통해 머신러닝 모델의 예측 결과를 해석함으로써 단순한 예측에 그치지 않고 주요 영향요인을 직관적으로 제시하였다는 점도 의미가 있다고 생각한다.

특히 부산에서 성장한 후 취업을 위해 수도권으로 이동한 경험이 있는 입장에서, 청년인구 유출 문제가 단순히 일자리나 소득만의 문제가 아니라 삶의 질, 정책 체감도, 지역 소속감 등 다양한 요소와 관련되어 있다는 점이 인상적이었다. 또한 사회과학 분야에서도 머신러닝 모델을 활용하여 복잡한 사회현상을 분석할 수 있다는 점을 확인할 수 있었다.

다만 본 연구는 부산·울산·경남 지역을 중심으로 분석이 이루어졌기 때문에 연구 결과를 전국 단위로 일반화하기에는 한계가 있다고 생각한다. 그럼에도 불구하고 실제 사회문제에 머신러닝과 설명가능한 인공지능(XAI)을 적용한 사례라는 점에서 학술적·실무적 가치가 있는 연구라고 평가한다.

[12] “팝업스토어 브랜드 경험이 소비자 반응에 미치는 영향: 문장 임베딩 기반 텍스트 마이닝과 머신러닝 예측 모델 개발을 중심으로”에 대한 리뷰 보고서, 주미리

1. 서론

본 보고서에서 검토한 논문은 장이화의 「팝업스토어 브랜드 경험이 소비자 반응에 미치는 영향: 문장 임베딩 기반 텍스트 마이닝과 머신러닝 예측 모델 개발을 중심으로」이다. 이 논문은 2025년 6월 숙명여자 대학교 대학원 경영학과 비즈니스애널리틱스 전공 석사학위논문으로 제출되었다.

검색 조건은 최근 연도인 2025~2026년, 석사학위논문, 키워드 “머신러닝”, “텍스트 마이닝”, “문장 임베딩”, “소비자 반응”, “예측 모델”로 설정하였다. 이 논문은 실제 소비자 후기 데이터를 수집·전처리하고, 문장 임베딩과 머신러닝 모델을 적용하여 방문 만족도를 예측했다는 점에서 과제 주제에 적합하다고 판단하였다.

2. 연구 개요

이 논문은 팝업스토어가 단순한 판매 공간이 아니라 브랜드 경험과 소비자 반응을 유도하는 마케팅 채널로 변화했다는 점에 주목한다. 기존 연구는 설문조사나 사례연구 중심이 많았으나, 본 연구는 소비자가 자발적으로 작성한 블로그 후기 데이터를 활용해 실제 반응을 정량적으로 분석하고자 하였다.

연구 목적은 팝업스토어에서의 브랜드 경험이 소비자 만족도와 온라인 구전효과에 미치는 영향을 분석하고, 텍스트 기반 머신러닝 모델로 방문 만족도를 예측하는 것이다. 연구 절차는 데이터 수집, KR-SBERT 기반 문장 임베딩, KNU 감성사전 기반 만족도 산출, 혼합효과 회귀분석, 머신러닝 모델 성능 비교 순으로 진행되었다.

3. 데이터

해당 논문은 팝업스토어 방문자의 실제 소비자 반응을 분석하기 위해 네이버 블로그 후기 텍스트를 주요 데이터로 활용하였다. 데이터 수집 기간은 2024년 1월부터 2025년 3월까지이며, 분석 대상은 팝업 전문 플랫폼 Popply에 등록된 사례 중 조건을 만족하는 40개의 팝업스토어이다. 최종적으로 수집된 블로그 후기는 총 1,298건이며, 브랜드 언급량과 온라인 구전효과 분석을 위해 썸트렌드 자료도 함께 사용하였다.

<표 1> 연구에 활용된 데이터 현황

구 분	데이터종류	건수	수집방법	전처리방법
팝업스토어 기본정보	팝업스토어명, 브랜드명, 기간, 장소, 조회수	40개 팝업스토어	Popply 플랫폼 활용	팝업스토어 고유 ID 기준 정리
방문후기 텍스트	네이버 블로그 본문 텍스트	1,298건	MAKE와 Replit을 활용한 URL 기반 크롤링	특수문자, 중복 공백, 해시태그 제거 및 문장 단위 분할
브랜드언급량	긍정·부정·중립 언급량, 인스타그램 언급량	브랜드별 온라인 언급 자료	썸트렌드 활용	팝업 전후 eWOM 변동량 계산
브랜드경험기준 문장	감각적·정서적·행동적·지적 경험 시드 문장	차원별 11~15개	연구자가 대표 문장 구성	KR-SBERT 임베딩 후 기준 벡터 생성

수집된 블로그 텍스트는 분석 전에 불필요한 특수문자, 중복 줄바꿈, 공백, 해시태그 등을 제거하였다.

이후 문장 단위로 분할하고, 팝업스토어 예약, 주차, 대기 등 연구 목적과 직접 관련이 낮은 정보성 문장은 제외하였다. 정제된 문장은 KR-SBERT를 활용해 브랜드 경험 차원별 기준 문장과의 코사인 유사도를 계산하는 데 사용되었고, 감성사전 분석을 통해 방문 만족도 점수로 변환되었다.

4. 모델 분석

해당 논문은 KR-SBERT 기반 문장 임베딩, KNU 감성사전 기반 감성분석, 혼합효과 회귀모형, 머신러닝 회귀 예측 모델을 활용하였다. KR-SBERT는 블로그 후기 문장과 브랜드 경험 차원별 기준 문장 간 코사인 유사도를 계산하여 감각적, 정서적, 행동적, 지적 경험 점수를 산출하는 데 사용되었다.

KNU 감성사전은 후기 텍스트의 긍정어와 부정어를 바탕으로 방문 만족도를 수치화하는 데 활용되었다. 이후 혼합효과 회귀모형을 통해 브랜드 경험 차원이 만족도에 미치는 영향을 분석하고, Gradient Boosting Regressor, Random Forest, XGBoost, Linear Regression 모델을 비교하였다. 모델 비교 결과 Gradient Boosting Regressor가 RMSE 7.002288, R^2 0.524939로 가장 우수한 성능을 보였다.

<표 2> 머신러닝 모델별 성능 비교

모델	RMSE	R^2
Gradient Boosting Regressor	7.002288	0.524939
Random Forest	7.969463	0.384642
XGBoost	8.236089	0.342778
Linear Regression	11.740888	-0.335586

이 결과를 보면 소비자 만족도 예측에는 단순 선형모델보다 비선형 관계를 잘 포착할 수 있는 앙상블 기반 모델이 더 적합하다는 것을 알 수 있다. 특히 Gradient Boosting Regressor는 이전 모델의 오차를 보완해가며 학습하는 방식이기 때문에, 브랜드 경험과 만족도 사이의 복잡한 관계를 더 효과적으로 반영한 것으로 해석할 수 있다. 또한 논문은 SHAP 분석을 통해 예측 결과에 영향을 주는 변수를 해석하고자 하였는데, 이는 머신러닝 모델의 블랙박스 문제를 보완하려는 시도로 볼 수 있다.

5. 결론

연구 결과, 무형성이 높은 브랜드일수록 팝업스토어 운영 전후 긍정 언급이 더 크게 증가하는 경향을 보였다. 또한 콜라보레이션 팝업스토어는 감정 방향성 측면에서, 단독 팝업스토어는 언급량 측면에서 더 긍정적인 효과를 보였다. 브랜드 경험 차원 중 감각적 경험과 정서적 경험은 방문 만족도에 긍정적인 영향을 주었고, 행동적 경험은 일정 수준을 넘으면 만족도에 부정적 영향을 줄 수 있는 비선형 관계가 확인되었다. 본인이 생각한 이 논문의 특징은 네이버 블로그 후기라는 비정형 텍스트 데이터를 문장 임베딩과 감성분석으로 수치화하고, 이를 머신러닝 예측 모델에 연결했다는 점이다. 특히 여러 모델의 성능을 비교하여 Gradient Boosting Regressor가 가장 적합하다는 결과를 제시한 점에서 모델 분석 과제에 적합하다. 다만 블로그 후기 데이터는 특정 소비자층이나 브랜드에 편중될 수 있고, 감성사전 기반 분석은 문맥이나 반어적 표현을 완전히 반영하기 어렵다는 한계가 있다. 그럼에도 이 논문은 텍스트 마이닝과 머신러닝을 실제 마케팅 문제에 적용한 사례로서 의미가 있다.

[13] “의류 판매량 장기 예측을 위한 트랜스포머 기반 시계열 예측 모델에 대한 리뷰 보고서, 나상원

1. 서론

본 보고서에서 검토한 논문은 이진우, 박태남, 조용원, 정석운, 황정현, 안태영, 문혜리, 김환호, 김성범 (2025)의 “의류 판매량 장기 예측을 위한 트랜스포머 기반 시계열 예측 모델”이다. 해당 논문은 대한산업 공학회지(Journal of the Korean Institute of Industrial Engineers, JKIIIE) 제51권 제1호(pp.48-60)에 2025년 2월 게재되었으며, DOI는 10.7232/JKIIIE.2025.51.1.048이다. 저자 소속은 고려대학교 산업경영 공학과(이진우, 박태남, 조용원, 김성범)와 한세실업(정석운, 황정현, 안태영, 문혜리, 김환호)으로 구성된 산학 협력 연구팀이다. 본 논문은 DBpia(www.dbpia.co.kr)에서 검색 기간 2025~2026년, 석박사 학위논문, 키워드 '머신러닝+의류' 조건으로 검색하여 선정하였다. 키워드를 이와 같이 설정한 이유는 의류 업계 종사자로서 머신러닝이 재고 관리 및 수요 예측 등 실무 의사결정에 어떻게 활용되는지 파악하기 위함이다. 해당 논문은 공개된 벤치마크 데이터가 아닌 실제 국내 패션 유통사 데이터를 활용한 실증 연구라는 점에서 학문적 기여와 산업 적용 가능성을 동시에 갖추어 리뷰 대상으로 선정하였다.

2. 연구 개요

2.1 연구 필요성

수요 예측은 생산, 재고 관리, 유통 계획 등 기업 운영 전반에 필수적인 요소로, 정확한 예측은 초과 재고 및 재고 소진에 따른 비용을 줄이고 공급망 효율과 기업 수익성을 높이는 데 중요한 역할을 한다. 의류 산업은 다음과 같은 세 가지 특성으로 인해 수요 예측이 특히 어려운 분야이다. 첫째, 의류 상품은 디자인, 원자재 조달, 생산, 운송 등 여러 단계를 거치므로 리드타임이 길어 장기적인 수요 예측이 필수적이다. 둘째, 패션 트렌드와 날씨에 민감하게 반응하여 계절성이 두드러지며, 매 시즌 고객 선호도가 빠르게 변화한다. 셋째, 판매량이 다양한 요인의 복합적 영향을 받아 급격히 변동하기 때문에 예측이 어렵다. 기존의 딥러닝 기반 시계열 예측 연구들은 대부분 한 달 이내의 단기 예측이나 신규 상품 예측에 집중하였으며, 판매량 내 급격한 변동성을 충분히 반영하지 못하는 한계가 있었다.

2.2 연구 목적

본 논문은 의류 상품 판매량 데이터의 고유한 특성인 장기 리드타임, 뚜렷한 계절성과 추세, 급격한 변동성을 효과적으로 반영하는 장기 시계열 예측 모델 PatchTSDD(PatchTST using Time Stamp and Denoised input with Dilate)를 제안하는 것을 목적으로 한다. 전문가 의견에 의존하지 않고 판매량 데이터만으로 의류 판매 패턴을 정밀하게 포착하며, 기존 딥러닝 모델이 다루지 못했던 급격한 변동 구간을 정확히 예측하는 것을 목표로 한다.

2.3 수행 절차

연구는 다음 절차로 수행되었다. 먼저 국내 의류 제조 전문 기업 한세실업으로부터 실제 레깅스 판매 시계열 데이터를 수집하였다. 이후 Denoising Autoencoder를 우선 학습하여 입력 데이터의 잡음을 제거하고 기저 판매 트렌드를 추출하였다. 다음으로 주(week)와 월(month) 단위의 시점 정보를 주기함수로 인코딩하여 스무딩된 판매 데이터와 함께 PatchTST 모델의 입력으로 구성하였다. 학습 시에는 형태 유사도와 시간 왜곡을 동시에 최소화하는 DILATE 손실함수를 적용하였다. 마지막으로 ARIMA, LSTM, GRU, Informer, PatchTST 등 11개의 기존 모델과 비교 실험을 수행하고 각 구성 요소의 기여도를 Ablation Study로 검증하였다.

3. 데이터

해당 논문에서 활용된 데이터는 국내 의류 제조 전문 기업 한세실업에서 수집한 실제 레깅스 판매량 시계열 데이터이다. 데이터는 2020년 2월부터 2024년 3월까지 총 221주에 걸친 주차별 판매량으로 구성되며, 최소 2~3년의 판매 이력이 누적된 핵심 레깅스 상품 83개 SKU가 포함되었다. 각 상품에는 상품코드, 스타일, 색상, 사이즈의 4가지 특성 변수가 기록되었으며, 스타일은 길이에 따라 A(5부), B(7부), C(9부)의 3가지로 구분된다.

데이터 수집은 기업 협력 연구를 통해 이루어졌다. 전처리 단계에서는 슬라이딩 윈도우 기법을 활용하여 데이터셋을 구축하였는데, 슬라이딩 윈도우란 전체 시계열 위에 일정 크기의 창을 한 칸씩 밀면서 입력-예측 쌍을 반복 생성하는 기법으로, 221주의 데이터로 수천 개의 학습 샘플을 만들어낼 수 있다. 입력 윈도우 길이와 예측 구간은 모두 24주로 설정하였으며, 이는 의류 산업의 실제 리드타임을 반영한 것이다. 학습-검증-테스트 데이터는 마지막 24주를 테스트로 고정하고 나머지를 0.85 대 0.15 비율로 분할하였다. 또한 유사한 판매 패턴을 보이는 상품들을 스타일 단위로 그룹화하여 학습함으로써 예측 성능과 연산 효율을 동시에 높였다.

4. 모델 분석

해당 논문은 PatchTSDD라는 새로운 장기 시계열 예측 모델을 제안하며, 이는 기반 모델인 PatchTST에 세 가지 구성 요소를 추가·변경한 구조이다. 이름 자체가 이를 반영하는데, PatchTST에 Denoising과 DILATE를 결합하여 PatchTSDD로 명명하였다. 학습은 Denoising Autoencoder를 먼저 독립적으로 학습한 뒤, 재구성된 입력 데이터로 PatchTST를 학습하는 순서로 진행된다.

4.1 기반 모델: PatchTST (Transformer)

PatchTST는 입력 시계열을 일정 길이의 패치 단위로 묶어 트랜스포머 인코더에 입력하는 모델이다. 기존 트랜스포머는 모든 시점이 서로를 비교하는 구조여서 입력 길이 L 에 대해 $O(L^2)$ 의 연산이 필요하다. PatchTST는 여러 시점을 패치로 묶어 토큰 수를 L/S 개로 줄이므로 연산 복잡도가 $O(L^2/S^2)$ 으로 감소한다. 예를 들어 $S=4$ 이면 연산량이 16분의 1로 줄면서도 패치 내 지역적 패턴 정보는 그대로 유지된다. 또한 다변량 시계열을 채널 독립(channel independence) 방식으로 처리하는데, 이는 각 변수를 분리하여 해당 변수 자체의 시간 패턴만 집중적으로 학습하는 방식이다. 변수들을 한꺼번에 섞어 학습하면 장기로 갈수록 변수 간 관계가 불안정해져 성능이 저하되는데, 채널 독립 방식은 이를 방지하여 장기 예측 안정성을 높인다. 아울러 RevIN(Reversible Instance Normalization)을 적용하여 학습-테스트 데이터 간 분포 차이 문제를 해결하였다. RevIN은 입력 시 각 시퀀스의 평균·분산을 기록해 정규화하고, 예측 후 이를 역변환하여 원래 스케일로 복원하는 방식이다.

4.2 Denoising Autoencoder (입력 스무딩)

다층 퍼셉트론 구조 기반의 Denoising Autoencoder는 입력 시퀀스에 가우시안 노이즈를 주입한 뒤 원본 시퀀스를 복원하도록 학습함으로써 추세와 무관한 잡음을 제거하는 스무딩 효과를 만들어낸다. 이때 노이즈 크기는 입력 데이터의 평균에 척도인자를 곱한 방식으로 결정하여 시퀀스마다 다른 데이터 분포를 고려하였다. 재구성된 시퀀스는 이후 PatchTST의 입력으로 사용되어 모델이 핵심 판매 패턴에만 집중할 수 있도록 입력 품질을 향상시킨다.

4.3 Timestamp Embedding (계절성 반영)

주(week)와 월(month) 단위의 시점 정보를 주기성을 갖는 수식으로 인코딩하여 수치 벡터로 변환하고, 이를 스무딩된 판매 시퀀스와 결합하여 PatchTST의 임베딩 레이어를 통해 입력한다. 이를 통해 모델이

전역적인 시간 관계와 계절적 패턴을 명시적으로 학습할 수 있다. Ablation Study 결과 시점 정보를 제거했을 때 전체 WAPE가 62.92% 상승하여, 세 구성 요소 중 계절성 학습에 가장 결정적인 기여를 하는 것으로 확인되었다.

4.4 DILATE 손실함수 (변동성 반영)

기존 MSE 손실함수는 예측값과 실제값의 수직 거리만 최소화하여 급격한 판매 변동의 형태와 발생 시점을 정확히 예측하는 데 한계가 있다. DILATE(Distortion Loss including shApe and TimE)는 SoftDTW를 활용한 형태 유사도 손실항과 TDI(Time Distortion Index) 기반 시간적 차이 손실항을 하이퍼파라미터 α 로 선형 결합한 복합 손실함수이다. 본 연구에서는 급격한 변동에 대한 가중치를 높이기 위해 α 를 0.7로 설정하였으며, 이를 통해 판매량 급등·급락의 형태와 발생 시점을 동시에 고려한 학습이 가능해진다.

5. 결론

5.1 연구 결과

실험 결과, 제안 모델 PatchTSDD는 ARIMA, LSTM, GRU, CNN-LSTM, TCN, Seq2Seq Attention, Informer, Autoformer, DLinear, PatchTST 등 11개의 기존 시계열 예측 모델과의 비교에서 전체 스타일에 걸쳐 가장 우수한 성능을 달성하였다. 특히 여름철 판매량이 높아 계절성이 뚜렷한 스타일 A와 B 상품에서 월등한 성능을 보였으며, 기반 모델 PatchTST 대비 스타일 A, B, C에서 각각 MAE 기준 41.06%, 24%, 13.03% 향상을 달성하였다. Ablation Study 결과, 시점 정보 제거 시 전체 WAPE가 62.92% 상승하여 가장 큰 기여를 하였으며, Denoising Autoencoder와 DILATE 손실함수 역시 각각 독립적으로 예측 성능 향상에 기여함이 정량적으로 확인되었다. 또한 스타일별 그룹 학습이 색상별·사이즈별 그룹화보다 우수한 성능(WAPE 49.86)을 보여 유사한 판매 패턴을 기준으로 상품을 묶는 방식의 효과를 입증하였다.

5.2 논문의 특징 및 평가

의류 업계 종사자 관점에서 이 논문의 가장 큰 특징은 공개 벤치마크 데이터가 아닌 실제 기업(한세실업) 데이터로 검증한 실증 연구라는 점이다. 이는 학문적 설득력과 현업 즉시 적용 가능성을 동시에 갖추게 한다. 특히 모델 설계 측면에서 의류 도메인의 특성인 계절성, 트렌드 민감도, 급격한 이벤트성 변동을 각각 Timestamp Embedding, Denoising Autoencoder, DILATE 손실함수로 명확히 대응하는 구조가 인상적이다. Ablation Study를 통해 각 모듈의 기여도를 독립적으로 검증한 점은 연구의 신뢰성을 높이며, 현업에서 모델을 부분적으로 도입할 때의 판단 근거를 제공한다는 점에서도 실용적이다. 원자재 주문 시점 결정, 시즌별 생산 수량 계획, 재고 과잉·품절 예방 등 의류 업계 핵심 실무 과제에 직접 활용 가능한 구조라는 점에서 높이 평가한다.

다만 몇 가지 한계점도 존재한다. 데이터가 비공개이므로 타 연구자의 재현 실험이 어려우며, 레깅스라는 단일 품목에 국한된 실험이라 상의, 하의, 아우터 등 다른 카테고리로의 일반화 가능성이 불확실하다. 또한 SNS 트렌드, 날씨, 마케팅 이벤트 등 판매량에 직접 영향을 미치는 외생 변수를 반영하지 못한 점은 실무 환경과의 괴리를 만든다. 논문 스스로도 향후 날씨·환율 등 연관 변수 추가와 시계열 군집화 기법 적용을 통해 성능을 더욱 향상시킬 수 있다고 제시하고 있다. 종합적으로, 이 논문은 패션·의류 업계의 수요 예측 고도화를 위한 실질적인 방법론을 제시한 연구로서 재고 최적화와 판매 전략 수립에 직접 활용 가능한 가치를 지닌다고 평가한다.

[14] “전자결제 사기 탐지를 위한 신뢰도·시간 가중치 결합 부스팅 모델”에 대한 리뷰 보고서, 김예지

1. 서론

본 보고서는 현대 금융 및 보안 도메인에서 가장 치명적인 위험 요소로 꼽히는 이상금융거래를 차단하기 위해 제안된 최신 머신러닝 방법론 논문을 분석하고 평가한 리뷰 보고서이다. 리뷰 대상이 되는 원본 연구의 제목은 『전자결제 사기 탐지를 위한 신뢰도·시간 가중치 결합 부스팅 모델』이며, 저자는 서강대학교 AI·SW 대학원 데이터사이언스·인공지능전공의 유승연이다. 해당 논문을 발굴하기 위해 국내 학위논문 및 학술지 검색 사이트인 RISS(한국교육학술정보원)와 DBpia를 활용했고, 검색 조건으로는 '학위논문', '발행연도 최근 1년' 필터를 적용했다. 검색 시 설정한 핵심 키워드는 '머신러닝, 추론 학습' 을 결합해서 도출했다.

이 논문을 최종 리뷰 대상으로 선택한 사유는 다음과 같다. 현재 제출자가 개인 연구로 진행 중인 석사 학위 연구는 소형 언어 모델(SLM)에 재귀적 루프(Recursive Loop)를 두어 성능 개선을 도모할 때, 모델의 크기 및 스케일에 따라서 루프의 효과가 구체적으로 어떻게 다르게 나타나는지 확인하고 그 차이와 한계를 규명하는 실험이다. 본 논문이 라벨 지연 환경에서 발생하는 데이터 왜곡 문제를 복잡한 딥러닝 모델로 대체하는 대신 Boosting 모델의 장점을 유지하면서 최소한의 비용으로 완화하는 현실적인 경량 개선 방안을 제시하는 점이 소형 언어 모델에서의 성능 개선을 시도한 본인의 실험 목적과 유사한 점이 있어 깊은 관심이 생겼고, 이에 본 논문을 최종 리뷰 대상으로 선정했다.

2. 연구 개요

2.1 연구의 필요성

전자결제 및 신용카드 거래 사기 탐지 실무 환경에서는 거래가 발생하는 시점과 해당 거래가 최종 사기로 확정되어 시스템에 기록되는 시점 사이에 수일에서 수십 일의 시차가 발생하는 라벨 지연(Label Delay) 문제가 필연적으로 발생한다. 이로 인해 가장 최신의 거래 데이터들은 사기 여부 라벨이 불완전하거나 누락된 채 모델 학습에 포함되게 되며, 이는 머신러닝 가중치 최적화 과정을 심각하게 왜곡하고 탐지 성능을 저하시키는 원인이 된다. 실제 금융 현장에서는 구현과 유지보수가 용이하고 CPU 환경에서도 고속으로 가동되는 부스팅(Boosting) 모델들이 널리 활용되고 있으나, 기존의 알고리즘들은 이러한 시간적 라벨 왜곡을 자체적으로 반영하지 못하는 치명적인 한계를 지니고 있어 새로운 방법론의 도입이 절실한 실정이다.

2.2 연구의 목적

본 연구의 목적은 실무에서 검증된 기존 부스팅 모델(XGBoost, LightGBM, CatBoost)의 높은 계산 효율성과 해석 가능성이라는 장점을 그대로 보존하면서 라벨 지연으로 인한 학습 왜곡을 손실 함수 수준에서 원천 차단하는 경량 개선 프레임워크를 제안하는 것이다. 이를 위해 임시 가상 라벨(Proxy Label)을 도입하고, 데이터의 예측 불확실성을 계량화한 신뢰도 가중치(Confidence Weight)와 사기 패턴의 최신 트렌드를 반영하는 시간 가중치(Time Decay Weight)를 수리적으로 결합해서 실무 환경에 즉시 도입 가능한 최적의 시간 윈도우 가이드라인을 제공하는 것을 최종 목적으로 설정했다.

2.3 연구 수행 절차

연구는 논문에서 제시한 파이프라인에 따라 크게 네 단계의 절차로 수행된다. 첫째, Stage 0(Data Preparation)에서는 거래 데이터(Transaction)와 신원 정보(Identity)를 TransactionID를 기준으로 병합

하고, 결측 처리 및 시간 변수(rel_days) 생성 등 피처 엔지니어링을 수행해 시계열 구조를 복원한다. 또한 라벨 지연 현상을 통제하기 위해 라벨 완성 기간(W_days)을 설정하고 라벨이 확정된 학습용 L_set과 라벨이 불완전한 최신 거래 U_set으로 분리하는 전처리 환경을 구축한다.

둘째, Stage 1(Base Model Training)에서는 라벨이 확정된 L_set을 활용해 XGBoost, LightGBM, CatBoost 등 1차 Boosting 모델을 학습하고, 해당 모델의 예측 확률 p를 기반으로 Confidence Weight를 생성한다. 셋째, Weight Construction Module에서는 각 데이터의 라벨 예측 불확실성을 정량화한 신뢰도 가중치 $\omega(p)$ 와 거래 발생 시점의 최신성을 반영한 시간 가중치 $\tau(t)$ 를 결합하여 최종 sample_weight를 산출한다. 넷째, Stage 2(Final Model Training)에서는 L_set과 Pseudo Label이 부여된 U_set을 통합하고, 생성된 가중치를 반영해 2차 모델을 학습해서 최종 Fraud Prediction을 수행한다. 이후 가중치별 기여도를 검증하는 소거 연구(Ablation Study)와 시간 윈도우(W_days)별 탐지 지표 분석을 통해 실무 최적화 조건을 규명하고 결론을 도출한다.

3. 데이터

3.1 데이터 종류 및 건수

본 연구에서 사용한 데이터는 IEEE-CIS Fraud Detection 대회(Kaggle, 2019)에서 제공되는 신용카드 거래 데이터로, 사기 탐지 분야의 대표적인 벤치마크 데이터이다. Transaction 데이터와 Identity 데이터 두 파일로 구성되며, 병합 전 Transaction 파일 기준 총 6,362,620건 중 약 3.5%(약 21만 건)만이 사기로 라벨링되어 있어 극단적인 클래스 불균형 구조를 반영하고 있다.

3.2 수집 및 전처리 방법

총 434개의 익명화된 피처 중 결측률 90% 이상이거나 해석 불가능한 변수를 제거하고, TransactionID를 기준으로 두 데이터를 병합한 뒤 거래 시각 기준으로 정렬해서 시계열 구조를 복원했다. 수치형 변수는 로그 변환 및 표준화를 적용했고, 범주형 변수는 LightGBM과 CatBoost의 내부 처리 기능을 활용했다. 전처리의 핵심은 라벨 지연 제어를 위한 L-set과 U-set의 분리이다. 라벨이 0으로 오염된 최신 거래 구간을 U-set으로 제외하고 라벨이 확정된 데이터만으로 L-set을 구성해서 정보 누수를 방지했다. 또한 거래 금액 변화율, 고객별 거래 패턴 통계, Merchant Risk Proxy, 지역 불일치 지표(Region Mismatch Score) 등 네 가지 도메인 기반 파생 변수를 추가로 생성했다. 모든 실험은 AWS EC2 환경에서 random seed 42로 고정해 3회 반복 수행한 평균값을 최종 지표로 보고했다.

4. 모델 분석

본 연구에서는 제안된 가중 결합 프레임워크를 이식하고 상호 성능을 벤치마킹하기 위해 머신러닝 지도 학습 분류 및 앙상블 알고리즘 중에서 실무 범용성이 가장 높은 트리 기반 gradient boosting 계열 알고리즘 3종을 선정해 비교 분석을 수행했다.

4.1 Boosting 기저 모델

첫째는 XGBoost(Extreme Gradient Boosting) 모델이다. 이 모델은 정교한 규제(L1, L2 Regularization)와 잔차 기반 학습을 통해 안정적인 수렴 특성을 제공하며, 본 연구가 제시한 라벨 신뢰도 및 시간 가중치 기반 학습 구조를 손실 함수 수준에서 결합해 신용카드 사기 탐지 도메인에 적용되었다. 둘째는 LightGBM(Light Gradient Boosting Machine)이다. LightGBM은 대규모 대용량 데이터 처리에 최적화된 모델로, 수직 성장 방식인 리프 중심 성장(Leaf-wise) 알고리즘을 채택한다. 예측 오류가 큰 리프 노드를 집중적으로 분기시키기 때문에 본 연구의 라벨 지연 보정 가중치 함수와 결합했을 때 극심한 불균형 데이터셋(3.5%) 환경에서 연산 소요 시간을 획기적으로 낮추면서도 정확도를 확보하는 구조적 특징을 보여주었다. 별도의 수치 정규화 없이도 극단적인 오른쪽 치우침(right-skewed) 분포를 가진

거래 금액 피처를 안정적으로 학습할 수 있는 강점이 있다.

셋째는 CatBoost(Categorical Boosting) 모델이다. 결제 사기 탐지 데이터의 특성상 카드 대분류, 주소, 이메일 도메인, 기기 정보 등 범주형(Categorical) 변수가 다수 존재하는데, CatBoost는 이러한 범주형 변수를 ordering_based encoding 구조로 자동 처리해 별도의 one-hot 인코딩 없이 가동된다. 대칭 트리(Symmetric Tree) 구조를 활용해 예측 균일성과 이상치에 대한 강건함을 보장하지만, 본 연구의 대규모 결제 거래 행렬 연산 환경에서는 LightGBM 대비 시간 복잡도가 상대적으로 증가하는 특성을 보였다.

4.2 가중치 설계 원리

본 연구의 핵심은 세 기저 모델 각각에 공통으로 적용되는 가중 결합 손실 구조이다. 라벨 지연 환경에서 isFraud=0 라벨이 항상 정상 거래를 의미하지 않는다는 점을 고려해 신뢰도 가중치(Confidence Weight)와 시간 가중치(Time Decay Weight)를 설계하고 이를 손실 함수 수준에서 각 모델에 주입했다. 신뢰도 가중치 $\omega(p)$ 는 1차 모델의 예측 확률 p 를 활용해 $\omega(p) = 1 - |p - 0.5|$ 로 정의되며, 예측값이 0.5에 가까운 불확실한 경계 샘플에는 낮은 가중치를, 0 또는 1에 가까운 신뢰 가능한 샘플에는 높은 가중치를 부여함으로써 라벨 오염 샘플의 학습 영향력을 자동으로 억제한다. 시간 가중치 $\tau(t)$ 는 거래 발생 이후 경과 시간 t 를 반영한 지수 감소 함수 $\tau(t) = e^{-(t/T)}$ 로 정의되며, 핵심 하이퍼파라미터인 T 는 후보값 {3.0, 5.0, 7.0, 10.0, 14.0}일에 대해 AUPRC 기준 그리드 서치를 수행한 결과 $T = 7.0$ 일에서 최고 성능(AUPRC 0.5123)을 기록하여 이후 모든 실험에 고정 적용했다. 최종 sample_weight는 두 가중치의 곱인 $w = \omega(p) \times \tau(t)$ 로 산출되며, 모델 구조 자체를 변경하지 않고 가중치 주입만으로 구현 가능하기 때문에 기존 실무 시스템에 최소한의 비용으로 도입할 수 있다는 실용적 장점을 가진다.

5. 결론

실험 결과, AUC, F1-Score, AUPRC 세 가지 핵심 지표에서 시간 가중치만 단독 적용한 세팅(TIME), 신뢰도 가중치만 단독 적용한 세팅(CONF)과 비교하는 소거 연구(Ablation Study)를 수행한 결과, 두 가중치를 모두 결합한 제안 방법(PROPOSE)이 모든 지표에서 가장 우수한 성과를 거두며 방법론의 유효성이 확인되었다. $W_days=60$ 일 조건에서 PROPOSE 기반의 모델별 최고 성능을 보면, CatBoost가 AUC 0.9079로 전반적인 판별력이 가장 우수했고, XGBoost는 F1-Score 0.5800으로 정밀도와 재현율의 균형이 가장 좋았으며, LightGBM은 AUPRC 0.6139와 43.67초의 추론 시간으로 탐지 정밀도와 연산 효율성 모두에서 강점을 보였다. 독립적 기여도 분석 결과, 불확실한 노이즈를 제어하는 신뢰도 가중치(CONF) 세팅이 성능 향상의 핵심적인 역할을 수행한 반면, 시간 가중치(TIME) 세팅은 최신 사기 패턴을 보정하며 약 1% 내외의 보조적 개선을 제공함을 규명하였다. 한편 W_days 를 90일로 확장해도 AUC 기준 0.80%p, F1-Score 기준 1.57%p 향상에 그쳐 성능이 수렴하는 양상을 보였으며, 이는 60일 윈도우만으로도 최적에 가까운 성능을 달성할 수 있음을 의미하므로 논문은 이를 실무 적용을 위한 최적 시간 윈도우 가이드라인으로 제시했다. 이 연구의 가장 큰 특징은 실용성으로, 모델 구조를 변경하지 않고 가중치 주입만으로 라벨 지연 문제를 해결할 수 있어 GPU 인프라나 전담 AI팀 없이도 즉시 현장에 도입 가능하다는 점이 높이 평가된다. 또한 단일 모델의 우수성을 주장하는 데 그치지 않고, 데이터 윈도우 크기(W_days)라는 환경 통제와 가중치 세팅 조합(PROPOSE, TIME, CONF) 조건 변화에 따라 세 모델 각각의 성능 차이와 한계를 소거 연구를 통해 정량적으로 비교했다는 점에서 방법론적 객관성과 완성도가 돋보이는 연구이다. 이러한 전개 방식은 소형 모델(SLM)에 재귀적 루프를 적용했을 때 모델 스케일에 따라 개선 효과가 어떻게 달라지는지 확인하고 그 한계점 자체를 관측하려는 제출자의 실험 연구와 방법론적 지향점이 일치하여 연구 설계 및 데이터 해석 측면에서 매우 훌륭한 참고가 된다.

[15] 머신러닝 기반 유료방송채널 시청률 예측 및 편성 시뮬레이션 연구, 김현민

1. 서론

논문명: 머신러닝 기반 유료방송채널 시청률 예측 및 편성 시뮬레이션 연구 - 방송 편성 전략의 데이터 기반 의사결정 가능성 탐구

저자: 이수진

연도/발행처: 2026년, 서강대학교 가상융합전문대학원 메타서비스비즈니스 전공 석사학위논문

검색 조건: 최근 학위논문(2025~2026년), 키워드 머신러닝, 방송 시청률 예측을 기준으로 검색하였다.

이 논문은 유료방송채널의 편성 전략을 경험과 직관 중심으로 결정하던 방식에서 벗어나, 실제 편성표와 시청률 데이터를 머신러닝으로 학습하여 시청률을 예측하고 편성 시나리오를 실험한다. 국내 유료방송 시장은 OTT 서비스와 경쟁이 심해지고 시청자의 콘텐츠 소비 방식도 빠르게 바뀌고 있다. 따라서 어느 프로그램을 어느 시간대에 배치할지, 직전 프로그램의 시청률이 후속 프로그램에 어떤 영향을 주는지, 충성도 높은 프로그램을 약한 시간대에 배치하면 효과가 있는지 등을 데이터로 검토할 필요가 있다. 이 논문을 선택한 이유는 머신러닝이 단순 예측 정확도 비교를 넘어 방송 편성 의사결정과 연결되는 과정을 보여주기 때문이다.

2. 연구 개요

연구 필요성은 OTT와 유료방송의 경쟁 심화에서 출발한다. OTT는 개인화 추천과 데이터 기반 큐레이션을 통해 콘텐츠 노출 전략을 계속 조정한다. 반면 유료방송채널은 정해진 시간표에 따라 프로그램을 송출해야 하므로 시간대와 프로그램 단위의 편성 전략이 중요하다.

연구 목적은 두 단계이다. 첫째, 실제 유료방송채널의 편성 및 시청률 데이터를 사용해 머신러닝 기반 시청률 예측모델을 구축하고 검증한다. 둘째, 검증된 예측모델을 이용해 여러 편성전략 시나리오를 구성하고 평균 시청률과 핵심 KPI 변화를 비교한다. 수행 절차는 데이터 수집, 변수 설정, 전처리, 예측모델 구축, 모델 검증, 시나리오 시뮬레이션, 경영적 효과 분석 순서로 진행된다. 예측 단계에서는 LightGBM과 XGBoost를 비교하고, RMSE, MAE, R^2 로 성능을 평가한다. 해석 단계에서는 변수 중요도와 SHAP 분석을 사용한다.

3. 데이터

논문에서 사용한 데이터는 2024년 1월 1일부터 2025년 9월 30일까지의 국내 유료방송채널 1개 편성 데이터이다. 데이터는 1시간 단위 편성 슬롯을 기준으로 구성되었고, 원시 데이터 기준 총 15,336개 표본과 14개의 기초 변수를 포함한다. 이후 시계열 기반 학습, 검증, 테스트 분할에는 총 14,789개 표본이 사용되었다. 종속변수는 수도권 남녀 20~40대의 타겟 시청률(RATING)이다.

주요 변수는 방송 일자, 요일, 방송 시작 시각, 프로그램명, 회차, 장르, 편성 길이, 직전 프로그램 시청률, 전전 프로그램 시청률, 최근 3회 평균 시청률(PROG_MA3), 직전 회차 시청률(PROG_LAST), 전주 동일 시간대 시청률(SLOT_LAST), 시청 충성도(LOYALTY), 프라임타임 여부(IS_PRIME) 등이다. 전처리 과정에서는 결측치와 이상치를 탐색하고 변수 타입에 맞는 인코딩을 계획하였다. 방송 데이터는 시간 순서가 중요하기 때문에 무작위 분할을 하지 않고 2024년은 학습, 2025년 1~3월은 검증, 2025년 4~9월은 테스트 데이터로 나누었다.

4. 모델 분석

논문에 포함된 핵심 머신러닝 모델은 LightGBM과 XGBoost이다. 두 모델 모두 Gradient Boosting Tree 기반 앙상블 알고리즘으로, 여러 개의 약한 결정트리를 순차적으로 학습시켜 예측 성능을 높인다. 방송 시청률 데이터는 프로그램 인기, 시간대, 직전 프로그램, 충성도 등이 비선형적으로 상호작용하므로 트리 기반 부스팅 모델이 적합하다.

LightGBM은 빠른 학습 속도와 메모리 효율이 장점이고, XGBoost는 정규화와 안정적인 일반화 성능이 강점이다. 성능 비교 결과 XGBoost가 더 우수했다. LightGBM은 테스트셋 기준 RMSE 0.1418, MAE 0.0856, R^2 0.9033을 기록하였다. XGBoost는 테스트셋 기준 RMSE 0.0993, MAE 0.0615, R^2 0.9526을 기록하여 더 낮은 예측 오차와 더 높은 설명력을 보였다. 변수 중요도와 SHAP 분석에서는 최근 3회 평균 시청률(PROG_MA3), 직전 회차 시청률(PROG_LAST), 전주 동일 시간대 시청률(SLOT_LAST), 리드인 효과, 프라임타임 여부가 주요 변수로 나타났다.

5. 결론

논문의 연구 결과는 머신러닝 기반 예측모델이 유료방송채널 편성 데이터에서도 실무적으로 의미 있는 성능을 낼 수 있음을 보여준다. 특히 XGBoost는 테스트셋 기준 R^2 0.9526을 기록하여 시청률 변동을 높은 수준으로 설명하였다. 다만 여러 편성 조정 시나리오의 평균 시청률 개선 폭은 크지 않았다. 이는 예측 정확도가 높다고 해서 곧바로 큰 편성 개선 효과가 보장되는 것은 아니며, 실제 편성 변경에는 시청자 반응, 경쟁 채널, 콘텐츠 홍보, 계절 이벤트 등 추가 요인을 함께 고려해야 함을 의미한다.

본인이 생각한 이 논문의 가장 큰 특징은 예측과 시뮬레이션을 연결했다는 점이다. 많은 머신러닝 연구는 모델 정확도만 제시하지만, 이 논문은 예측모델을 사용해 실제 편성전략을 바꾸는 가상 실험을 수행한다. 또한 성능 결과를 광고 매출 증가, 인건비 절감, 모델 도입 비용 등 경영 지표로 연결해 머신러닝 도입의 경제적 타당성까지 검토한다. 한계는 데이터가 국내 유료방송채널 1개에 한정되어 다른 채널이나 장르로 일반화하기 어렵다는 점이다. 종합하면 이 연구는 AI가 편성을 자동으로 대체한다기보다, 편성자의 판단을 보조하고 시나리오를 사전에 검증하는 도구로 활용될 수 있음을 보여주는 연구라고 평가할 수 있다.

[16] “인공지능을 활용한 전기자동차 통합 열관리 제어시스템 모델링 및 실시간성 검증에 관한 연구”에 대한 리뷰 보고서, 김준수

1. 서론

이 보고서는 한양대학교 대학원 미래모빌리티학과 임종원이 2025년 2월 발표한 석사학위논문 “인공지능을 활용한 전기자동차 통합 열관리 제어시스템 모델링 및 실시간성 검증에 관한 연구”를 대상으로 하였다.

해당 논문은 DBpia에 ‘전기자동차 인공지능’을 키워드로 하여 검색하였으며 2025년과 2026년 내의 학위논문으로 범위를 한정하였다. 현재 전기자동차의 보급은 빠르게 확산되고 있으며 그에 따라 배터리 사고 이슈에 대해서도 많은 관심과 우려 또한 확산되고 있다. 전기자동차에 대한 과장된 공포를 방지하고 미래 기술의 원활한 도입을 위해 전기자동차와 인공지능 기술을 연계한 에너지 관리 기술을 소개하고자 해당 키워드를 선정하였다.

2. 연구 개요

2.1 연구 필요성 및 목적

내연기관과 달리 배터리가 유일한 에너지원인 전기자동차는 저온 환경에서 주행거리가 최대 50%까지 감소하는 문제를 안고 있다. 이에 따라 이용 에너지를 최소화하면서도 각 부품의 적정 온도를 유지하는 제어 알고리즘 개발이 시급한 상황이다.

이러한 제어 알고리즘을 실제 전기자동차에 적용하기 전에 안전하고 효율적으로 검증하는 수단이 HIL(Hardware In-the-loop Simulation)이다. 기존의 열관리 방식인 Simscape 시스템의 경우 다양한 파라미터 튜닝을 복잡한 기반 수식으로 유사한 시뮬레이션 결과를 얻을 수는 있지만 특정한 과도 상황에서는 단위 시간이 10^{-10} 초 단위까지 떨어져 실시간 시뮬레이션 자체가 불가능하다는 한계를 갖는다.

이를 해결하기 위해서 해당 논문에서는 신경망 기반 차수 축소 모델로 기존 모델과 유사한 수준의 정확도를 유지하고 고정 단위로 실시간 시뮬레이션이 가능한 모델을 개발하였다.

2.2 수행 절차

먼저 해당 논문에서는 우선 수식기반 모델링 이후 신경망 기반으로 모델링 하는 순서를 채택하였다. 수식기반 모델링으로는 상용화된 전기자동차의 열관리 시스템에서 자주 사용하는 방식인 두 개의 냉각수 회로를 통한 열관리 시스템을 모델링 대상으로 선정하였다. 또한 고온 열관리에서 저온 열관리, 냉매 기반 냉각 시스템 모델을 순차적으로 살펴보았다.

수식 기반 모델링에서 고온 열관리 모델링은 전장 부품 발열 모델, 전장 부품 열 교환 모델, 냉각수 펌프 모델, 냉각수 탱크 모델, 라디에이터 시스템 모델, 팬 모델 순으로 모델 검증을 진행하였으며 이후 고온 열관리 시스템 모델 시뮬레이션 검증으로 마무리하였다.

저온 열관리 시스템 모델링은 배터리 냉각 시스템 모델과 캐빈 모델을 살펴보았으며, 기존 냉매 기반 냉각 시스템 모델은 증기 압축기 모델과 팽창 밸브 모델, 응축기 및 증발기 모델을 살펴보았다.

이후 인공지능 기반의 냉매 열관리 시스템 모델링을 본격적으로 다루었으며 차수 축소 모델링을 선정하여 절차를 진행하였다.

3. 데이터

신경망 학습에 사용된 데이터는 Simscape 기반 기준 모델의 시뮬레이션 출력으로부터 생성되었다. 냉매 사이클 내부의 압력과 상변화 경계 등은 센서로 직접 측정하기 어렵고 냉매의 물성과 거동 특성은 내부 상태로 간주되기 때문이다. 학습에 사용된 주행 시나리오는 UDDS, HWFET, US06, NEDC, WLTP의 5종 표준 주행 사이클과, GPS/INS 장비(RT3001)를 탑재한 차량으로 실제 시내버스를 추종하며 취득한 실도로 데이터 Bus5413을 포함하였다. 각 시나리오에 온도 25·30·35°C를 조합한 총 18개 조건에서 시뮬레이션을 수행하였다.

신경망의 입출력은 냉매 기반 냉각 시스템의 물리적 구조를 고려하여 결정되었다. 시스템은 압축기, 응축기, 3방향 밸브, 2개의 열팽창 밸브, 증발기, 배터리 칠러로 구성되며, 냉매의 내부 상태를 시스템 내부로 은닉하면 외부에서 제어 가능하거나 측정 가능한 변수만 입력으로 정의할 수 있다. 이에 따라 입력은 압축기 회전속도, 냉각 모드 신호, 응축기 유입 외기의 온도 및 유량, 증발기 유입 실내 공기의 온도 및 유량, 배터리 칠러로 유입되는 냉각수의 온도 및 유량의 총 8개 변수로 구성되었다. 출력은 증발기에서의 열교환량과 배터리 칠러에서의 열교환량 2개이며, 이 두 값은 캐빈 냉방과 배터리 냉각 성능을 결정하는 핵심 변수이다. 시계열 샘플링 단위 시간은 0.1초이며 LSTM 학습용 시퀀스 길이는 20초 50초 100초 150초의 4가지 조건으로 탐색하였다.

4. 모델 분석

신경망 후보 모델로는 MLP와 LSTM 두 가지가 선정되었다. MLP는 인공 신경망의 기본 구조로 복잡한 신경망 구조 기초가 된다. 뉴런 또는 퍼셉트론이라고 하는 유닛을 조합한 입력층, 은닉층, 출력층으로 구성되어 각 계층의 뉴런이 다음 계층의 모든 뉴런과 연결되는 완전 연결 구조 기반으로 작동한다. 이는 보편 근사 정리에 의해 충분한 노드 수와 레이어를 갖추면 임의의 연속 비선형 시스템을 표현할 수 있다는 이론적 근거에서 채택되었다. LSTM은 순환 신경망의 한 종류이다. LSTM의 각 셀은 망각 게이트와 입력 게이트, 출력 게이트로 이루어져 있어 식을 이용해 이전 셀에서 제거할 정보를 결정하고 입력 게이트에서는 식을 통해 추가할 정보를 결정한다. 또한 식을 이용해 셀 상태 업데이트 및 출력 정보를 조정하는 방식으로 은닉 상태를 생성한다. 긴 시간 의존성을 갖는 시계열 데이터를 잘 학습할 수 있어 냉각 모드 전환 시 나타나는 과도 특성 표현에 적합하다는 판단 하에 선정되었다. 두 모델 모두 활성화 함수로 ReLU를 채택하였는데 이는 깊은 신경망에서 발생하는 Vanishing Gradient 문제를 완화하기 때문이다.

5. 결론

본 연구는 전기자동차의 통합 연관리 제어 시스템을 모델링하고 실시간 시뮬레이션 환경 검증을 진행했다. 전체 시스템 중에서 냉각수 기반 열관리 회로는 열 교환의 매개체가 되는 냉각수가 상변화를 하지 않으므로 수식 기반 모델링을 진행했고 높은 정확도를 갖고 있음을 확인했다. 냉매의 상변화를 이용하는 냉매 사이클 기반의 냉각 시스템에는 신경망 기반 모델링을 활용했으며 전체 시스템에서 신경망 기반으로 모델링할 부위를 선정해서 그에 맞는 입출력을 결정했다.

논문의 가장 돋보이는 특징은 시스템 특성에 따라 물리 기반 모델과 데이터 기반 모델을 전략적으로 분리 적용한 점이다. 냉각수 기반 회로는 수식 기반으로 처리해 모델의 설명 가능성을 확보하고, 비선형성이 강한 냉매 사이클만 신경망으로 대체하여 계산 효율을 극대화한 하이브리드 전략은 실용성과 신뢰성을 동시에 갖춘 접근법으로 평가된다. 또한 실도로 계측 데이터인 Bus5413을 검증 전용으로 분리 활용하여 표준 사이클만으로는 드러나기 어려운 실제 주행 과도 특성에 대한 일반화 성능을 별도 검증한 점도 연구의 완성도를 높이는 요소이다. 다만 LSTM 모델의 블랙박스 특성상 학습 범위를 벗어난 극한 조건에서의 결과를 보증하기 어렵다는 점은 한계로 남는다.