

머신러닝 모델 학습절차 분석

202476624 권호근

I. 서론

1. 연구 배경

- 당뇨병은 현대 사회에서 가장 흔한 만성 질환 중 하나로, 조기 예측 및 예방이 매우 중요
특히 혈당, 체질량지수(BMI), 연령 등 기본적인 건강 데이터만으로도 당뇨병 발병 위험을 어느 정도 예측할 수 있어 머신러닝 기반의 분석이 활발히 이루어지고 있음
- 본 연구에서는 Kaggle의 Pima Indians Diabetes 공개 의료 데이터를 활용하여 여러 머신러닝 모델을 비교·분석하고, 당뇨병 여부 예측의 정확도와 중요 변수를 도출하는 것을 목표로 함

2. 연구 목적

- 건강 지표를 기반으로 당뇨병 발병 여부를 예측하는 머신러닝 모델 구축
- 모델별 성능 비교(Logistic Regression, Random Forest, SVM)
- 데이터 분석을 통한 당뇨병 위험 요인 도출
- 실험 결과를 기반으로 의료적 시사점과 모델 개선 방향 제안

II. 연구 방법

1. 데이터셋 개요

- 데이터 출처: Kaggle - Pima Indians Diabetes Database
- 전체 샘플 수: 768개
- 특성(Feature): 8개
- 타겟(Target): Outcome (0 = 비당뇨, 1 = 당뇨)
- 구성 변수

| 변수명 | 설명 |
|--------------------------|--------------|
| Pregnancies | 임신 횟수 |
| Glucose | 포도당 수치 |
| BloodPressure | 이완기 혈압 |
| SkinThickness | 피부 두께 두께 |
| Insulin | 혈중 인슐린 |
| BMI | 체질량지수 |
| DiabetesPedigreeFunction | 가계력 기반 당뇨 지수 |
| Age | 나이 |
| Outcome | 당뇨 여부 |

2. 데이터셋 전처리

- 0 값 처리: 생리적으로 0이 될 수 없는 항목(Glucose 등)은 결측치로 간주하고
중간값(median)으로 대체
- 정규화(Scaling): StandardScaler를 이용해 모든 변수 스케일 조정
- 훈련/테스트 분리

- Train:Test = 80:20
- stratify=Outcome 적용하여 클래스 비율 유지

3. 탐색적 데이터 분석(EDA)

EDA를 활용한 당뇨/비당뇨 그룹 간 차이 분석

(1) 변수별 평균 비교

- Glucose
 - 비당뇨: 109.9
 - 당뇨: 140.1
- BMI
 - 비당뇨: 30.4
 - 당뇨: 35.2
- Age
 - 비당뇨: 31.2
 - 당뇨: 37.1

→ 당뇨 그룹이 모든 주요 변수에서 높은 값을 보임

(2) Outcome과의 상관관계

| 변수명 | 상관계수 |
|-------------|------|
| Glucose | 0.49 |
| BMI | 0.29 |
| Age | 0.23 |
| Pregnancies | 0.22 |

→ 포도당 수치가 Outcome에 가장 큰 영향을 미침

III. 모델 학습 및 평가

1. 실험 활용 모델

- Logistic Regression
- Random Forest Classifier
- Support Vector Machine (RBF Kernel)

IV. 실험 결과

1. 1차 모델 성능 비교 (기본 모델)

| 모델 | Accuracy | Precision | Recall | F1-score |
|---------------------|----------|-----------|--------|----------|
| Logistic Regression | 0.803 | 0.693 | 0.667 | 0.680 |
| Random Forest | 0.779 | 0.653 | 0.612 | 0.632 |
| SVM (RBF) | 0.753 | 0.624 | 0.600 | 0.611 |

2. 해석

- 정확도(Accuracy): Logistic Regression이 가장 높음
- 재현율(Recall): 당뇨 환자를 놓치지 않는 비율
 - Logistic Regression이 가장 우수(0.667)

- 의료 분야에서는 환자를 놓치지 않는 것이 중요 → Logistic Regression 우수

V. 모델 최적화(Hyperparameter Tuning)

1. 최적화 대상 모델

- Random Forest
- GridSearchCV로 n_estimators, max_depth, min_samples_split 튜닝

2. 최적화 결과

- Best Params : n_estimators=50, max_depth=5, min_samples_split=5

3. 성능

| 변수명 | 상관계수 |
|-----------|-------|
| Accuracy | 0.784 |
| Precision | 0.678 |
| Recall | 0.612 |
| F1-score | 0.643 |

4. 결론

- 최적화 후에도 Logistic Regression보다 성능 열세
- 특히 Recall이 낮아 의료적 활용성 떨어짐
- 최종 모델은 Logistic Regression 선정

VI. 최종 분석: 중요 변수 해석

1. Logistic Regression 계수 분석

- 영향도 순서:
 - 1) Glucose(포도당)
 - 2) BMI(비만도)
 - 3) Age(나이)
 - 4) Pregnancies(임신 횟수)
- Glucose는 가장 강력한 위험 인자
- BMI와 Age 또한 당뇨병 판단에서 중요한 역할

2. 의료적 의미

- 혈당 관리가 가장 중요
- 비만과 고령이 당뇨 위험을 크게 증가
- 임신 횟수 증가도 일정 위험을 갖는다