

Cybersecurity Intrusion Prediction

Author: Madhura Atmaram Bhagat

Dataset: Cybersecurity Intrusion Detection Dataset

<https://www.kaggle.com/code/madhuraatmarambhagat/cybersecurity-intrusion-prediction>

1. 개요 (Overview)

이 프로젝트는 보안 트래픽/로그 데이터를 사용하여 침입 여부를 예측하는 머신러닝 분류 모델을 구축하는 과정을 다룹니다.

전체 절차는 다음 순서로 구성됩니다.

- 1) 라이브러리 및 데이터 불러오기
- 2) 탐색적 데이터 분석 (EDA)
- 3) 모델 학습(Classifiers)
- 4) 모델 평가
- 5) 결론

2. 라이브러리 및 데이터 불러오기

가. 설명

- 기본적인 데이터 분석 및 모델 학습을 위한 라이브러리를 불러옵니다.
- Kaggle dataset을 읽어서 DataFrame 형태로 불러옵니다.

```
In [1]:  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import seaborn as sns  
from sklearn.model_selection import train_test_split  
from sklearn.ensemble import AdaBoostClassifier, GradientBoostingClassifier, RandomForestClassifier  
from sklearn.tree import DecisionTreeClassifier  
from sklearn.linear_model import LogisticRegression  
from sklearn.naive_bayes import GaussianNB  
from sklearn.metrics import accuracy_score, confusion_matrix, f1_score, recall_score, precision_score  
from sklearn.preprocessing import LabelEncoder, StandardScaler
```

```
In [2]:  
data=pd.read_csv("/kaggle/input/cybersecurity-intrusion-dataset/cybersecurity_intrusion_data.csv")  
data.head(5)
```

Out[2]:

	session_id	network_packet_size	protocol_type	login_attempts	session_duration	encryption_used	ip_reputation_score	failed
0	SID_00001	599	TCP	4	492.983263	DES	0.606818	1
1	SID_00002	472	TCP	3	1557.996461	DES	0.301569	0
2	SID_00003	629	TCP	3	75.044262	DES	0.739164	2
3	SID_00004	804	UDP	4	601.248835	DES	0.123267	0
4	SID_00005	453	TCP	5	532.540888	AES	0.054874	1

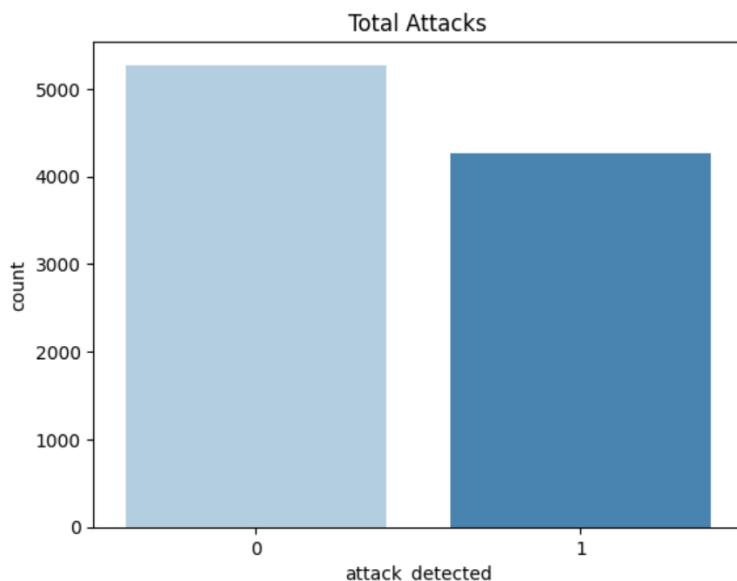
3. 데이터 탐색 (EDA)

가. 설명

- 데이터 구조 확인
- 클래스 분포(정상 vs 침입 여부) 파악

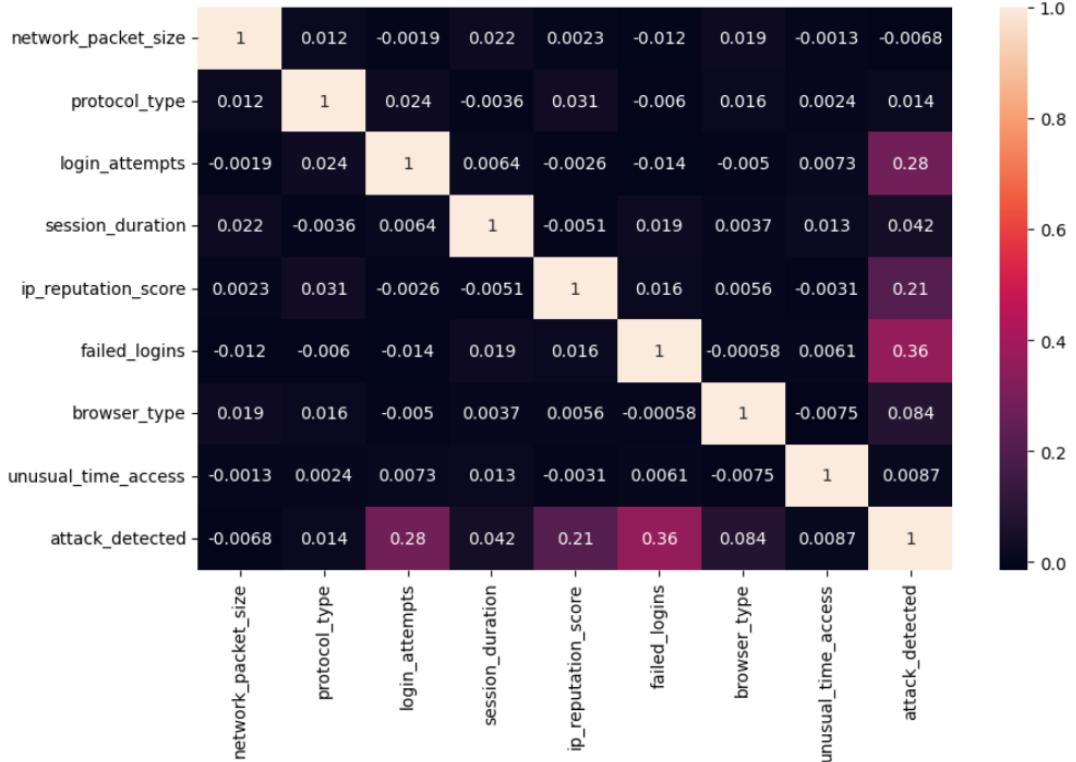
나. 코드

```
In [8]:  
sns.countplot(x="attack_detected", data=data, palette="Blues")  
plt.title("Total Attacks")  
plt.show()
```



```
In [9]: le=LabelEncoder()
data["protocol_type"] = le.fit_transform(data["protocol_type"])
data["browser_type"] = le.fit_transform(data["browser_type"])
```

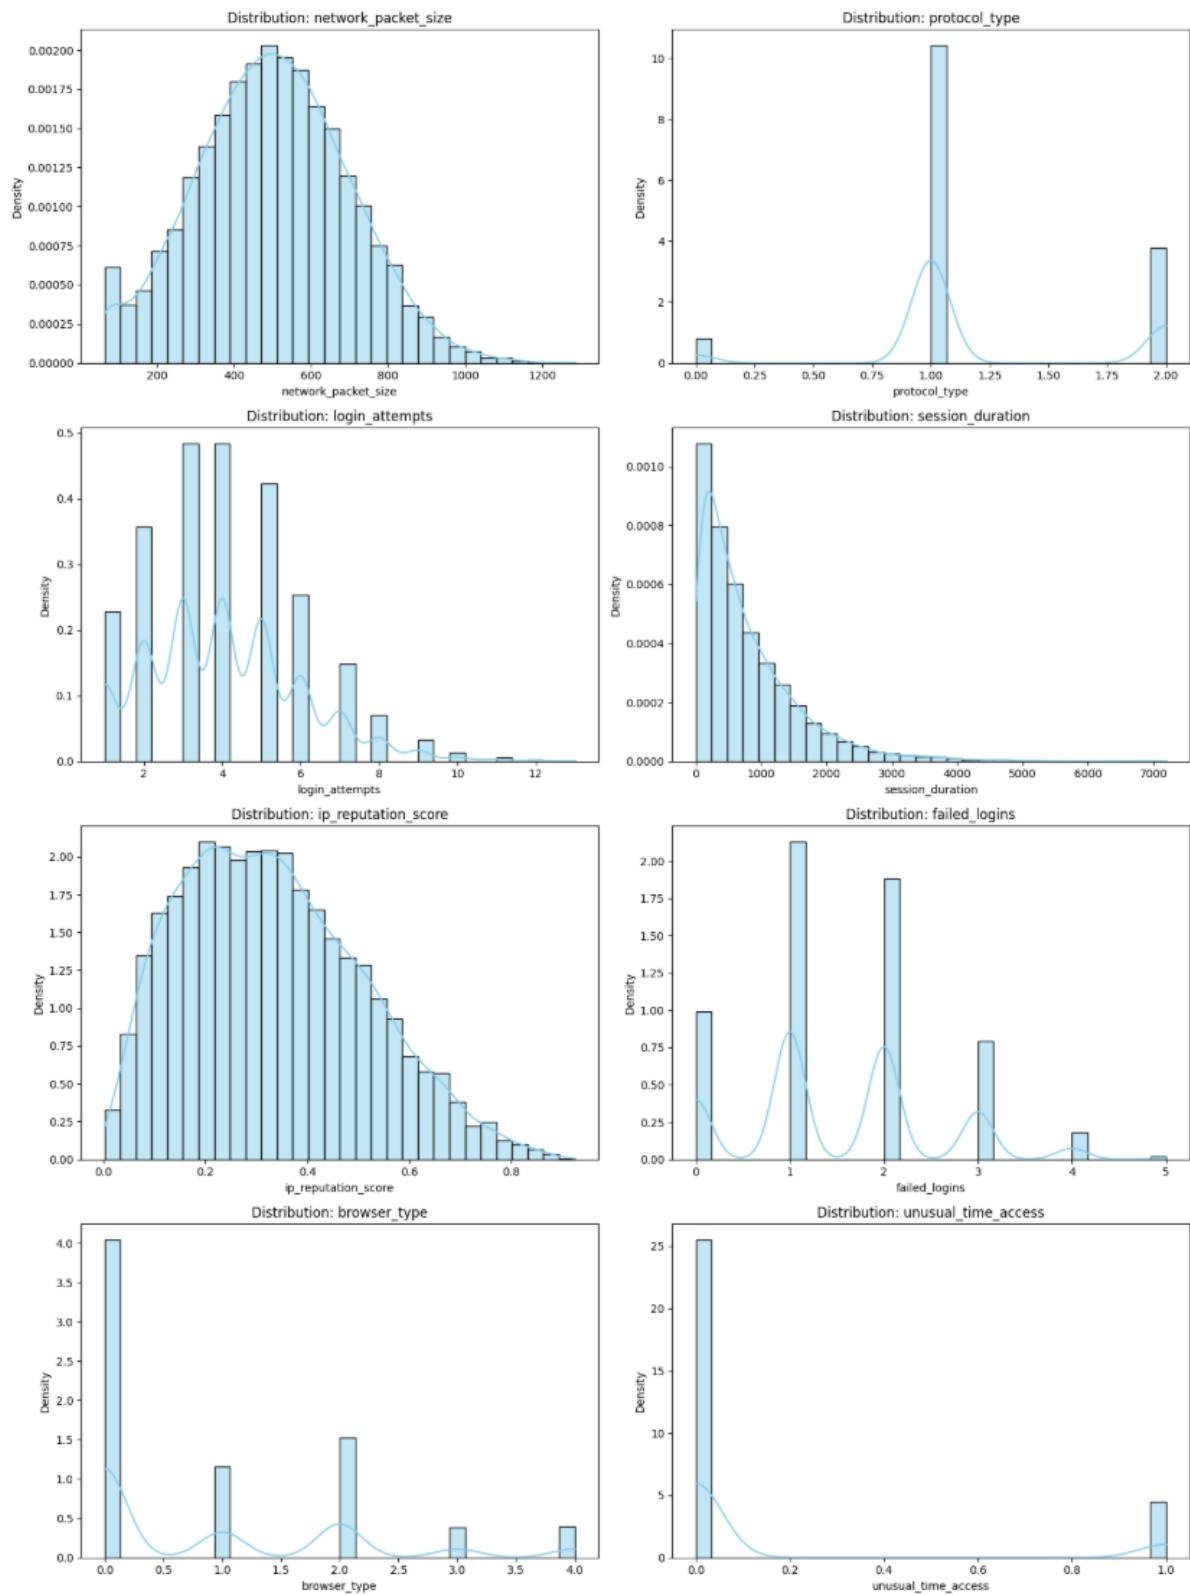
```
In [10]: plt.figure(figsize=(10,6))
sns.heatmap(data.corr(), annot=True)
plt.show()
```



```
In [11]: numeric_cols = data.select_dtypes(include=[np.number]).columns
num_cols = 2
num_rows = (len(numeric_cols) + num_cols - 1) // num_cols
plt.figure(figsize=(15, num_rows * 5))

for i, column in enumerate(numeric_cols, 1):
    plt.subplot(num_rows, num_cols, i)
    sns.histplot(data[column], kde=True, stat='density', color='skyblue', bins=30)
    plt.title(f"Distribution: {column}")
    plt.xlabel(column)
    plt.ylabel('Density')

plt.tight_layout()
plt.show()
```



4. 모델 학습(Classifier)

가. 설명

- 모델 선택
- 학습용/테스트용 데이터 분리
- 모델 학습

나. 코드

```
In [13]:  
models={  
    "Random Forest Classifier":RandomForestClassifier(),  
    "Decision Tree Classifier":DecisionTreeClassifier(),  
    "Ada Boost Classifier":AdaBoostClassifier(),  
    "Logistic Regression":LogisticRegression(),  
    "Gradient Boosting Classifier":GradientBoostingClassifier(),  
    "Naive Bayes Classifier":GaussianNB()  
}
```

```
In [14]:  
x=data.drop(["attack_detected"],axis=1)  
y=data["attack_detected"]  
x_train,x_test,y_train,y_test=train_test_split(x,y,test_size=0.25,random_state=42)  
ss=StandardScaler()  
x_train=ss.fit_transform(x_train)  
x_test=ss.transform(x_test)
```

5. 모델 평가

가. 설명

노트북에서는 기본적인 지도학습 모델들을 적용하여 성능을 비교합니다.

- Random Forest
- Logistic Regression
- Decision Tree

나. 코드

```
In [15]: metrics = {
    'Model': [],
    'Accuracy': [],
    'Precision': [],
    'Recall': []
}
for name,model in models.items():
    model.fit(x_train,y_train)
    y_pred=model.predict(x_test)
    acc = accuracy_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)
    recall=recall_score(y_test,y_pred)
    precision=precision_score(y_test,y_pred)
    metrics['Model'].append(name)
    metrics['Accuracy'].append(acc * 100)
    metrics['Precision'].append(precision * 100)
    metrics['Recall'].append(recall * 100)
    print(f"Model: {name}")
    print(f"Accuracy: {acc*100}")
    print(f"Precision: {precision*100}")
    print(f"F1 Score: {f1*100}")
    print(f"Recall: {recall*100}")
print("-" * 30)
```

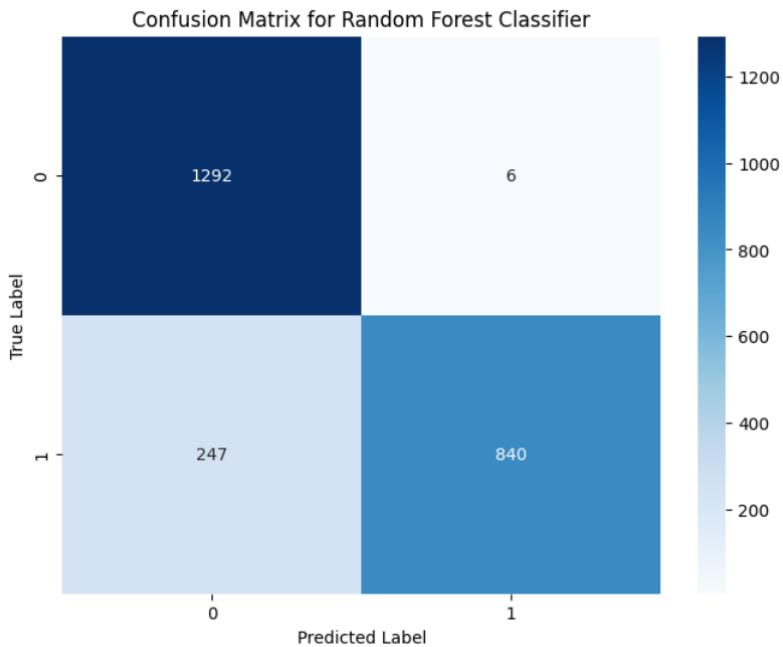
6. 결과

가. 모델 성능 분석

- **Random Forest** 가 가장 높은 정확도와 균형 잡힌 Precision/Recall 성능을 보임
 - Logistic Regression 및 Decision Tree 도 일정 수준의 성능을 보이나 데이터의 복잡도, 피처 간 상호작용 측면에서 Random Forest 가 더 유리함

나. 코드

```
In [16]: accuracy_results={}
for name,clf in models.items():
    clf.fit(x_train,y_train)
    y_pred=clf.predict(x_test)
    accuracy=accuracy_score(y_test,y_pred)
    accuracy_results[name]=accuracy
    cm = confusion_matrix(y_test, y_pred)
    plt.figure(figsize=(8, 6))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', xticklabels=np.unique(y), yticklabels=np.unique(y))
    plt.title(f'Confusion Matrix for {name}')
    plt.xlabel('Predicted Label')
    plt.ylabel('True Label')
    plt.show()
```



```
In [17]: metrics_df = pd.DataFrame(metrics)
plt.figure(figsize=(14, 6))
metrics_df.set_index('Model').plot(kind='bar', width=0.8, figsize=(14, 7), color=['skyblue', 'lightgreen', 'lightcoral'])
plt.title('Comparison of Model Metrics (Accuracy, Precision, Recall)', fontsize=16)
plt.ylabel('Score (%)', fontsize=14)
plt.xlabel('Model', fontsize=14)
plt.xticks(rotation=45)
plt.legend(title='Metrics', loc='upper left')
plt.tight_layout()
plt.show()
```

